ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO BÀI TẬP LỚN A1

CO5085 · Học sâu và ứng dụng trong thị giác máy tính

Học kỳ 261 · Năm học 2026–2027

So sánh ResNet18 và Swin-T trên CIFAR-100

Sinh viên

Huỳnh Thành Đạt	2570161
Giảng viên	Lê Thành Sách
	Nguyễn Quốc Minh

Thành phố Hồ Chí Minh, tháng 11 năm 2026

Tóm tắt

Thực nghiệm so sánh ResNet18 và Swin-T trên CIFAR-100 để khảo sát ảnh hưởng của tiền huấn luyện và số tầng được cập nhật. Thiết lập 20 epoch gồm tám cấu hình với ba seed. Mỗi kiến trúc được huấn luyện từ đầu và thử ba chế độ với trọng số ImageNet, gồm chỉ học bộ phân loại, tinh chỉnh một phần và tinh chỉnh toàn bộ.

Trong thiết lập 20 epoch, Swin-T tinh chỉnh toàn bộ đạt độ chính xác cao hơn ResNet18 và cần nhiều thời gian, bộ nhớ hơn. Hai bản Swin-T chạy dưới cùng lịch 40 epoch đạt lần lượt 60,30% khi khởi tạo ngẫu nhiên và 86,39% khi dùng trọng số ImageNet. Độ chính xác của bản ngẫu nhiên tăng rõ so với cấu hình 20 epoch, trong đó quá trình học dừng gần mức đoán ngẫu nhiên ở một số lượt.

Tổng quan báo cáo

Bài toán	Phân loại 100 lớp ảnh CIFAR-100.
Kiến trúc	ResNet18 và Swin-T. Các bản tiền huấn luyện dùng trọng số ImageNet.
Đối chứng	Huấn luyện từ đầu, chỉ học đầu ra, tinh chỉnh một phần và tinh chỉnh toàn bộ.
Phép đo	Độ chính xác, macro-F1, thời gian và bộ nhớ trong hai thiết lập với tổng cộng 30 lượt.
Kết quả chính	Swin-T từ đầu đạt 60,30% trong lịch 40 epoch. Bản ImageNet cùng lịch đạt 86,39%.
Giới hạn	Cách chia có một số ảnh trùng pixel. Phép đối chứng 40 epoch dành riêng cho Swin-T.

Mục lục

Tóm tắt **i**

Tổng quan báo cáo **ii**

1 Bài toán và dữ liệu **1**

1.1 Mục tiêu và phạm vi 1

1.2 CIFAR-100 và tình trạng license 1

1.3 Phân bố dữ liệu và cách chia tập 1

1.4 Tiền xử lý và tải dữ liệu 2

2 Kiến trúc và chế độ huấn luyện **3**

2.1 ResNet18: đối chứng CNN 3

2.2 Swin-T: đối chứng Transformer 3

2.3 Ma trận đối chứng 4

3 Thiết lập thực nghiệm và phép đo **5**

3.1 Thiết lập 20 epoch 5

3.2 Thiết lập 40 epoch cho Swin-T 5

3.3 Chọn checkpoint và mở test 6

3.4 Chi phí và môi trường 6

3.5 Thông tin tái lập 6

4 Kết quả trong thiết lập 20 epoch **8**

4.1 So sánh các chế độ huấn luyện 8

4.2 Thời gian, bộ nhớ và số tham số 8

4.3 Thảo luận kết quả 9

4.3.1 Ảnh hưởng của mức tinh chỉnh 9

4.3.2 Chi phí và lỗi phân loại 9

4.4 Đường cong và lỗi phân loại 9

5 Kết quả đối chứng khởi tạo Swin-T **14**

6 Kết luận và giới hạn **15**

6.1 Kết luận 15

6.2 Giới hạn 15

6.2.1 Ảnh trùng giữa các split 15

Tài liệu tham khảo **16**

Danh sách hình vẽ

4.1 ResNet18 scratch: train/val CE và accuracy ở seed 42. 10
4.2 Swin-T scratch: train/val CE và accuracy ở seed 42. 10
4.3 ResNet18 pretrained full: đường cong ở seed 42. 10
4.4 Swin-T pretrained full: đường cong ở seed 42. 11
4.5 Confusion matrix test của ResNet18 full ở seed 42; hàng là nhãn thực tế. 11
4.6 Confusion matrix test của Swin-T full ở seed 42. 12
4.7 Các dự đoán sai có confidence cao của ResNet18 full ở seed 42, hiển thị ảnh gốc 32×32. 12
4.8 Các dự đoán sai có confidence cao của Swin-T full ở seed 42. 13

5.1 Đường cong học của Swin-T khởi tạo ngẫu nhiên trong lịch 40 epoch, seed 42. 14

Danh sách bảng

2.1 Bốn chế độ cho mỗi họ kiến trúc, cùng split và ba seed. 4

4.1 Accuracy và macro-F1 của tám cấu hình, trung bình và SD mẫu qua ba seed. Accuracy theo phần trăm, F1 theo thang 0–1. 8

4.2 Tổng tham số và tham số được học theo triệu (M). Thời gian huấn luyện đủ 20 epoch và bộ nhớ cấp phát cực đại là trung bình và độ lệch chuẩn mẫu qua ba seed trên RTX 5090. 8

5.1 Swin-T dưới cùng lịch 40 epoch, trung bình và độ lệch chuẩn mẫu qua ba seed. 14

Chương 1

Bài toán và dữ liệu

1.1 Mục tiêu và phạm vi

A1 so sánh CNN và Transformer trên CIFAR-100, tập trung vào ảnh hưởng của khởi tạo pretrained và mức độ đóng băng backbone. Hai kiến trúc được chọn là ResNet18 và Swin-T của torchvision. Thí nghiệm chính gồm 24 lượt, với bốn chế độ huấn luyện cho mỗi kiến trúc và ba seed 42, 43, 44. Thí nghiệm bổ sung khảo sát riêng cách khởi tạo Swin-T dưới cùng lịch huấn luyện 40 epoch.

Các so sánh chính gồm huấn luyện từ đầu với pretrained, và head-only với partial/full fine-tuning. Accuracy, macro-F1, thời gian và bộ nhớ được dùng để đánh giá hiệu quả cùng chi phí của từng chế độ.

1.2 CIFAR-100 và tình trạng license

CIFAR-100 gồm 60.000 ảnh màu 32×32, 100 nhãn chi tiết (fine classes) và 20 nhóm coarse classes. Bài này dự đoán toàn bộ 100 fine classes; không chọn subset ảnh hoặc lớp. Mỗi lớp có 500 ảnh official train và 100 ảnh official test [2]. Số lớp lớn hơn bài E1 và ảnh độ phân giải thấp có thể làm những lớp gần nhau khó phân biệt.

Nguồn chính là trang CIFAR của Toronto, của Alex Krizhevsky, Vinod Nair và Geoffrey Hinton. Trang này không nêu license tường minh; thẻ dataset chính thức `uoft-cs/cifar100` trên Hugging Face ghi *license: unknown* [2, 3]. Vì vậy, tình trạng license của dữ liệu được ghi là chưa rõ. Bản lưu CIFAR-100 dùng cho thực nghiệm được đối chiếu mã băm với bản gốc của Toronto. Dữ liệu ảnh được lưu riêng.

1.3 Phân bố dữ liệu và cách chia tập

Trong 50.000 ảnh phát triển, chỉ số được xáo theo từng lớp bằng seed 2026. Mỗi lớp đóng góp 450 ảnh cho tập huấn luyện và 50 ảnh cho tập validation. Tập test chính thức gồm 100 ảnh mỗi lớp. Ba tập lần lượt có 45.000, 5.000 và 10.000 ảnh, nên sai khác về số ảnh giữa các lớp không chi phối độ chính xác chung. Trung bình RGB của tập huấn luyện trên thang $[0, 1]$ là $(0{,}507, 0{,}487, 0{,}441)$. Phép đối chiếu theo pixel phát hiện một số ảnh lặp, được phân tích riêng ở phần giới hạn.

1.4 Tiền xử lý và tải dữ liệu

Ảnh huấn luyện được đệm bốn pixel, cắt ngẫu nhiên về 32×32 và lật ngang với xác suất 0,5. Sau đó ảnh được nội suy song tuyến tính lên 96×96. Tập validation và tập test chỉ dùng bước nội suy. Cả hai kiến trúc chuẩn hóa ảnh với trung bình ImageNet $(0{,}485, 0{,}456, 0{,}406)$ và độ lệch chuẩn $(0{,}229, 0{,}224, 0{,}225)$. DataLoader xáo thứ tự ảnh huấn luyện. Phép biến đổi của từng ảnh được xác định theo seed, epoch và chỉ số ảnh, để một lượt tiếp tục từ checkpoint nhận lại đúng chuỗi biến đổi.

Chương 2

Kiến trúc và chế độ huấn luyện

2.1 ResNet18: đối chứng CNN

Giữ kiến trúc ResNet18 chuẩn torchvision, gồm stem convolution 7×7, max pooling và bốn residual stages. Một residual block cập nhật

$$h_{l+1} = \mathrm{ReLU}\left(F_l(h_l) + S_l(h_l)\right), \tag{2.1}$$

trong đó S_l là identity hoặc projection khi đổi số kênh/stride. Kernel convolution chia sẻ trọng số theo vị trí và khai thác quan hệ cục bộ. Sau adaptive average pooling, head Linear được thay để dự đoán 100 lớp; không thay stem thành biến thể ResNet chuyên cho CIFAR.

Bản pretrained dùng `ResNet18_Weights.IMAGENET1K_V1`. Ba chế độ là chỉ học `fc`; học `layer4` và `fc`; học toàn bộ. Bản scratch khởi tạo mới và học toàn bộ. BatchNorm trong phần frozen ở eval, nên cả tham số lẫn running mean/variance và bộ đếm batch được giữ nguyên.

2.2 Swin-T: đối chứng Transformer

Swin-T dùng patch embedding stride4, các stage Transformer theo cấp độ và patch merging. Attention trên cửa sổ có dạng

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d}} + B + M\right)V, \tag{2.2}$$

trong đó B là relative position bias, M là mask của shifted windows. Dịch cửa sổ giúp trao đổi thông tin giữa cửa sổ qua các block; việc giới hạn attention trong cửa sổ khác với global attention của ViT cổ điển.

Swin-T giữ kiến trúc chuẩn torchvision, với `head` được thay bằng Linear 100 lớp. Đầu vào 96×96 tạo lưới patch đầu 24×24; các stage muộn có lưới nhỏ hơn. Kích thước cửa sổ mặc định là 7, với padding nội bộ ở những stage có kích thước không chia hết cho cửa sổ.

Bản pretrained dùng `Swin_T_Weights.IMAGENET1K_V1`. Chế độ partial chỉ học stage cuối `features.7`, `norm` cuối và `head`; patch merging đứng trước stage cuối vẫn frozen. Head-

only chỉ học head. Frozen stages được giữ ở eval, bao gồm stochastic depth, để đặc trưng của phần đóng băng ổn định trong quá trình học head. Full và scratch cập nhật toàn bộ mô hình.

2.3 Ma trận đối chứng

Chế độ	Khởi tạo backbone	Phần được cập nhật
Scratch	Ngẫu nhiên	Toàn bộ
Head-only	ImageNet pretrained	Head100
Partial	ImageNet pretrained	Stage cuối và head; Swin thêm norm
Full	ImageNet pretrained	Toàn bộ

Bảng 2.1: Bốn chế độ cho mỗi họ kiến trúc, cùng split và ba seed.

Scratch cập nhật toàn bộ mô hình từ khởi tạo ngẫu nhiên. Số tham số tổng và trainable được đếm trực tiếp từ từng mô hình và lưu trong metadata. ResNet18 và Swin-T khác nhau về kiến trúc, capacity và recipe pretrained; các kết quả phản ánh tổng thể những khác biệt này trong cùng thiết lập.

Chương 3

Thiết lập thực nghiệm và phép đo

3.1 Thiết lập 20 epoch

Mỗi lượt của thí nghiệm chính có 20 epoch, batch 128 (giữ batch cuối), vòng lặp huấn luyện trực tiếp, AdamW với weight decay 10^{-4}, $\beta = (0{,}9, 0{,}999)$, epsilon 10^{-8}. Learning rate ban đầu là 10^{-3} cho scratch/head và 10^{-4} cho pretrained partial/full. Cosine scheduler bước một lần sau epoch:

$$\eta_e = \frac{\eta_0}{2}\left[1 + \cos\left(\frac{\pi e}{20}\right)\right], \tag{3.1}$$

với $e = 0$ trước epoch đầu. Loss cross-entropy không label smoothing:

$$\mathcal{L} = -\frac{1}{B}\sum_{i=1}^{B} \log \frac{\exp z_{i,y_i}}{\sum_{c=1}^{100} \exp z_{i,c}}. \tag{3.2}$$

Clip global gradient norm ở 1 trước optimizer.step. BF16 autocast áp dụng cho tất cả chế độ; tham số và Adam moments giữ FP32, không GradScaler, TF32 tắt và không dùng compile. Các phép đo được thiết lập trên RTX 5090 với bốn worker tải dữ liệu và bốn luồng CPU.

Ngân sách 20 epoch được giữ cố định giữa các chế độ. Learning rate của head/scratch và partial/full được đặt khác nhau để phù hợp với mức độ cập nhật backbone. Kết quả vì vậy được phân tích theo từng thiết lập đầy đủ; mức hội tụ còn được đối chiếu qua đường cong train/validation.

3.2 Thiết lập 40 epoch cho Swin-T

Trong lịch 20 epoch, hai lượt Swin-T khởi tạo ngẫu nhiên có độ chính xác trên tập validation 1% ở epoch cuối và cross-entropy huấn luyện gần ln(100). Vì sai số cao ngay trên tập huấn luyện, điểm thấp cho thấy quá trình tối ưu chưa học được biểu diễn phân lớp trong thiết lập đó. So sánh trực tiếp với bản ImageNet trong điều kiện này sẽ phóng đại chênh lệch giữa hai cách khởi tạo.

Thí nghiệm bổ sung giữ kiến trúc, cách chia tập, tiền xử lý, batch 128 và ba seed. Hai bản cập nhật toàn bộ tham số và chỉ khác nguồn trọng số backbone. Cả hai dùng AdamW với hệ số suy giảm trọng số 10^{-2}, tốc độ học tăng tuyến tính từ 2×10^{-5} đến 2×10^{-4}

qua năm epoch làm nóng, rồi giảm theo cosine đến cuối lịch 40 epoch. Lịch tăng dần và giảm cosine dựa trên cách huấn luyện Swin trong bài báo gốc [5], với ngân sách và tốc độ học điều chỉnh cho CIFAR-100. Thay đổi đồng thời lịch, ngân sách và hệ số suy giảm trọng số giúp kiểm tra cấu hình có học ổn định hơn hay không. Phép so sánh giữa hai lịch không tách riêng đóng góp của từng thay đổi.

3.3 Chọn checkpoint và mở test

Checkpoint được chọn theo độ chính xác validation lớn nhất; nếu bằng nhau, ưu tiên cross-entropy nhỏ hơn, rồi đến epoch sớm hơn. Tập validation được dùng để chọn mô hình trong quá trình huấn luyện. Test được đánh giá ở một bước riêng sau khi hoàn tất các lượt huấn luyện. Các cấu hình, learning rate và seed được cố định trước bước này.

Accuracy và macroF1 đều tính trên 100 lớp. Với mỗi lớp c,

$$F1_c = \frac{2TP_c}{2TP_c + FP_c + FN_c}, \qquad F1_{macro} = \frac{1}{100}\sum_{c=1}^{100} F1_c. \tag{3.3}$$

Trường hợp mẫu số bằng0 có F1 bằng0. Confusion matrix, support, precision, recall, F1 theo lớp và từng prediction được lưu để kiểm tra. Gallery lấy tối đa 8 lỗi confidence cao nhất của seed 42.

3.4 Chi phí và môi trường

Training time bao gồm data loading/augmentation và train pass, có CUDA synchronize trước/sau. Epoch time thêm validation. Thời gian dựng mô hình, lưu checkpoint và xuất báo cáo nằm ngoài hai khoảng đo này. Peak GPU memory là peak allocated trong train và validation của mỗi epoch, không phải reserved memory hoặc VRAM toàn hệ thống.

Metadata lưu GPU, torch/torchvision, CUDA/cuDNN, workers, CPU threads và chế độ deterministic. Các phép đo thời gian của cùng cấu hình được gộp khi những thông số môi trường này thống nhất.

3.5 Thông tin tái lập

Mỗi lượt lưu trạng thái huấn luyện ở cuối epoch để có thể tiếp tục từ mốc hoàn tất gần nhất. Checkpoint có kết quả trên tập validation tốt nhất giữ trọng số và chỉ số dùng để chọn mô hình. Dữ liệu, cách chia tập, mã nguồn và môi trường thực nghiệm được ghi nhận cùng từng lượt. Sai khác phần cứng hoặc thư viện có thể ảnh hưởng khả năng tái lập từng bit.

Notebook A1 trình bày từ khảo sát dữ liệu đến huấn luyện và đánh giá. Các tệp cấu hình và kết quả theo seed cho phép đối chiếu bảng với checkpoint đã chọn.

Chương 4

Kết quả trong thiết lập 20 epoch

4.1 So sánh các chế độ huấn luyện

Cấu hình	Validation (%)	Test (%)	Macro-F1	Thời gian (s)	Tham số (M)
ResNet18: Từ đầu	63,83 ± 0,51	64,35 ± 0,11	0,6422 ± 0,0012	86,6 ± 5,4	11,228
ResNet18: Chỉ đầu ra	61,89 ± 0,24	60,95 ± 0,29	0,6081 ± 0,0030	80,1 ± 0,2	0,051
ResNet18: Một phần	74,50 ± 0,31	73,96 ± 0,12	0,7396 ± 0,0011	80,2 ± 0,2	8,445
ResNet18: Toàn bộ	79,29 ± 0,10	78,97 ± 0,04	0,7898 ± 0,0006	80,4 ± 0,6	11,228
Swin-T: Từ đầu	2,81 ± 1,40	2,76 ± 1,26	0,0093 ± 0,0069	211,1 ± 1,6	27,596
Swin-T: Chỉ đầu ra	72,45 ± 0,10	71,67 ± 0,09	0,7154 ± 0,0009	86,1 ± 0,5	0,077
Swin-T: Một phần	78,99 ± 0,31	78,25 ± 0,22	0,7818 ± 0,0021	106,9 ± 0,2	14,262
Swin-T: Toàn bộ	86,89 ± 0,02	86,63 ± 0,22	0,8663 ± 0,0020	212,5 ± 0,6	27,596

24/24 lượt huấn luyện hoàn tất; 24/24 lượt đã đánh giá.

Bảng 4.1: Accuracy và macro-F1 của tám cấu hình, trung bình và SD mẫu qua ba seed. Accuracy theo phần trăm, F1 theo thang 0–1.

Kết quả được tổng hợp bằng trung bình và độ lệch chuẩn mẫu qua các seed. Danh sách lượt chạy và checkpoint tương ứng được lưu trong manifest.

4.2 Thời gian, bộ nhớ và số tham số

Kiến trúc	Chế độ	Tổng (M)	Học (M)	Giây	MiB
ResNet18	Từ đầu	11,228	11,228	$86,6 \pm 5,4$	$520,1 \pm 2,2$
ResNet18	Chỉ đầu ra	11,228	0,051	$80,1 \pm 0,2$	$251,0 \pm 0,0$
ResNet18	Một phần	11,228	8,445	$80,2 \pm 0,2$	$347,3 \pm 0,0$
ResNet18	Toàn bộ	11,228	11,228	$80,4 \pm 0,6$	$518,9 \pm 0,0$
Swin-T	Từ đầu	27,596	27,596	$211,1 \pm 1,6$	$2451,8 \pm 0,2$
Swin-T	Chỉ đầu ra	27,596	0,077	$86,1 \pm 0,5$	$502,9 \pm 0,0$
Swin-T	Một phần	27,596	14,262	$106,9 \pm 0,2$	$667,7 \pm 0,0$
Swin-T	Toàn bộ	27,596	27,596	$212,5 \pm 0,6$	$2451,9 \pm 0,0$

Bảng 4.2: Tổng tham số và tham số được học theo triệu (M). Thời gian huấn luyện đủ 20 epoch và bộ nhớ cấp phát cực đại là trung bình và độ lệch chuẩn mẫu qua ba seed trên RTX 5090.

4.3 Thảo luận kết quả

4.3.1 Ảnh hưởng của mức tinh chỉnh

ResNet18 chỉ học bộ phân loại đạt 60,95%, thấp hơn 64,35% của bản học từ đầu. Khi các tầng đặc trưng giữ nguyên, bộ phân loại tuyến tính chỉ có thể thay đổi ranh giới trên biểu diễn đã học từ ImageNet. Tinh chỉnh khối cuối đạt 73,96%, còn cập nhật toàn bộ đạt 78,97%. Kết quả cho thấy mức thích nghi của bộ trích xuất đặc trưng có ảnh hưởng đáng kể trên CIFAR-100.

Swin-T chỉ học bộ phân loại đạt 71,67%, tinh chỉnh một phần đạt 78,25% và tinh chỉnh toàn bộ đạt 86,63%. Bản khởi tạo ngẫu nhiên ở lịch 20 epoch chỉ đạt 2,76%. Hai trong ba seed kết thúc ở 1% trên tập validation, với cross-entropy huấn luyện gần ln(100). Điểm thấp xuất hiện trên cả hai tập, phù hợp với việc tối ưu chưa học được biểu diễn hữu ích. Lịch 40 epoch ở chương sau dùng chung tốc độ học và cách cập nhật cho hai cách khởi tạo Swin-T.

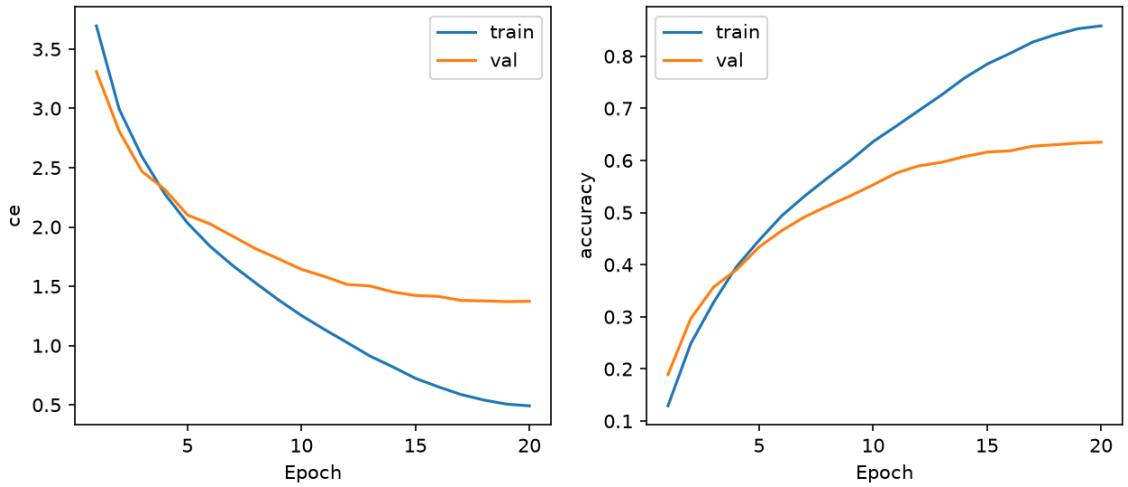
4.3.2 Chi phí và lỗi phân loại

Khi tinh chỉnh toàn bộ, Swin-T cao hơn ResNet18 7,66 điểm phần trăm độ chính xác trên tập test. Tính theo trung bình ba seed, Swin-T cần thời gian huấn luyện gấp 2,64 lần và bộ nhớ cấp phát cực đại gấp 4,73 lần. Với Swin-T, chỉ học bộ phân loại hoặc tinh chỉnh khối cuối giảm thời gian và bộ nhớ so với cập nhật toàn bộ, nhưng độ chính xác cũng thấp hơn. Với ResNet18, thời gian của ba chế độ tiền huấn luyện gần nhau trong lần đo này, trong khi bộ nhớ giảm rõ khi đóng băng nhiều tầng hơn.

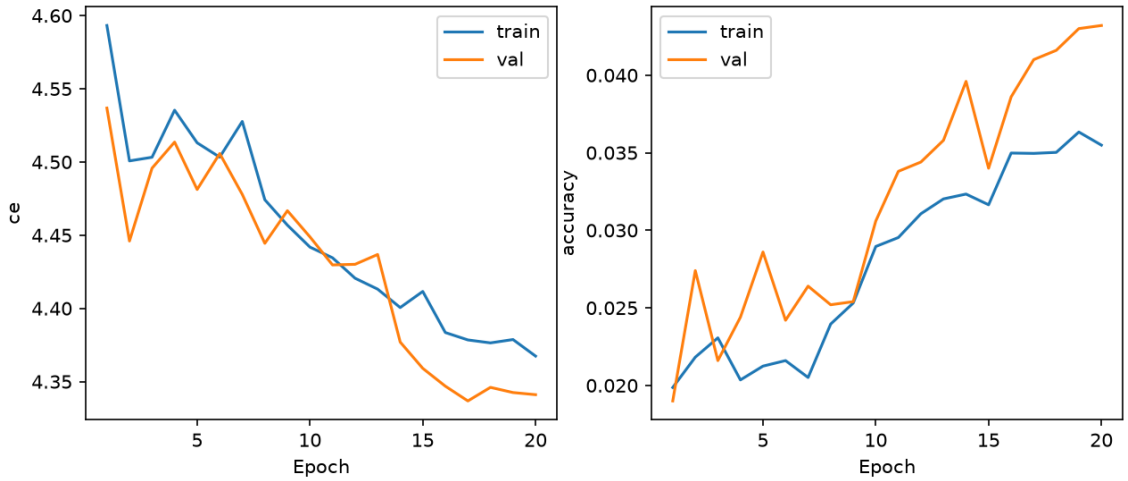
Ở epoch 20, ResNet18 tinh chỉnh toàn bộ đạt khoảng 99,1% trên tập huấn luyện và 79,2% trên tập validation; Swin-T tương ứng đạt 98,7% và 86,7%. Khoảng cách này cho thấy sai số khái quát hóa vẫn còn dù độ chính xác huấn luyện cao. Checkpoint dùng để đánh giá được chọn theo độ chính xác trên tập validation. Trong cả hai ma trận của seed 42, lớp cây sồi thường bị gán thành cây phong. Các ví dụ sai cho thấy độ phân giải gốc 32×32 khiến chi tiết hình dáng và kết cấu khó phân biệt.

4.4 Đường cong và lỗi phân loại

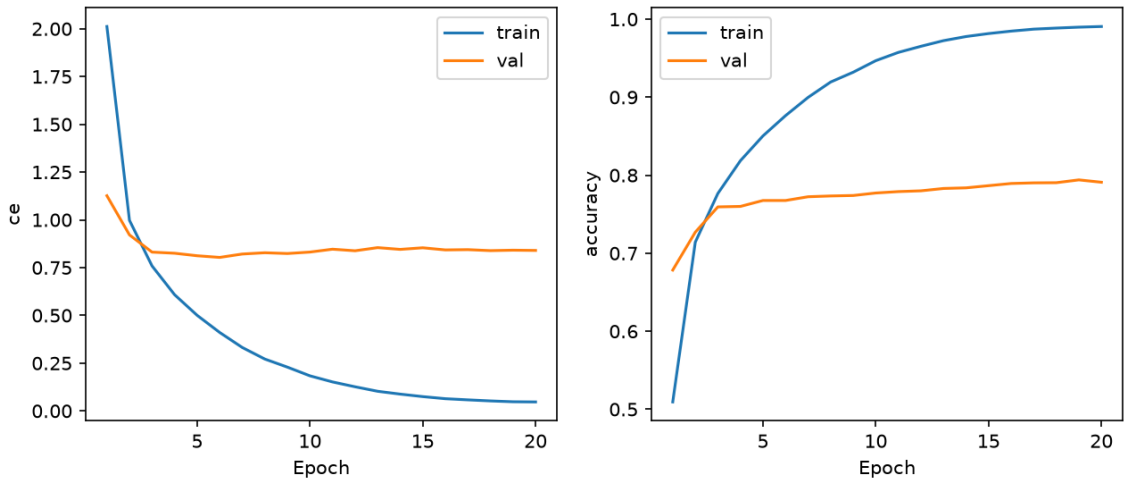
Các hình dùng seed 42 đã định trước, không chọn seed theo kết quả test. Ma trận lỗi dùng chỉ số lớp 0–99; danh sách tên lớp và số đếm đầy đủ nằm trong các tệp CSV kèm báo cáo.



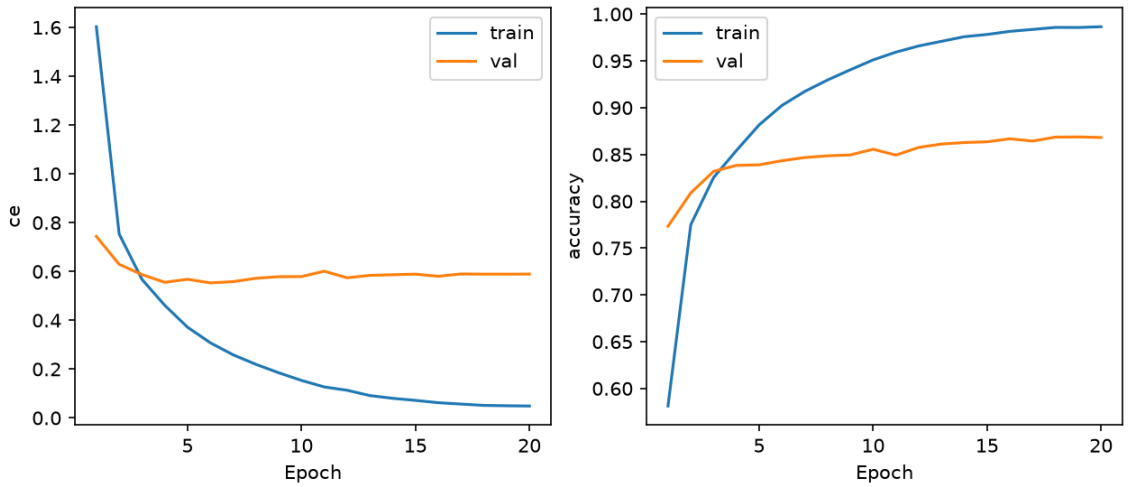
Hình 4.1: ResNet18 scratch: train/val CE và accuracy ở seed 42.



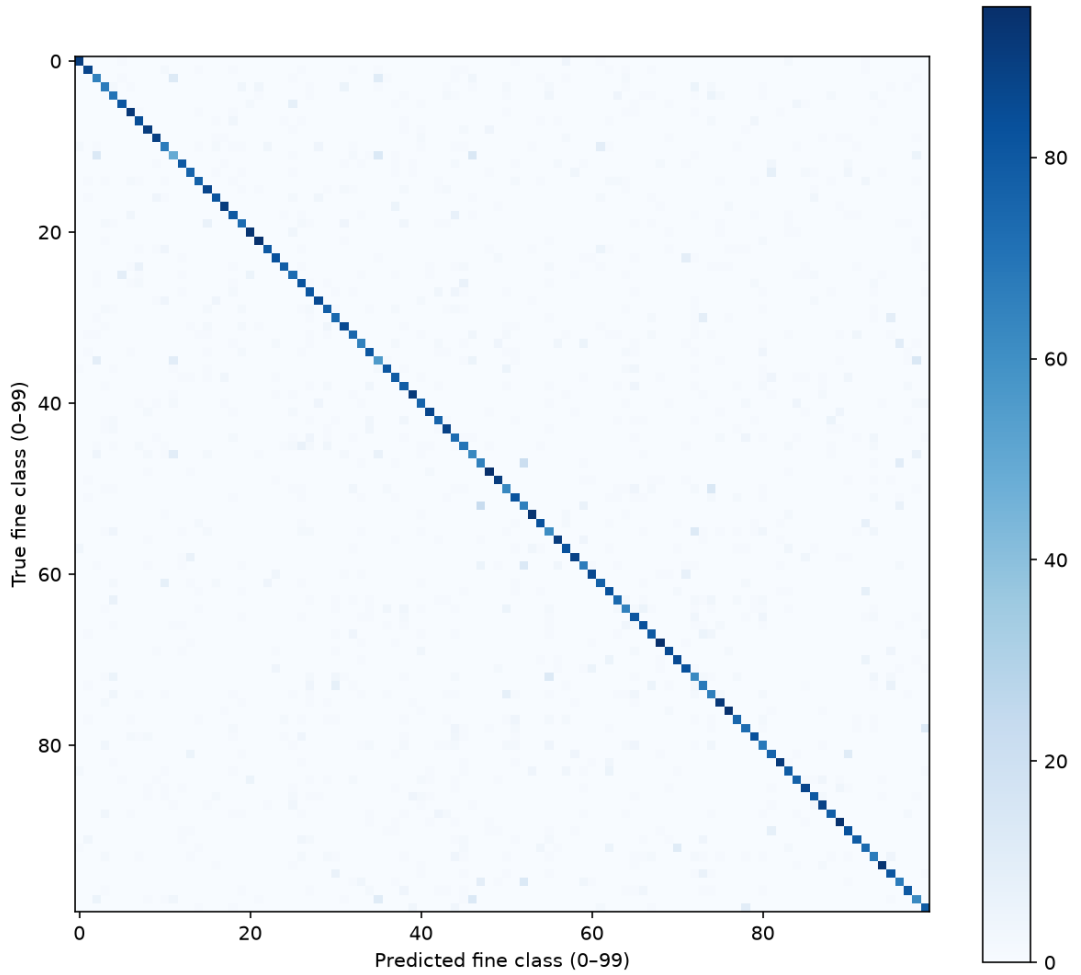
Hình 4.2: Swin-T scratch: train/val CE và accuracy ở seed 42.



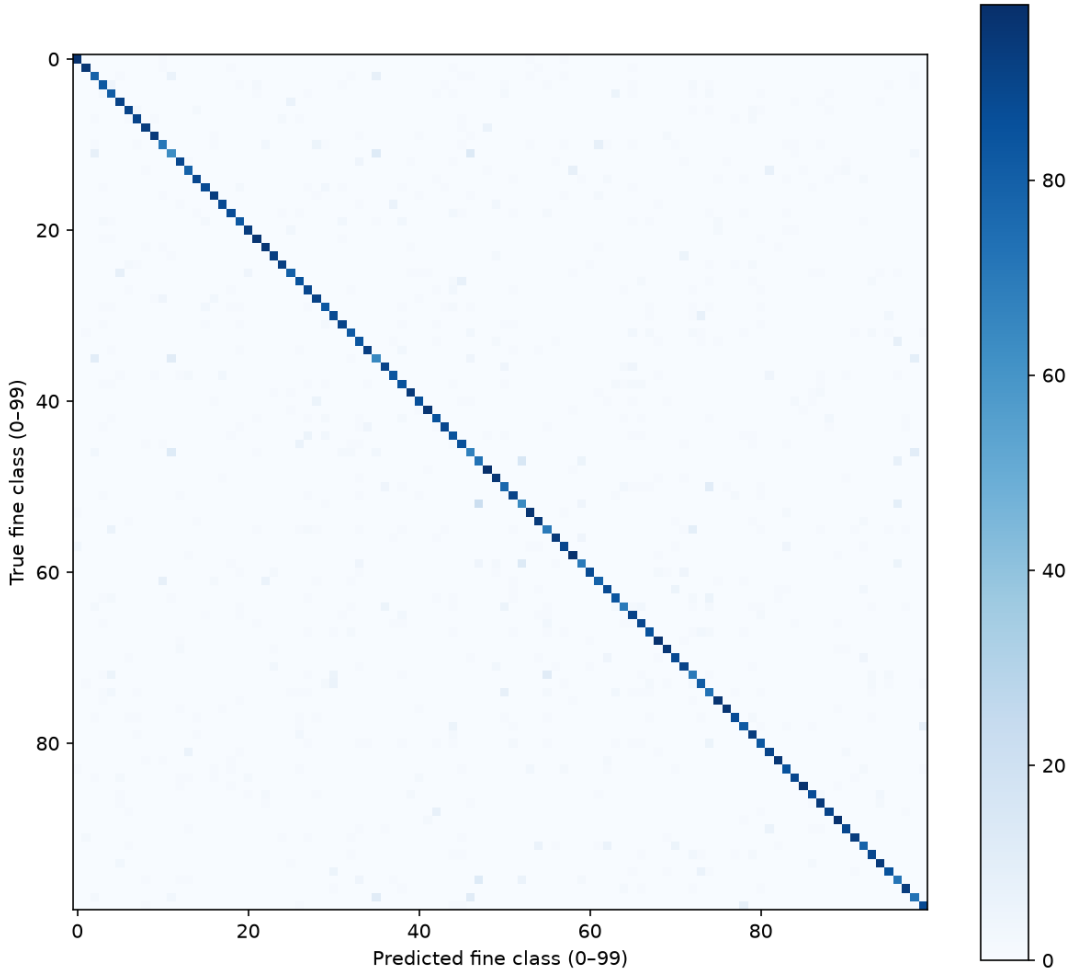
Hình 4.3: ResNet18 pretrained full: đường cong ở seed 42.



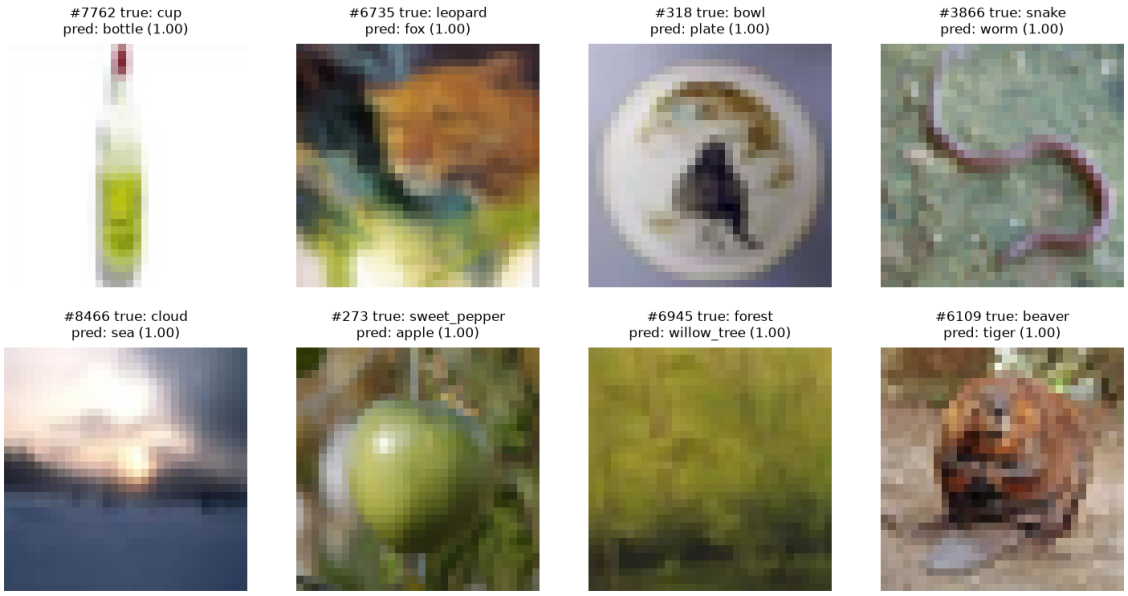
Hình 4.4: Swin-T pretrained full: đường cong ở seed 42.



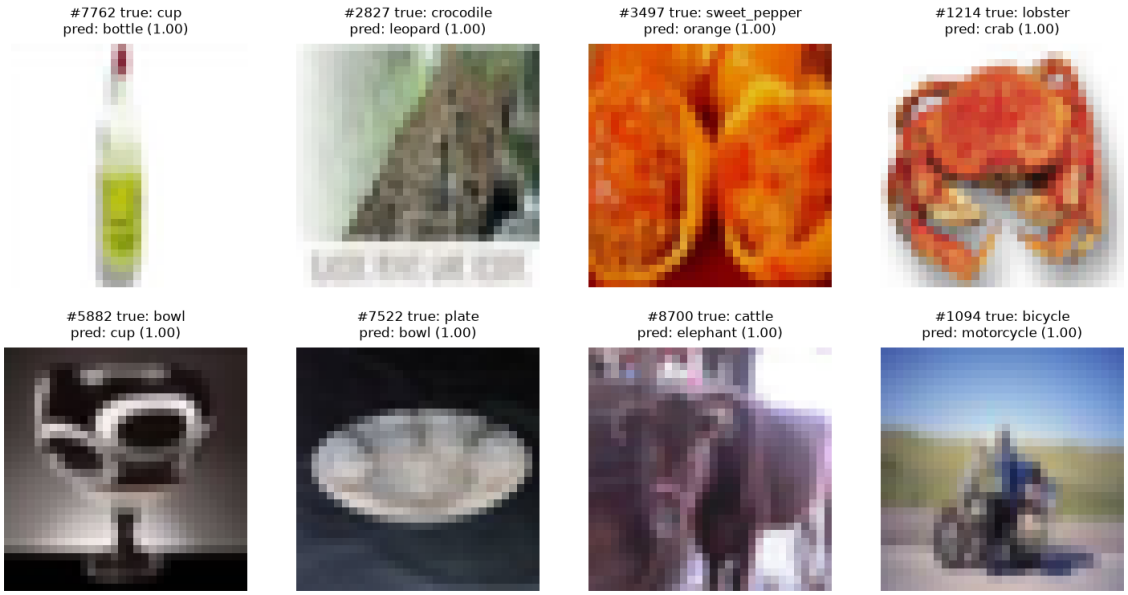
Hình 4.5: Confusion matrix test của ResNet18 full ở seed 42; hàng là nhãn thực tế.



Hình 4.6: Confusion matrix test của Swin-T full ở seed 42.



Hình 4.7: Các dự đoán sai có confidence cao của ResNet18 full ở seed 42, hiển thị ảnh gốc 32×32.



Hình 4.8: Các dự đoán sai có confidence cao của Swin-T full ở seed 42.

Chương 5

Kết quả đối chứng khởi tạo Swin-T

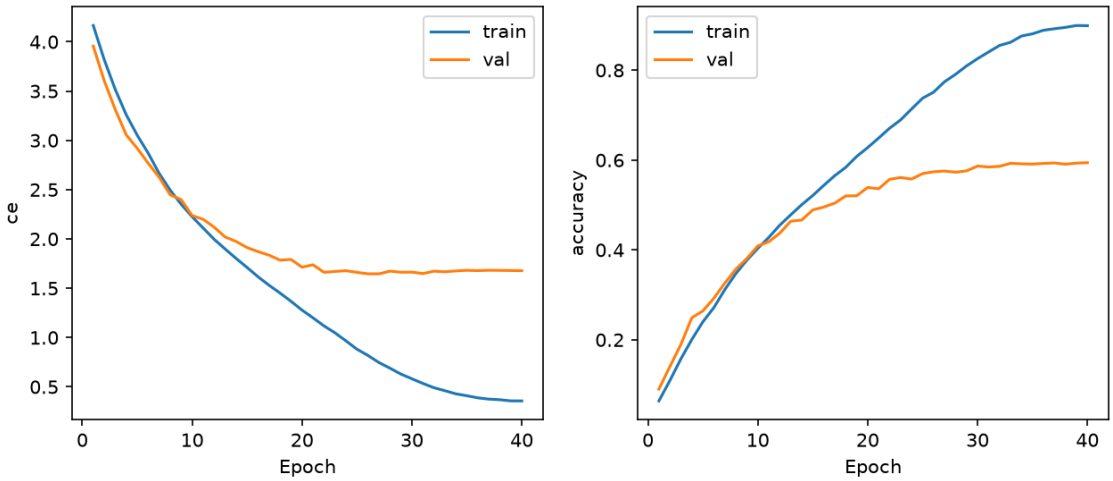
Cấu hình	Validation (%)	Test (%)	Macro-F1	Thời gian (s)	Tham số (M)
Swin-T: Từ đầu	59,89 ± 0,48	60,30 ± 0,05	0,6021 ± 0,0006	425,3 ± 0,9	27,596
Swin-T: Toàn bộ	86,33 ± 0,19	86,39 ± 0,34	0,8637 ± 0,0034	426,3 ± 0,3	27,596

6/6 lượt huấn luyện hoàn tất; 6/6 lượt đã đánh giá.

Bảng 5.1: Swin-T dưới cùng lịch 40 epoch, trung bình và độ lệch chuẩn mẫu qua ba seed.

Swin-T khởi tạo ngẫu nhiên đạt 60,30% trên tập test. Checkpoint được chọn ở các epoch 40, 38 và 38, tương ứng với seed 42, 43 và 44. Đường cong trên tập validation tăng trong phần lớn lịch học, cho thấy cấu hình khởi tạo ngẫu nhiên đã học được biểu diễn phân lớp. Ở cuối lịch, độ chính xác huấn luyện nằm trong khoảng 89,7–90,0%, trong khi độ chính xác trên tập validation đạt 59,4–60,2%, cho thấy khoảng cách khái quát hóa còn lớn.

Bản khởi tạo ImageNet đạt 86,39%. Chênh lệch theo cặp cùng seed là $26{,}08 \pm 0{,}30$ điểm phần trăm. Hai cấu hình dùng cùng lịch và cập nhật cùng số tham số, nên khoảng cách này mô tả lợi ích của khởi tạo từ trọng số ImageNet trong điều kiện đã khảo sát. Checkpoint của bản ngẫu nhiên thường được chọn muộn trong lịch, vì vậy cần thận trọng khi suy rộng kết quả sang ngân sách huấn luyện dài hơn.



Hình 5.1: Đường cong học của Swin-T khởi tạo ngẫu nhiên trong lịch 40 epoch, seed 42.

Chương 6

Kết luận và giới hạn

6.1 Kết luận

Trong thiết lập 20 epoch, tinh chỉnh khối cuối hoặc toàn bộ cho độ chính xác cao hơn chỉ học bộ phân loại ở cả ResNet18 và Swin-T. Khi tinh chỉnh toàn bộ, Swin-T đạt độ chính xác cao hơn ResNet18 với chi phí huấn luyện và bộ nhớ lớn hơn. Đối chứng ở Bảng 5.1 cho thấy cấu hình Swin-T khởi tạo ngẫu nhiên học được khi dùng lịch 40 epoch. Khoảng cách với bản ImageNet cần được đọc trong cùng lịch và trên cùng cách chia dữ liệu.

6.2 Giới hạn

Ảnh gốc 32×32 và đầu vào 96×96 khác với kích thước phổ biến 224×224 của các bản tiền huấn luyện. Thực nghiệm khảo sát hai kiến trúc trên CIFAR-100. Đối chứng bổ sung dành riêng cho Swin-T, nên không dùng để xếp hạng hai kiến trúc dưới cùng lịch 40 epoch. Hai họ cũng khác số tham số và quá trình tiền huấn luyện ImageNet. Ba seed mô tả biến thiên giữa các lượt khởi tạo, với cùng phần cứng và thiết lập workers. Tình trạng license của dữ liệu vẫn là chưa rõ.

6.2.1 Ảnh trùng giữa các split

Đối chiếu toàn bộ ảnh theo giá trị pixel phát hiện hai ảnh validation và mười ảnh test trùng với ảnh huấn luyện. Các bảng sử dụng đủ 10.000 ảnh test chính thức và giữ nguyên checkpoint đã chọn. Do mười ảnh trong số này đã xuất hiện khi huấn luyện, tập test có một phần nội dung trùng với tập huấn luyện.

Tính lại trên 9.990 dự đoán sau khi loại mười ảnh trùng cho độ chính xác trung bình 79,009% với ResNet18 và 86,677% với Swin-T khi tinh chỉnh toàn bộ. Thứ hạng của hai cấu hình giữ nguyên. Phép kiểm tra độ nhạy dùng lại các dự đoán đã lưu. Hai ảnh validation trùng vẫn có thể ảnh hưởng việc chọn checkpoint, và phạm vi đối chiếu chỉ bao gồm các ảnh trùng pixel chính xác. Dữ liệu đối chiếu được lưu trong `docs/training-evidence/`.

Phạm vi hỗ trợ của AI được trình bày trong `AI_USE_REPORT.md`.

Tài liệu tham khảo

[1] Lê Thành Sách, Nguyễn Quốc Minh. *Bài tập lớn A1: CNN vs Transformer trên tập ảnh lớn*. CO5085, học kỳ 261.

[2] A. Krizhevsky. *Learning Multiple Layers of Features from Tiny Images*. 2009. Trang dataset: `https://www.cs.toronto.edu/~kriz/cifar.html`.

[3] uoft-cs. *CIFAR100 dataset card*; license: unknown. `https://huggingface.co/datasets/uoft-cs/cifar100`.

[4] K. He và cộng sự. *Deep Residual Learning for Image Recognition*. CVPR 2016. `https://arxiv.org/abs/1512.03385`.

[5] Z. Liu và cộng sự. *Swin Transformer: Hierarchical Vision Transformer using Shifted Windows*. ICCV 2021. `https://arxiv.org/abs/2103.14030`.

[6] Torchvision. ResNet18 và Swin-T model API; sử dụng weight enum IMAGENET1K_V1. `https://docs.pytorch.org/vision/stable/models.html`.