ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO BÀI TẬP LỚN A1

CO5085 · Học sâu và ứng dụng trong thị giác máy tính

Học kỳ 261 · Năm học 2026–2027

So sánh ResNet18 và Swin-T trên CIFAR-100

Học viên

Huỳnh Thành Đạt	2570161
Giảng viên	Lê Thành Sách
	Nguyễn Quốc Minh

Thành phố Hồ Chí Minh, tháng 11 năm 2026

Tóm tắt

Thực nghiệm so sánh ResNet18 và Swin-T trên CIFAR-100 để khảo sát ảnh hưởng của pretraining và phạm vi cập nhật tham số. Thiết lập 20 epoch gồm tám cấu hình với ba seed. Mỗi kiến trúc được huấn luyện từ đầu và thử ba chế độ với trọng số ImageNet, gồm head-only, partial fine-tuning và full fine-tuning.

Trong thiết lập 20 epoch, Swin-T full fine-tuning đạt độ chính xác cao hơn ResNet18 và cần nhiều thời gian, bộ nhớ hơn. Hai bản Swin-T chạy dưới cùng lịch 40 epoch đạt lần lượt 60,30% khi khởi tạo ngẫu nhiên và 86,39% khi dùng trọng số ImageNet. Độ chính xác của bản ngẫu nhiên tăng rõ so với cấu hình 20 epoch, trong đó quá trình học dừng gần mức đoán ngẫu nhiên ở một số lượt.

Tổng quan báo cáo

Bài toán	Phân loại 100 lớp ảnh CIFAR-100.
Kiến trúc	ResNet18 và Swin-T. Các bản pretrained dùng trọng số ImageNet.
Đối chứng	Huấn luyện từ đầu, head-only, partial fine-tuning và full fine-tuning.
Phép đo	Độ chính xác, macro-F1, thời gian và bộ nhớ trong hai thiết lập với tổng cộng 30 lượt.
Kết quả chính	Swin-T từ đầu đạt 60,30% trong lịch 40 epoch. Bản ImageNet cùng lịch đạt 86,39%.
Giới hạn	Cách chia có một số ảnh trùng pixel. Phép đối chứng 40 epoch dành riêng cho Swin-T.

Mục lục

Tóm tắt **i**

Tổng quan báo cáo **ii**

1 Bài toán và dữ liệu **1**

1.1 Mục tiêu và phạm vi 1

1.2 Nguồn và cấu trúc CIFAR-100 1

1.3 Phân bố dữ liệu và cách chia tập 1

1.4 Tiền xử lý và tải dữ liệu 2

2 Kiến trúc và chế độ huấn luyện **3**

2.1 ResNet18: đối chứng CNN 3

2.2 Swin-T: đối chứng Transformer 3

2.3 Ma trận đối chứng 4

3 Thiết lập thực nghiệm và phép đo **5**

3.1 Thiết lập 20 epoch 5

3.2 Thiết lập 40 epoch cho Swin-T 5

3.3 Chọn checkpoint và đánh giá trên tập test 6

3.4 Chi phí và môi trường 6

4 Kết quả trong thiết lập 20 epoch **8**

4.1 So sánh các chế độ huấn luyện 8

4.2 Thời gian, bộ nhớ và số tham số 8

4.3 Thảo luận kết quả 9

4.3.1 Ảnh hưởng của chế độ fine-tuning 9

4.3.2 Chi phí và lỗi phân loại 9

4.4 Đường cong và lỗi phân loại 10

5 Kết quả đối chứng khởi tạo Swin-T **15**

6 Kết luận và giới hạn **17**

6.1 Kết luận 17

6.2 Giới hạn 17

6.2.1 Ảnh trùng giữa các split 17

Tài liệu tham khảo **18**

Danh sách hình vẽ

4.1 ResNet18 scratch: train/val CE và accuracy ở seed 42. 10
4.2 Swin-T scratch: train/val CE và accuracy ở seed 42. 10
4.3 ResNet18 pretrained full: đường cong ở seed 42. 11
4.4 Swin-T pretrained full: đường cong ở seed 42. 11
4.5 Confusion matrix test của ResNet18 full ở seed 42; hàng là nhãn thực tế. 12
4.6 Confusion matrix test của Swin-T full ở seed 42. 13
4.7 Các dự đoán sai có confidence cao của ResNet18 full ở seed 42, hiển thị ảnh gốc 32×32. 13
4.8 Các dự đoán sai có confidence cao của Swin-T full ở seed 42. 14

5.1 Đường cong học của Swin-T khởi tạo ngẫu nhiên trong lịch 40 epoch, seed 42. 16

Danh sách bảng

2.1 Bốn chế độ cho mỗi họ kiến trúc, cùng split và ba seed. 4

4.1 Accuracy và macro-F1 của tám cấu hình, trung bình và SD mẫu qua ba seed. Accuracy theo phần trăm, F1 theo thang 0–1. 8

4.2 Tổng tham số và tham số được học theo triệu (M). Thời gian huấn luyện đủ 20 epoch và bộ nhớ cấp phát cực đại là trung bình và độ lệch chuẩn mẫu qua ba seed trên RTX 5090. 8

5.1 Swin-T dưới cùng lịch 40 epoch, trung bình và độ lệch chuẩn mẫu qua ba seed. 15

Chương 1

Bài toán và dữ liệu

1.1 Mục tiêu và phạm vi

A1 so sánh CNN và Transformer trên CIFAR-100, tập trung vào ảnh hưởng của khởi tạo pretrained và mức độ đóng băng backbone. Hai kiến trúc được chọn là ResNet18 và Swin-T của torchvision. Thí nghiệm chính gồm 24 lượt, với bốn chế độ huấn luyện cho mỗi kiến trúc và ba seed 42, 43, 44. Thí nghiệm bổ sung khảo sát riêng cách khởi tạo Swin-T dưới cùng lịch huấn luyện 40 epoch.

Các so sánh chính gồm huấn luyện từ đầu với pretrained, và head-only với partial/full fine-tuning. Accuracy, macro-F1, thời gian và bộ nhớ được dùng để đánh giá hiệu quả cùng chi phí của từng chế độ.

1.2 Nguồn và cấu trúc CIFAR-100

CIFAR-100 gồm 60.000 ảnh màu 32×32, 100 nhãn chi tiết (fine classes) và 20 nhóm coarse classes. Bài này dự đoán toàn bộ 100 fine classes; không chọn subset ảnh hoặc lớp. Mỗi lớp có 500 ảnh trong tập train chính thức và 100 ảnh trong tập test chính thức [2]. Số lớp lớn hơn bài E1 và ảnh độ phân giải thấp có thể làm những lớp gần nhau khó phân biệt.

Dữ liệu được cung cấp trên trang CIFAR của University of Toronto. Trang nguồn không nêu license tường minh; dataset card `uoft-cs/cifar100` ghi *license: unknown*, nên báo cáo ghi nhận tình trạng license chưa rõ [2, 3]. Bản Python của dữ liệu được phân phối dưới dạng `cifar-100-python.tar.gz`. Sau khi giải nén, thư mục `cifar-100-python/` chứa ba tệp Python pickle: `train`, `test` và `meta`. Hai tệp đầu lưu mảng pixel ảnh cùng fine labels và coarse labels; `meta` lưu tên các lớp. Thực nghiệm đọc bản dữ liệu này bằng `torchvision.datasets.CIFAR100` [2, 6].

1.3 Phân bố dữ liệu và cách chia tập

Trong 50.000 ảnh phát triển, chỉ số được xáo theo từng lớp bằng seed 2026. Mỗi lớp đóng góp 450 ảnh cho tập train và 50 ảnh cho tập validation. Tập test chính thức gồm 100 ảnh mỗi lớp. Ba tập lần lượt có 45.000, 5.000 và 10.000 ảnh, nên sai khác về số ảnh giữa các

lớp không chi phối độ chính xác chung. Trung bình RGB của tập train trên thang $[0, 1]$ là $(0{,}507, 0{,}487, 0{,}441)$. Phép đối chiếu theo pixel phát hiện một số ảnh lặp, được phân tích riêng ở phần giới hạn.

1.4 Tiền xử lý và tải dữ liệu

Ảnh trong tập train dùng padding bốn pixel, random crop về 32×32 và random horizontal flip với xác suất 0,5. Sau đó, ảnh được resize lên 96×96 bằng bilinear interpolation với antialias. Tập validation và tập test chỉ dùng bước resize này. Resize cho phép dùng cùng kích thước đầu vào với hai kiến trúc và giảm chi phí so với đầu vào 224×224. Phép nội suy không khôi phục chi tiết đã mất trong ảnh gốc 32×32. Cả hai kiến trúc áp dụng normalization với trung bình ImageNet $(0{,}485, 0{,}456, 0{,}406)$ và độ lệch chuẩn $(0{,}229, 0{,}224, 0{,}225)$. DataLoader xáo thứ tự ảnh trong tập train. Phép biến đổi của từng ảnh được xác định theo seed, epoch và chỉ số ảnh, để một lượt tiếp tục từ checkpoint nhận lại đúng chuỗi biến đổi.

Chương 2

Kiến trúc và chế độ huấn luyện

2.1 ResNet18: đối chứng CNN

Giữ kiến trúc ResNet18 chuẩn torchvision, gồm stem convolution 7×7, max pooling và bốn residual stages. Một residual block cập nhật

$$h_{l+1} = \mathrm{ReLU}\left(F_l(h_l) + S_l(h_l)\right), \tag{2.1}$$

trong đó S_l là identity hoặc projection khi đổi số kênh/stride. Kernel convolution chia sẻ trọng số theo vị trí và khai thác quan hệ cục bộ. Kết nối residual cho phép khối học phần hiệu chỉnh $F_l(h_l)$ trên biểu diễn được truyền qua S_l, đồng thời tạo đường truyền gradient qua nhánh tắt [4]. Sau adaptive average pooling, head Linear được thay để dự đoán 100 lớp; không thay stem thành biến thể ResNet chuyên cho CIFAR.

Bản pretrained dùng `ResNet18_Weights.IMAGENET1K_V1`. Ba chế độ là chỉ học `fc`; học `layer4` và `fc`; học toàn bộ. Bản scratch khởi tạo mới và học toàn bộ. BatchNorm trong phần frozen ở eval, nên cả tham số lẫn running mean/variance và bộ đếm batch được giữ nguyên.

2.2 Swin-T: đối chứng Transformer

Swin-T dùng patch embedding stride 4, các stage Transformer theo cấp độ và patch merging. Window attention có dạng

$$\mathrm{Attention}(Q, K, V) = \mathrm{softmax}\left(\frac{QK^\top}{\sqrt{d}} + B + M\right)V, \tag{2.2}$$

Biểu thức trên mô tả một attention head: Q, K và V là các phép chiếu tuyến tính của token trong cửa sổ; d là số chiều của query/key. B là relative position bias và M là attention mask: các cặp token bị chặn nhận một giá trị âm lớn trước softmax để giảm trọng số attention về gần 0. Các head được ghép nối rồi chiếu tuyến tính. Swin luân phiên window attention và shifted-window attention để trao đổi thông tin qua ranh giới cửa sổ; patch merging giảm độ phân giải và tăng số kênh ở các stage sâu [5].

Swin-T giữ kiến trúc chuẩn torchvision, với `head` được thay bằng Linear 100 lớp. Đầu vào 96×96 tạo lưới patch đầu 24×24; các stage muộn có lưới nhỏ hơn. Kích thước cửa

sổ mặc định là 7, với padding nội bộ ở những stage có kích thước không chia hết cho cửa sổ.

Bản pretrained dùng `Swin_T_Weights.IMAGENET1K_V1`. Chế độ partial chỉ học stage cuối `features.7`, `norm` cuối và `head`; patch merging đứng trước stage cuối vẫn frozen. Head-only chỉ học head. Frozen stages được giữ ở eval, bao gồm stochastic depth, để đặc trưng của phần đóng băng ổn định trong quá trình học head. Full và scratch cập nhật toàn bộ mô hình.

2.3 Ma trận đối chứng

Chế độ	Khởi tạo backbone	Phần được cập nhật
Scratch	Ngẫu nhiên	Toàn bộ
Head-only	ImageNet pretrained	Head 100 lớp
Partial	ImageNet pretrained	Stage cuối và head; Swin thêm norm
Full	ImageNet pretrained	Toàn bộ

Bảng 2.1: Bốn chế độ cho mỗi họ kiến trúc, cùng split và ba seed.

Scratch cập nhật toàn bộ mô hình từ khởi tạo ngẫu nhiên. Số tham số tổng và trainable được đếm trực tiếp từ từng mô hình. Head-only khảo sát mức phù hợp của biểu diễn ImageNet khi chỉ thay bộ phân loại. Partial fine-tuning cho phép đặc trưng ở stage cuối thích nghi với CIFAR-100, còn full fine-tuning cập nhật cả các tầng trước đó. So sánh trong từng họ kiến trúc vì vậy cho thấy tác động của phạm vi cập nhật. So sánh ResNet18 với Swin-T đồng thời chịu ảnh hưởng của số tham số và quá trình pretraining, nên không cô lập riêng CNN với attention.

Chương 3

Thiết lập thực nghiệm và phép đo

3.1 Thiết lập 20 epoch

Mỗi lượt của thí nghiệm chính có 20 epoch, batch 128 (giữ batch cuối), vòng lặp huấn luyện trực tiếp, AdamW với weight decay 10^{-4}, $\beta = (0{,}9, 0{,}999)$, epsilon 10^{-8}. Learning rate ban đầu là 10^{-3} cho scratch/head và 10^{-4} cho pretrained partial/full. Cosine scheduler bước một lần sau epoch:

$$\eta_e = \frac{\eta_0}{2}\left[1 + \cos\left(\frac{\pi e}{20}\right)\right], \tag{3.1}$$

với $e = 0$ trước epoch đầu. Loss cross-entropy không label smoothing:

$$\mathcal{L} = -\frac{1}{B}\sum_{i=1}^{B} \log \frac{\exp z_{i,y_i}}{\sum_{c=1}^{100} \exp z_{i,c}}. \tag{3.2}$$

Ở đây, B là số ảnh trong batch, $z_{i,c}$ là logit của ảnh i tại lớp c và y_i là nhãn đúng. Cross-entropy tối ưu xác suất của nhãn đúng, còn accuracy và macro-F1 được dùng để đánh giá quyết định phân lớp. Clip global gradient norm ở 1 trước optimizer.step. BF16 autocast áp dụng cho tất cả chế độ; tham số và Adam moments giữ FP32, không GradScaler, TF32 tắt và không dùng compile. Các phép đo được thiết lập trên RTX 5090 với bốn worker tải dữ liệu và bốn luồng CPU.

Ngân sách 20 epoch được giữ cố định giữa các chế độ. Learning rate của head/scratch và partial/full được đặt khác nhau để phù hợp với mức độ cập nhật backbone. Kết quả vì vậy được phân tích theo từng thiết lập đầy đủ; mức hội tụ còn được đối chiếu qua đường cong train/validation.

3.2 Thiết lập 40 epoch cho Swin-T

Trong lịch 20 epoch, hai lượt Swin-T khởi tạo ngẫu nhiên có độ chính xác trên tập validation 1% ở epoch cuối và cross-entropy huấn luyện gần ln(100). Vì sai số cao ngay trên tập train, điểm thấp cho thấy quá trình tối ưu chưa học được biểu diễn phân lớp trong thiết lập đó. So sánh trực tiếp với bản ImageNet trong điều kiện này phản ánh cả khác biệt về khởi tạo lẫn mức độ học được của cấu hình tối ưu, nên chưa cho biết khoảng cách khi bản scratch được huấn luyện hiệu quả hơn.

Thí nghiệm bổ sung giữ kiến trúc, cách chia tập, tiền xử lý, batch 128 và ba seed. Hai bản cập nhật toàn bộ tham số và chỉ khác nguồn trọng số backbone. Cả hai dùng AdamW với weight decay 10^{-2}, tốc độ học tăng tuyến tính từ 2×10^{-5} đến 2×10^{-4} qua năm epoch warmup, rồi giảm theo cosine đến cuối lịch 40 epoch. Lịch warmup và cosine decay dựa trên cách huấn luyện Swin trong bài báo gốc [5], với ngân sách và tốc độ học điều chỉnh cho CIFAR-100. Thay đổi đồng thời lịch, ngân sách và weight decay giúp kiểm tra cấu hình có học ổn định hơn hay không. Phép so sánh giữa hai lịch không tách riêng đóng góp của từng thay đổi. Vì vậy, mức tăng từ lịch 20 sang 40 epoch không thể quy riêng cho việc tăng gấp đôi số epoch; đối chứng về khởi tạo nằm ở hai bản Swin-T cùng dùng lịch 40 epoch.

3.3 Chọn checkpoint và đánh giá trên tập test

Checkpoint được chọn theo accuracy trên tập validation lớn nhất; nếu bằng nhau, ưu tiên cross-entropy nhỏ hơn, rồi đến epoch sớm hơn. Tập validation được dùng để chọn mô hình trong quá trình huấn luyện. Tập test được đánh giá ở một bước riêng sau khi hoàn tất các lượt huấn luyện. Các cấu hình, learning rate và seed được cố định trước bước này.

Accuracy và macro-F1 đều tính trên 100 lớp. Với mỗi lớp c,

$$F1_c = \frac{2TP_c}{2TP_c + FP_c + FN_c}, \qquad F1_{macro} = \frac{1}{100}\sum_{c=1}^{100} F1_c. \tag{3.3}$$

Với mỗi lớp, TP, FP và FN lần lượt là số dự đoán đúng, số dự đoán nhầm vào lớp và số ảnh của lớp bị bỏ sót. Trường hợp mẫu số bằng 0 có F1 bằng 0. Vì tập test cân bằng theo lớp, accuracy cũng bằng trung bình recall của các lớp; macro-F1 còn phản ánh precision nên giúp nhận ra xu hướng dồn dự đoán vào một số lớp. Confusion matrix, support, precision, recall, F1 theo lớp và từng prediction được lưu để kiểm tra. Gallery lấy tối đa 8 lỗi confidence cao nhất của seed 42.

3.4 Chi phí và môi trường

Training time bao gồm data loading/augmentation và train pass, có CUDA synchronize trước/sau. Epoch time thêm validation. Thời gian dựng mô hình, lưu checkpoint và xuất báo cáo nằm ngoài hai khoảng đo này. Peak GPU memory là peak allocated trong train và validation của mỗi epoch, không phải reserved memory hoặc VRAM toàn hệ thống.

Các phép đo thời gian của cùng cấu hình chỉ được gộp khi thống nhất GPU, phiên bản torch/torchvision, CUDA/cuDNN, số worker, số luồng CPU và chế độ deterministic.

Notebook A1 trình bày từ khảo sát dữ liệu đến huấn luyện và đánh giá. Notebook kèm

cấu hình và kết quả theo từng seed.

Chương 4

Kết quả trong thiết lập 20 epoch

4.1 So sánh các chế độ huấn luyện

Cấu hình	Validation (%)	Test (%)	Macro-F1	Thời gian (s)	Tham số (M)
ResNet18: Từ đầu	63,83 ± 0,51	64,35 ± 0,11	0,6422 ± 0,0012	86,6 ± 5,4	11,228
ResNet18: Chỉ đầu ra	61,89 ± 0,24	60,95 ± 0,29	0,6081 ± 0,0030	80,1 ± 0,2	0,051
ResNet18: Một phần	74,50 ± 0,31	73,96 ± 0,12	0,7396 ± 0,0011	80,2 ± 0,2	8,445
ResNet18: Toàn bộ	79,29 ± 0,10	78,97 ± 0,04	0,7898 ± 0,0006	80,4 ± 0,6	11,228
Swin-T: Từ đầu	2,81 ± 1,40	2,76 ± 1,26	0,0093 ± 0,0069	211,1 ± 1,6	27,596
Swin-T: Chỉ đầu ra	72,45 ± 0,10	71,67 ± 0,09	0,7154 ± 0,0009	86,1 ± 0,5	0,077
Swin-T: Một phần	78,99 ± 0,31	78,25 ± 0,22	0,7818 ± 0,0021	106,9 ± 0,2	14,262
Swin-T: Toàn bộ	86,89 ± 0,02	86,63 ± 0,22	0,8663 ± 0,0020	212,5 ± 0,6	27,596

24/24 lượt huấn luyện hoàn tất; 24/24 lượt đã đánh giá.

Bảng 4.1: Accuracy và macro-F1 của tám cấu hình, trung bình và SD mẫu qua ba seed. Accuracy theo phần trăm, F1 theo thang 0–1.

Kết quả được tổng hợp bằng trung bình và độ lệch chuẩn mẫu qua ba seed.

4.2 Thời gian, bộ nhớ và số tham số

Kiến trúc	Chế độ	Tổng (M)	Học (M)	Giây	MiB
ResNet18	Từ đầu	11,228	11,228	$86,6 \pm 5,4$	$520,1 \pm 2,2$
ResNet18	Chỉ đầu ra	11,228	0,051	$80,1 \pm 0,2$	$251,0 \pm 0,0$
ResNet18	Một phần	11,228	8,445	$80,2 \pm 0,2$	$347,3 \pm 0,0$
ResNet18	Toàn bộ	11,228	11,228	$80,4 \pm 0,6$	$518,9 \pm 0,0$
Swin-T	Từ đầu	27,596	27,596	$211,1 \pm 1,6$	$2451,8 \pm 0,2$
Swin-T	Chỉ đầu ra	27,596	0,077	$86,1 \pm 0,5$	$502,9 \pm 0,0$
Swin-T	Một phần	27,596	14,262	$106,9 \pm 0,2$	$667,7 \pm 0,0$
Swin-T	Toàn bộ	27,596	27,596	$212,5 \pm 0,6$	$2451,9 \pm 0,0$

Bảng 4.2: Tổng tham số và tham số được học theo triệu (M). Thời gian huấn luyện đủ 20 epoch và bộ nhớ cấp phát cực đại là trung bình và độ lệch chuẩn mẫu qua ba seed trên RTX 5090.

4.3 Thảo luận kết quả

4.3.1 Ảnh hưởng của chế độ fine-tuning

ResNet18 head-only đạt 60,95%, thấp hơn 64,35% của bản học từ đầu. Khi các tầng đặc trưng giữ nguyên, bộ phân loại tuyến tính chỉ có thể thay đổi ranh giới trên biểu diễn đã học từ ImageNet. Partial fine-tuning đạt 73,96%, còn full fine-tuning đạt 78,97%. Kết quả cho thấy backbone ImageNet đóng băng chưa phải biểu diễn tốt nhất cho CIFAR-100 trong thiết lập này: cho phép stage cuối thích nghi đã cải thiện rõ so với chỉ học một bộ phân loại tuyến tính. Tuy vậy, bản scratch và các bản pretrained dùng learning rate khác nhau, nên chênh lệch giữa chúng không tách riêng tác động của pretraining.

Swin-T head-only đạt 71,67%, partial fine-tuning đạt 78,25% và full fine-tuning đạt 86,63%. Bản khởi tạo ngẫu nhiên ở lịch 20 epoch chỉ đạt 2,76%. Hai trong ba seed kết thúc ở 1% trên tập validation, với cross-entropy huấn luyện gần ln(100). Điểm thấp xuất hiện trên cả hai tập, phù hợp với việc tối ưu chưa học được biểu diễn hữu ích. Macro-F1 của bản scratch chỉ đạt 0,0093, thấp hơn nhiều so với accuracy 0,0276 trên cùng thang 0–1. Confusion matrix tại checkpoint được chọn cho thấy mô hình chỉ dự đoán 54, 36 và 14 trong số 100 lớp, tương ứng seed 42, 43 và 44. Vì mỗi lớp test có cùng số ảnh, đây là dấu hiệu dự đoán tập trung vào một số lớp, không phải ảnh hưởng của mất cân bằng nhãn. Lịch 40 epoch ở chương sau dùng chung learning rate và cách cập nhật cho hai cách khởi tạo Swin-T.

4.3.2 Chi phí và lỗi phân loại

Với full fine-tuning, Swin-T cao hơn ResNet18 7,66 điểm phần trăm độ chính xác trên tập test. Tính theo trung bình ba seed, Swin-T cần thời gian huấn luyện gấp 2,64 lần và bộ nhớ cấp phát cực đại gấp 4,73 lần. Với Swin-T, head-only hoặc partial fine-tuning giảm thời gian và bộ nhớ so với cập nhật toàn bộ, nhưng độ chính xác cũng thấp hơn. Với ResNet18, thời gian của ba chế độ pretrained gần nhau trong lần đo này, trong khi bộ nhớ giảm rõ khi đóng băng nhiều tầng hơn. Do training time còn gồm tải dữ liệu và forward qua toàn bộ backbone, giảm số tham số trainable không nhất thiết làm tổng thời gian giảm theo cùng tỷ lệ.

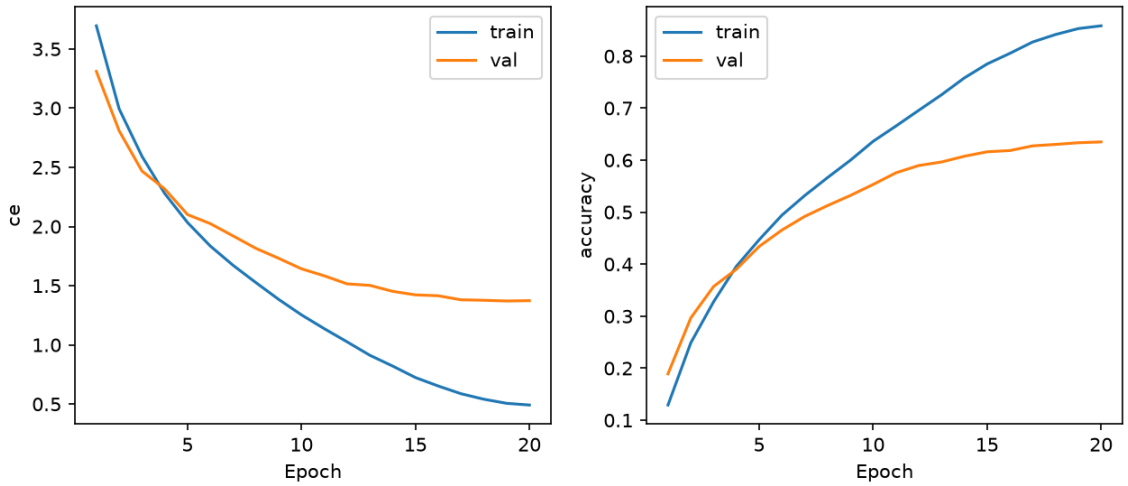
Partial fine-tuning cũng không đồng nghĩa với chỉ cập nhật một phần nhỏ tham số: stage cuối và head của ResNet18 chiếm 8,445 trên tổng 11,228 triệu tham số; với Swin-T, phần được cập nhật là 14,262 trên 27,596 triệu. Ở Swin-T, chuyển từ partial sang full tăng accuracy từ 78,25% lên 86,63%, nhưng thời gian tăng từ 106,9 lên 212,5 giây và peak allocated memory từ 667,7 lên 2451,9 MiB. Đây là sự đánh đổi cụ thể giữa mức thích nghi của backbone và chi phí trong lịch 20 epoch.

Ở epoch 20, ResNet18 full fine-tuning đạt khoảng 99,1% trên tập train và 79,2% trên tập validation; Swin-T tương ứng đạt 98,7% và 86,7%. Khoảng cách train/validation lớn phù

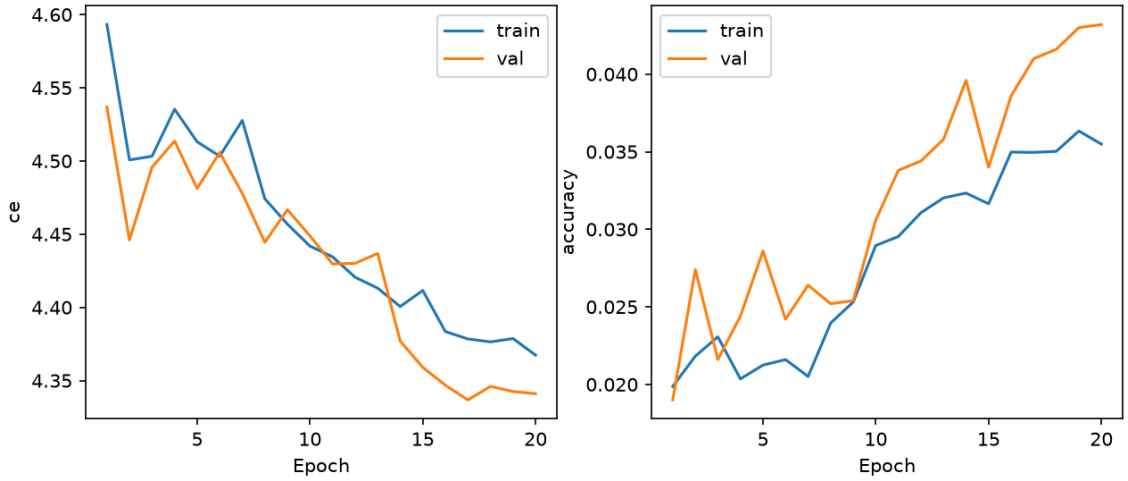
hợp với hiện tượng overfitting. Tuy nhiên, chỉ số train được tích lũy trong lúc cập nhật trọng số trên ảnh augmentation, còn validation được tính ở eval với trọng số cuối epoch; hiệu hai số không phải phép đo trên cùng điều kiện. Checkpoint dùng để đánh giá được chọn theo độ chính xác trên tập validation. Trong cả hai confusion matrix của seed 42, lớp cây sồi thường bị gán thành cây phong. Các ví dụ sai có hình dáng và kết cấu tương tự ở độ phân giải gốc 32×32. Chúng gợi ý một giới hạn về thông tin thị giác, nhưng chưa đủ để quy mọi lỗi cho độ phân giải hoặc một thành phần kiến trúc cụ thể.

4.4 Đường cong và lỗi phân loại

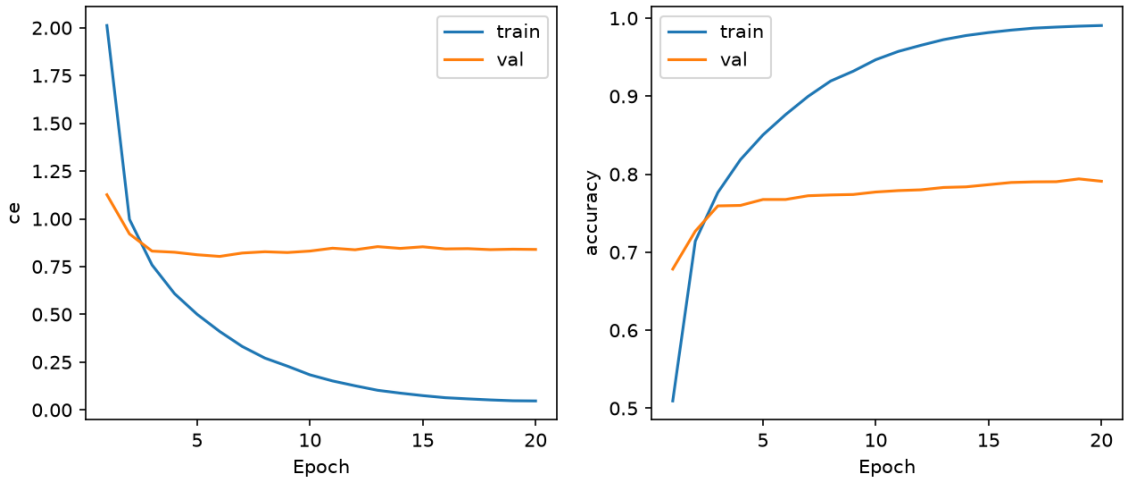
Các hình dùng seed 42 đã định trước, không chọn seed theo kết quả test. Confusion matrix dùng chỉ số lớp 0–99; danh sách tên lớp và số đếm đầy đủ nằm trong các tệp CSV kèm báo cáo.



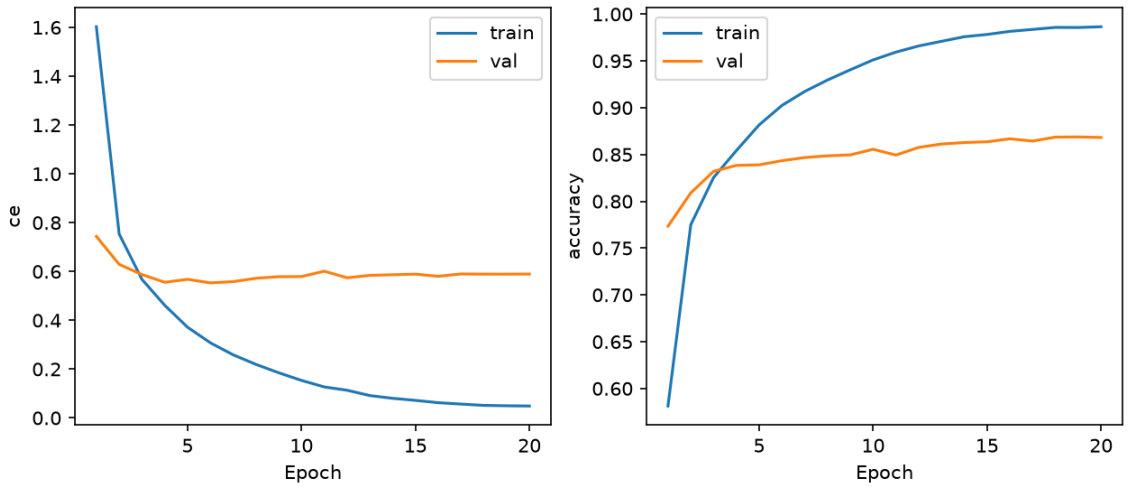
Hình 4.1: ResNet18 scratch: train/val CE và accuracy ở seed 42.



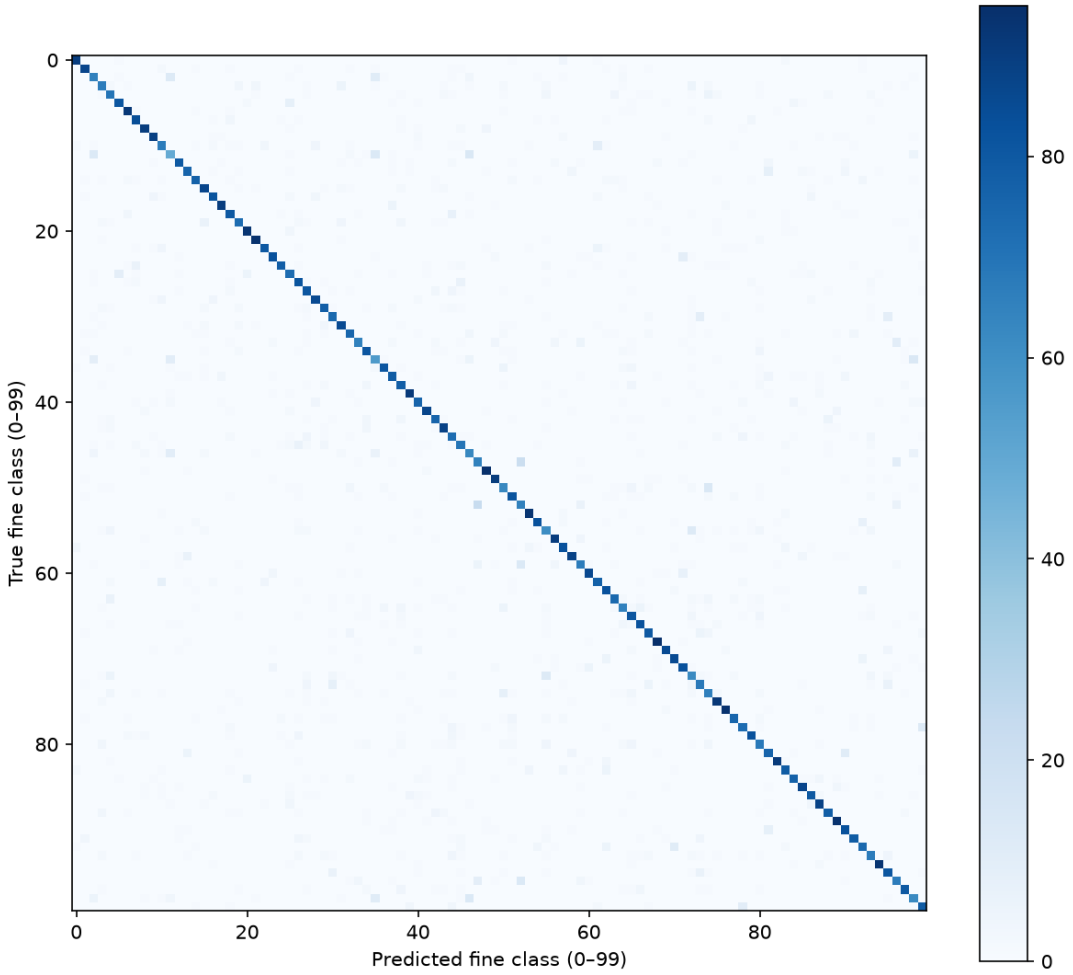
Hình 4.2: Swin-T scratch: train/val CE và accuracy ở seed 42.



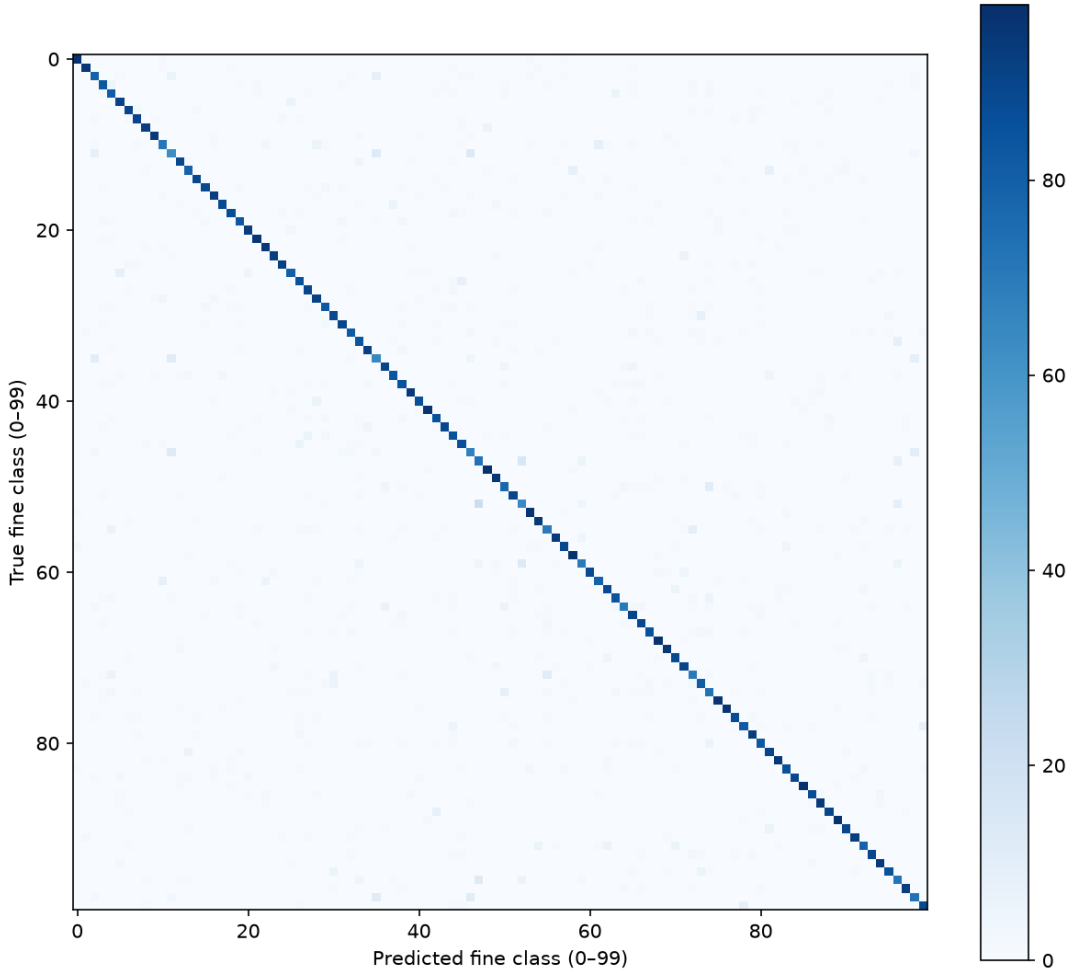
Hình 4.3: ResNet18 pretrained full: đường cong ở seed 42.



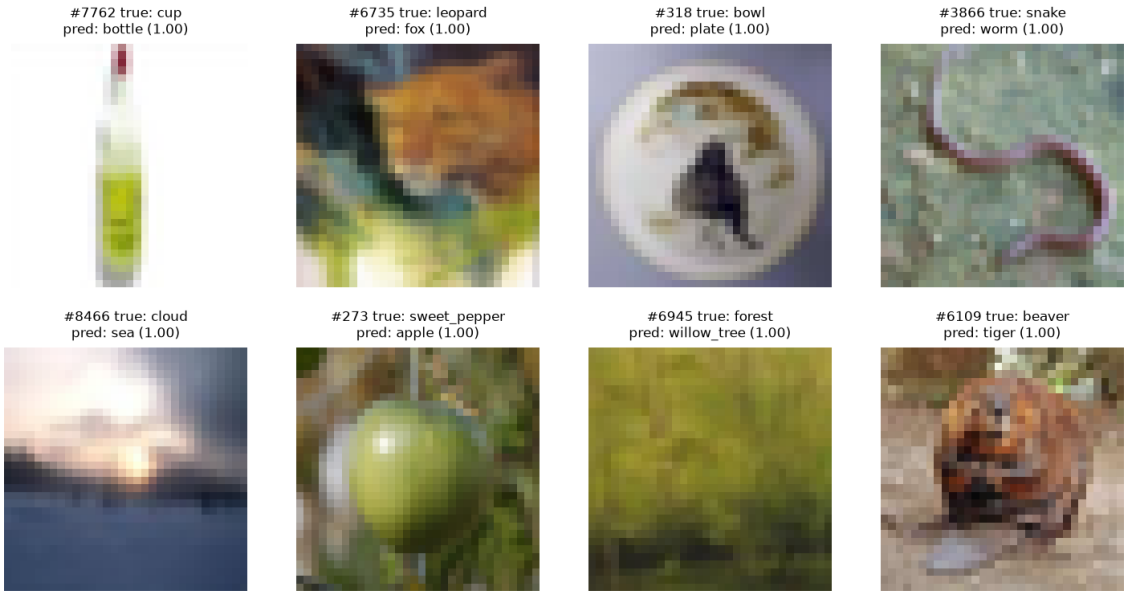
Hình 4.4: Swin-T pretrained full: đường cong ở seed 42.



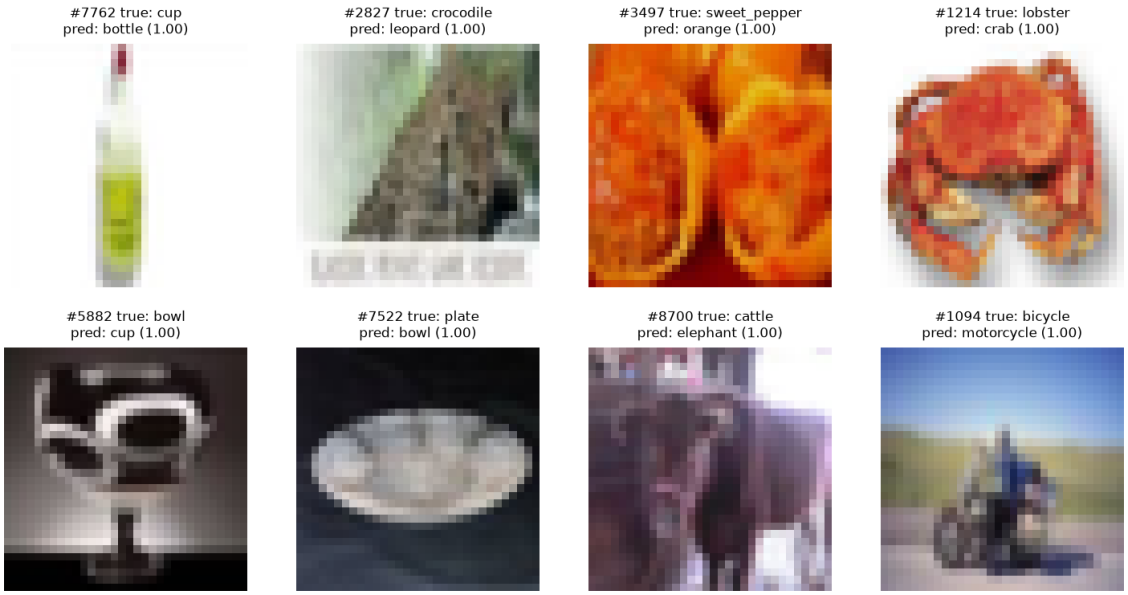
Hình 4.5: Confusion matrix test của ResNet18 full ở seed 42; hàng là nhãn thực tế.



Hình 4.6: Confusion matrix test của Swin-T full ở seed 42.



Hình 4.7: Các dự đoán sai có confidence cao của ResNet18 full ở seed 42, hiển thị ảnh gốc 32×32.



Hình 4.8: Các dự đoán sai có confidence cao của Swin-T full ở seed 42.

Chương 5

Kết quả đối chứng khởi tạo Swin-T

Cấu hình	Validation (%)	Test (%)	Macro-F1	Thời gian (s)	Tham số (M)
Swin-T: Từ đầu	59,89 ± 0,48	60,30 ± 0,05	0,6021 ± 0,0006	425,3 ± 0,9	27,596
Swin-T: Toàn bộ	86,33 ± 0,19	86,39 ± 0,34	0,8637 ± 0,0034	426,3 ± 0,3	27,596

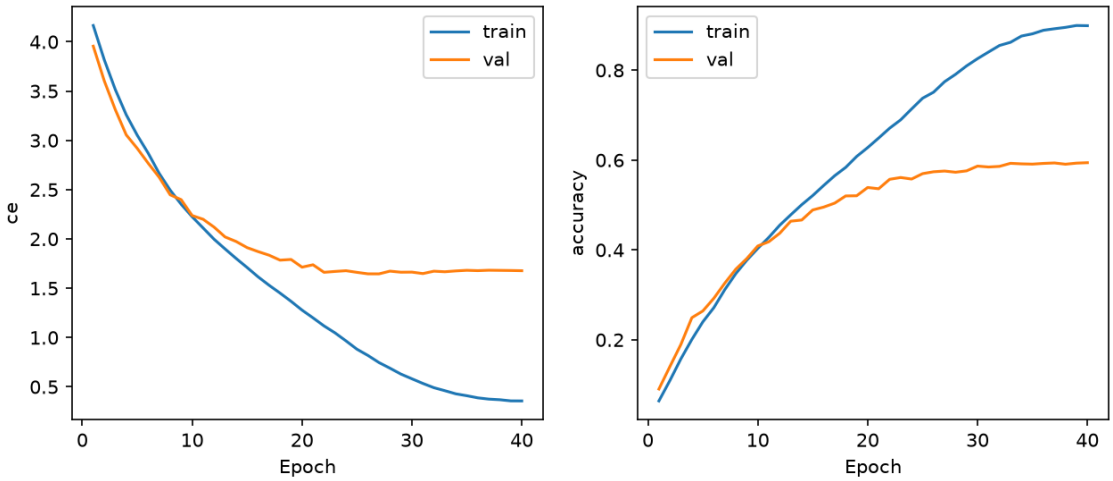
6/6 lượt huấn luyện hoàn tất; 6/6 lượt đã đánh giá.

Bảng 5.1: Swin-T dưới cùng lịch 40 epoch, trung bình và độ lệch chuẩn mẫu qua ba seed.

Swin-T khởi tạo ngẫu nhiên đạt 60,30% trên tập test. Checkpoint được chọn ở các epoch 40, 38 và 38, tương ứng với seed 42, 43 và 44. Đường cong trên tập validation tăng trong phần lớn lịch học, cho thấy cấu hình khởi tạo ngẫu nhiên đã học được biểu diễn phân lớp. Ở cuối lịch, độ chính xác huấn luyện nằm trong khoảng 89,7–90,0%, trong khi độ chính xác trên tập validation đạt 59,4–60,2%, cho thấy khoảng cách khái quát hóa còn lớn.

Bản khởi tạo ImageNet đạt 86,39%. Chênh lệch theo cặp cùng seed là $26{,}08 \pm 0{,}30$ điểm phần trăm. Hai cấu hình dùng cùng lịch và cập nhật cùng số tham số, nên khoảng cách này mô tả lợi ích của khởi tạo từ trọng số ImageNet trong điều kiện đã khảo sát. Checkpoint của bản ngẫu nhiên thường được chọn muộn trong lịch, vì vậy cần thận trọng khi suy rộng kết quả sang ngân sách huấn luyện dài hơn.

Bản ImageNet đạt 86,39% trong lịch 40 epoch, so với 86,63% trong lịch 20 epoch. Như vậy, cấu hình bổ sung giúp bản scratch học được nhưng không cho thấy cải thiện accuracy đồng thời ở bản pretrained. Do learning rate, warmup và weight decay cùng thay đổi, kết quả này không xác định thành phần nào của lịch mới quan trọng nhất hoặc liệu chỉ kéo dài lịch cũ có đạt kết quả tương tự.



Hình 5.1: Đường cong học của Swin-T khởi tạo ngẫu nhiên trong lịch 40 epoch, seed 42.

Chương 6

Kết luận và giới hạn

6.1 Kết luận

Trong thiết lập 20 epoch, partial fine-tuning và full fine-tuning cho accuracy cao hơn head-only ở cả ResNet18 và Swin-T. Với full fine-tuning, Swin-T đạt độ chính xác cao hơn ResNet18 với chi phí huấn luyện và bộ nhớ lớn hơn. Đối chứng ở Bảng 5.1 cho thấy cấu hình Swin-T khởi tạo ngẫu nhiên học được khi dùng lịch 40 epoch. Khoảng cách với bản ImageNet cần được đọc trong cùng lịch và trên cùng cách chia dữ liệu; kết quả không xác định accuracy tối đa của Swin-T scratch khi được tối ưu với ngân sách dài hơn.

6.2 Giới hạn

Ảnh gốc 32×32 và đầu vào 96×96 khác với kích thước phổ biến 224×224 của các bản pretrained. Thực nghiệm khảo sát hai kiến trúc trên CIFAR-100. Đối chứng bổ sung dành riêng cho Swin-T, nên không dùng để xếp hạng hai kiến trúc dưới cùng lịch 40 epoch. Hai họ cũng khác số tham số và quá trình pretraining trên ImageNet. Ba seed mô tả biến thiên giữa các lượt khởi tạo, với cùng phần cứng và thiết lập workers. Tình trạng license của dữ liệu vẫn là chưa rõ.

6.2.1 Ảnh trùng giữa các split

Đối chiếu toàn bộ ảnh theo giá trị pixel phát hiện hai ảnh validation và mười ảnh test trùng với ảnh trong tập train. Các bảng sử dụng đủ 10.000 ảnh test chính thức và giữ nguyên checkpoint đã chọn. Do mười ảnh trong số này đã xuất hiện khi huấn luyện, tập test có một phần nội dung trùng với tập train.

Tính lại trên 9.990 dự đoán sau khi loại mười ảnh trùng cho độ chính xác trung bình 79,009% với ResNet18 và 86,677% với Swin-T ở chế độ full fine-tuning. Thứ hạng của hai cấu hình giữ nguyên. Phép kiểm tra độ nhạy dùng lại các dự đoán đã lưu. Hai ảnh validation trùng vẫn có thể ảnh hưởng việc chọn checkpoint, và phạm vi đối chiếu chỉ bao gồm các ảnh trùng pixel chính xác.

Phạm vi hỗ trợ của AI được trình bày trong `AI_USE_REPORT.md`.

Tài liệu tham khảo

[1] Lê Thành Sách, Nguyễn Quốc Minh. *Bài tập lớn A1: CNN vs Transformer trên tập ảnh lớn*. CO5085, học kỳ 261.

[2] A. Krizhevsky. *Learning Multiple Layers of Features from Tiny Images*. 2009. Trang dataset: `https://www.cs.toronto.edu/~kriz/cifar.html`.

[3] uoft-cs. *CIFAR100 dataset card*; license: unknown. `https://huggingface.co/datasets/uoft-cs/cifar100`.

[4] K. He và cộng sự. *Deep Residual Learning for Image Recognition*. CVPR 2016. `https://arxiv.org/abs/1512.03385`.

[5] Z. Liu và cộng sự. *Swin Transformer: Hierarchical Vision Transformer using Shifted Windows*. ICCV 2021. `https://arxiv.org/abs/2103.14030`.

[6] Torchvision. ResNet18 và Swin-T model API; sử dụng weight enum IMAGENET1K_V1. `https://docs.pytorch.org/vision/stable/models.html`.