ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO BÀI TẬP LỚN A2

CO5085 · Học sâu và ứng dụng trong thị giác máy tính

Học kỳ 261 · Năm học 2026–2027

PIDNet: phân tích và áp dụng phân đoạn ngữ nghĩa trên CamVid

Học viên

Huỳnh Thành Đạt	2570161
Giảng viên	Lê Thành Sách
	Nguyễn Quốc Minh

Thành phố Hồ Chí Minh, tháng 11 năm 2026

Tóm tắt

Báo cáo phân tích *PIDNet: A Real-Time Semantic Segmentation Network Inspired by PID Controllers* của Jiacong Xu, Zixiang Xiong và Shankar P. Bhattacharyya, công bố tại IEEE/CVF CVPR 2023 [1]. Bài báo giải quyết khó khăn khi kết hợp ngữ cảnh rộng với chi tiết ở biên vật thể. PIDNet chia công việc cho ba nhánh: P giữ chi tiết, I học ngữ cảnh và D tìm biên. Báo cáo giải thích cơ sở PID, cách Pag, PAPPM và Bag/Light-Bag phối hợp, cùng vai trò của các thành phần loss qua thí nghiệm của tác giả.

Phần thực nghiệm áp dụng PIDNet-S lên CamVid ở độ phân giải 960×720, với 367 ảnh train, 101 ảnh validation và 233 ảnh test. Hai biến thể giữ nguyên kiến trúc: một bản dùng đủ loss của tác giả, một bản bỏ riêng boundary-awareness semantic loss (BAS-Loss). Mạng được khởi tạo từ trọng số Cityscapes và fine-tune toàn bộ trong 200 epoch với mỗi seed 42, 43 và 44. Bản đủ loss đạt $79{,}03 \pm 0{,}44\%$ mIoU, còn bản bỏ BAS-Loss đạt $78{,}38 \pm 0{,}47\%$. Chênh lệch ghép theo seed là $0{,}66 \pm 0{,}13$ điểm phần trăm và dương ở cả ba cặp. Mức tăng tập trung ở các lớp nhỏ như biển báo, cột và người đi xe đạp. Kết quả cho thấy BAS-Loss giúp cải thiện mIoU trong thiết lập fine-tuning này.

Tổng quan báo cáo

Bài toán	Phân đoạn ngữ nghĩa cảnh đường phố trên CamVid, gồm 11 lớp và vùng bỏ qua.
Bài báo	PIDNet của Xu, Xiong và Bhattacharyya, IEEE/CVF CVPR 2023 [1].
Mô hình	PIDNet-S đầy đủ ba nhánh P/I/D, Pag, PAPPM và Light-Bag.
Đối chứng	PIDNet-S đủ loss và PIDNet-S bỏ BAS-Loss; giữ nguyên kiến trúc và giám sát biên.
Thiết lập	367 ảnh train, 101 validation, 233 test; ba seed, 200 epoch; khởi tạo Cityscapes.
Kết quả	Bản đủ loss đạt $79{,}03 \pm 0{,}44\%$ mIoU, hơn bản bỏ BAS-Loss $0{,}66 \pm 0{,}13$ điểm phần trăm.

Mục lục

Tóm tắt **i**

Tổng quan báo cáo **ii**

1 Giới thiệu **1**

1.1 Bài báo và vấn đề nghiên cứu 1

1.2 Mục tiêu thực nghiệm 1

2 Phân tích PIDNet **2**

2.1 Từ mạng hai nhánh đến vấn đề overshoot 2

2.2 Cơ sở PID và ý nghĩa của nhánh D 2

2.2.1 PID truyền thống 2

2.2.2 Từ phép tương tự PID đến CNN 4

2.3 Kiến trúc ba nhánh và trao đổi thông tin 4

2.3.1 Residual block và luồng đặc trưng trong PIDNet-S 4

2.3.2 Pag: tiếp nhận ngữ cảnh có chọn lọc 6

2.3.3 PAPPM: tổng hợp ngữ cảnh với độ trễ thấp 6

2.3.4 Bag và Light-Bag: dùng biên để điều tiết fusion 7

2.4 Boundary supervision và hàm mục tiêu 8

2.5 Thí nghiệm và mức đóng góp của paper 9

2.5.1 Giao thức và kết quả chính 9

2.5.2 Đóng góp từng thành phần qua ablation 9

2.6 Liên hệ với thiết kế thực nghiệm A2 10

3 Dữ liệu và thiết lập thực nghiệm **11**

3.1 Nguồn dữ liệu và nhãn 11

3.2 Chia tập và phân tích khám phá 11

3.3 Mô hình và hai biến thể đối chứng 13

3.4 Tiền xử lý dữ liệu 13

3.5 Hàm mất mát 13
3.6 Huấn luyện và chọn checkpoint 14
3.7 Đánh giá phân đoạn 14

4 Kết quả thực nghiệm **15**
4.1 Kết quả tổng hợp và từng lượt chạy 15
4.2 Loss train, mIoU validation và lựa chọn checkpoint 16
4.3 Ảnh hưởng của BAS-Loss theo từng lớp 16
4.3.1 Nhầm lẫn giữa các lớp và ví dụ dự đoán 18
4.4 Đối chiếu với kết quả công bố 19
4.5 Suy luận trên video 20

5 Kết luận và giới hạn **22**

Danh sách hình vẽ

2.1 Phép tương tự giữa PID và mạng ba nhánh; phần dưới minh họa độ nhạy với ngữ cảnh và dự đoán của từng luồng DDRNet. Trích Hình 3 của Xu và cộng sự, CVPR 2023 [1]. 3

2.2 Kiến trúc PIDNet. P giữ feature map độ phân giải cao; I tổng hợp ngữ cảnh; D học thông tin biên. S-Head và B-Head là các đầu ngữ nghĩa và biên. Các đường nét đứt phục vụ loss khi train. Trích Hình 4 của Xu và cộng sự [1]. 5

2.3 Pag dùng tương đồng giữa đặc trưng P và I để điều chỉnh lateral fusion. Trích Hình 5 của Xu và cộng sự [1]. 7

2.4 Bag (trái) và Light-Bag (phải) kết hợp P và I bằng tín hiệu D. Các ô màu minh họa vùng bên trong vật thể và vùng biên. Trích Hình 7 của Xu và cộng sự [1]. 8

3.1 Tỷ lệ pixel và số ảnh theo lớp ở tập train. 12

3.2 Ảnh, mặt nạ và ví dụ tăng cường dữ liệu. 12

4.1 Loss train và mIoU validation của sáu lượt chạy. 16

4.2 IoU test từng lớp qua ba seed. 17

4.3 Confusion matrix test của hai checkpoint seed 42. 18

4.4 Ba ảnh test và dự đoán của hai biến thể ở seed 42. 19

4.5 Khung hình CamVid 0005VD và kết quả phân đoạn. 21

Danh sách bảng

2.1 Luồng đặc trưng của PIDNet-S với $C = 32$, $m = 2$, $n = 3$ và đầu phân đoạn 11 lớp. Tỷ lệ không gian là mức giảm danh nghĩa so với ảnh đầu vào; kích thước các tầng sâu còn phụ thuộc padding và làm tròn. Các kết nối Pag và I–D được minh họa ở Hình 2.2. 5

2.2 Kết quả công bố trong Bảng 5–7 của PIDNet [1]. CamVid dùng Cityscapes pretraining. PASCAL Context dùng multi-scale và flip inference. 9

3.1 Ánh xạ màu sang ID lớp theo PIDNet và phân bố đo trên toàn bộ 367 ảnh train. Tỷ lệ dùng tổng số pixel có nhãn hợp lệ làm mẫu số. 11

3.2 Thiết lập train chung cho PIDNet-S đủ loss và PIDNet-S bỏ BAS-Loss. . 14

4.1 Trung bình và độ lệch chuẩn mẫu của ba seed trên 233 ảnh test. Thời gian train tính trên RTX 5090. 15

4.2 Kết quả của sáu lượt train 200 epoch. Các chỉ số phân đoạn tính bằng phần trăm. Thời gian train gồm chuẩn bị batch và cập nhật trọng số; thời gian tổng còn gồm validation và ghi checkpoint. 15

4.3 Chênh lệch mIoU của PIDNet-S đủ loss trừ PIDNet-S bỏ BAS-Loss ở từng cặp seed. Đpt là điểm phần trăm. 16

4.4 IoU từng lớp: trung bình và SD qua ba seed. Chênh lệch được ghép theo seed trước khi tổng hợp. 17

4.5 Đối chiếu trên CamVid test 233 ảnh ở 960×720. mIoU của hai biến thể A2 tổng hợp ba seed; FPS của bản đủ loss chỉ đo checkpoint seed 42. FPS đo lại là trung bình và SD của năm lượt, mỗi lượt 200 forward sau 20 warm-up, batch 1, FP32, tắt auxiliary heads. Không có phép đo FPS riêng cho bản bỏ BAS-Loss. Bài báo dùng train+validation và điều kiện đo riêng [1]. 19

4.6 Phép chạy trên toàn bộ 869 khung hình CamVid 0005VD bằng checkpoint PIDNet-S đủ loss, seed 42, ở 960×720 trên RTX 5090, FP32. Độ trễ từ ảnh đến mask gồm tiền xử lý, suy luận và tạo mask; toàn luồng còn gồm đọc, vẽ và ghi video. 20

Chương 1

Giới thiệu

1.1 Bài báo và vấn đề nghiên cứu

Báo cáo phân tích *PIDNet: A Real-Time Semantic Segmentation Network Inspired by PID Controllers* của Jiacong Xu, Zixiang Xiong và Shankar P. Bhattacharyya, công bố tại *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) 2023*, tr. 19529–19539 [1]. Bài báo có bản PDF tại CVF, bản toàn văn trên arXiv và mã nguồn chính thức.

Trong semantic segmentation, mỗi pixel được gán một lớp, chẳng hạn Road, Car hoặc Pedestrian. Để nhận ra lớp, mạng cần nhìn cả vùng xung quanh; để vẽ đúng đường viền, mạng lại cần giữ chi tiết tại từng vị trí. Hai yêu cầu dễ xung đột ở vật thể nhỏ. Một cột bên đường có thể hiện rõ trong ảnh nhưng biến mất sau nhiều lần downsampling. Giữ mọi tầng ở độ phân giải cao giúp giảm mất chi tiết, song tốn thời gian và bộ nhớ.

PIDNet giải quyết bài toán bằng ba nhánh. P giữ thông tin vị trí, I học ngữ cảnh trên vùng rộng, còn D học nơi nhãn lớp thay đổi. Khi ghép đặc trưng bằng fusion, D giúp tăng vai trò của P ở biên và của I trong vùng đồng nhất. Các mô-đun Pag, PAPPM và Bag được thiết kế để thực hiện cách phối hợp này với tốc độ phù hợp cho xử lý thời gian thực.

1.2 Mục tiêu thực nghiệm

Phần thực nghiệm sử dụng PIDNet-S trên CamVid. Kiến trúc giữ ba nhánh P/I/D, Pag, PAPPM, Light-Bag và các đầu dự đoán như trong mô hình gốc. Thí nghiệm so sánh **PIDNet-S đủ loss** (FULL) với **PIDNet-S bỏ BAS-Loss** (NO_BAS). Bản thứ nhất dùng đầy đủ bốn thành phần loss của tác giả; bản thứ hai bỏ riêng loss bổ sung để phân loại tại vùng biên dự đoán. Hai bản giữ cùng kiến trúc, trọng số khởi tạo và thiết lập train.

BAS-Loss chọn những pixel có điểm biên cao để tính thêm lỗi phân loại ngữ nghĩa. Giả thuyết là giám sát bổ sung này giúp mô hình phân biệt hai phía của đường biên tốt hơn, sau khi mạng đã học biên và dùng biên cho fusion. Đối chứng theo cùng seed, IoU từng lớp và ảnh dự đoán được dùng để đánh giá giả thuyết.

Chương 2

Phân tích PIDNet

2.1 Từ mạng hai nhánh đến vấn đề overshoot

Trong mạng encoder–decoder, encoder giảm kích thước feature map để mỗi vị trí nhìn được một vùng ảnh rộng hơn. Vùng ảnh đó được gọi là receptive field. Nhờ có ngữ cảnh rộng, mạng dễ nhận ra một vùng là mặt đường hay tòa nhà, nhưng có thể làm mất chi tiết của cột mảnh hoặc người ở xa. Upsampling chỉ tăng kích thước feature map; những chi tiết đã mất vẫn cần được bổ sung từ các tầng có độ phân giải cao. Dilated convolution và mạng nhiều độ phân giải là hai cách giữ thêm chi tiết, với chi phí tính toán khác nhau.

BiSeNet [2] giải quyết bài toán bằng hai luồng: một luồng giữ chi tiết, một luồng học ngữ cảnh. DDRNet [3] cũng duy trì hai độ phân giải và cho hai luồng trao đổi thông tin nhiều lần. Khi ghép chúng bằng fusion, ngữ cảnh vẫn có thể lấn át chi tiết ở biên. Chẳng hạn, một cột nhỏ nằm giữa vùng đường và tòa nhà có thể bị gán thành nền vì phần lớn receptive field chứa pixel nền, dù luồng chi tiết còn nhận ra đường viền cột.

Bài báo gọi sự lan nhãn qua biên này là *overshoot*, lấy ý tưởng từ đáp ứng vượt mức trong điều khiển. Vấn đề cần xử lý là quyết định nơi nào nên dựa nhiều vào ngữ cảnh, nơi nào cần giữ chi tiết. PIDNet bổ sung nhánh D để học vị trí biên, rồi dùng thông tin đó khi ghép hai luồng còn lại.

2.2 Cơ sở PID và ý nghĩa của nhánh D

2.2.1 PID truyền thống

Với sai số $e(t) = r(t) - y(t)$ giữa giá trị đặt và đầu ra hệ thống, dạng PID liên tục lý tưởng là

$$u(t) = K_P e(t) + K_I \int_0^t e(\tau)\, d\tau + K_D \frac{de(t)}{dt}. \tag{2.1}$$

Trong công thức trên, $u(t)$ là tín hiệu điều khiển; K_P, K_I và K_D là hệ số của ba thành phần. P phản ứng với sai số hiện tại, I cộng dồn sai số theo thời gian, còn D phản ứng với tốc độ thay đổi của sai số. Khi lấy mẫu theo từng bước và gộp chu kỳ lấy mẫu vào

các hệ số, công thức trở thành

$$u[n] = k_p e[n] + k_i \sum_{j=0}^{n} e[j] + k_d\big(e[n] - e[n-1]\big). \tag{2.2}$$

Ở đây, n là bước thời gian và k_p, k_i, k_d là các hệ số rời rạc. Khi sai số đang giảm, hiệu $e[n] - e[n-1]$ có thể âm. Hạng D khi đó bù bớt tác dụng của hạng I đang còn tích lũy nhiều sai số, giúp giảm overshoot. Công thức (1) của bài báo trình bày hai hạng P và I; Hình 3 bổ sung vai trò của D như trong biểu thức (2.2).

Có thể nhìn ba thành phần này dưới góc độ lọc tín hiệu. Với điều kiện đầu bằng 0, hàm truyền trong miền z và đáp ứng theo tần số là

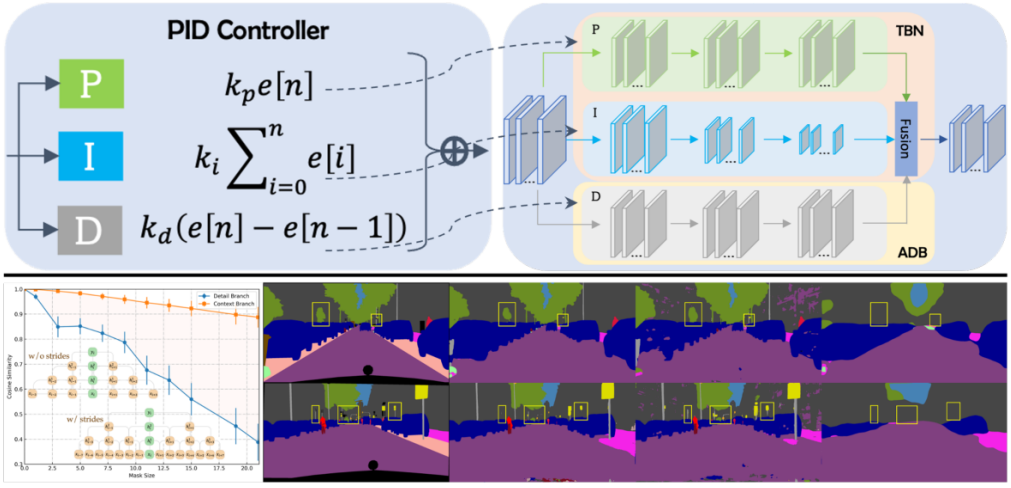
$$C(z) = k_p + \frac{k_i}{1 - z^{-1}} + k_d(1 - z^{-1}), \tag{2.3}$$

$$C(e^{j\omega}) = k_p + \frac{k_i}{1 - e^{-j\omega}} + k_d(1 - e^{-j\omega}). \tag{2.4}$$

Trong đó, z là biến của phép biến đổi Z; thay $z = e^{j\omega}$ cho đáp ứng tại tần số góc ω, với $j^2 = -1$. Biểu thức (2.4) tương ứng công thức (4) của bài báo. Độ lớn đáp ứng của riêng I và D, bỏ qua hệ số khuếch đại, là

$$|H_I(e^{j\omega})| = \frac{1}{2|\sin(\omega/2)|}, \qquad |H_D(e^{j\omega})| = 2|\sin(\omega/2)|. \tag{2.5}$$

Với $0 < \omega \le \pi$, I có độ khuếch đại lớn ở tần số thấp, còn D nhấn mạnh tần số cao; P giữ độ khuếch đại không đổi. Trên ảnh, vùng mặt đường có màu và nhãn thay đổi chậm là ví dụ về thành phần tần số thấp. Mép giữa người đi bộ và nền thay đổi nhanh hơn, nên chứa nhiều thành phần tần số cao. Tác giả dựa vào đặc điểm này để gắn I với ngữ cảnh và D với biên. Tần số ở đây mô tả sự thay đổi theo vị trí trong ảnh.



Hình 2.1: Phép tương tự giữa PID và mạng ba nhánh; phần dưới minh họa độ nhạy với ngữ cảnh và dự đoán của từng luồng DDRNet. Trích Hình 3 của Xu và cộng sự, CVPR 2023 [1].

2.2.2 Từ phép tương tự PID đến CNN

Để giải thích sự khác nhau giữa detail và context, bài báo xét hai CNN một chiều gồm ba tầng và bỏ BatchNorm, ReLU để phép tính dễ theo dõi. Các công thức (2)–(3) được viết gọn như sau:

$$O_{\text{detail}}[i] = \sum_{r=-3}^{3} K^D_{i+r} x[i+r], \tag{2.6}$$

$$O_{\text{context}}[i] = \sum_{r=-7}^{7} K^C_{i+r} x[i+r]. \tag{2.7}$$

Ở đây, $x[i+r]$ là giá trị đầu vào cách vị trí i một khoảng r; các hệ số K được tạo từ trọng số convolution của ba tầng. Luồng detail chỉ dùng bảy vị trí từ $i-3$ đến $i+3$, còn context dùng 15 vị trí từ $i-7$ đến $i+7$. Context vì vậy tổng hợp thông tin trên vùng rộng hơn, tương tự vai trò cộng dồn của I; detail giữ thay đổi cục bộ tốt hơn, gần với P. Chữ D trong K^D viết tắt cho *detail*, khác với tên nhánh D của PIDNet.

Phép tương tự này là cơ sở thiết kế mạng. CNN thực tế còn có trọng số học được, BatchNorm, ReLU và residual connection, nên đáp ứng phức tạp hơn các bộ lọc trên. PIDNet dùng ba nhánh để học chi tiết, ngữ cảnh và biên trong ảnh; mạng không tích lũy sai số theo thời gian như một bộ điều khiển PID.

2.3 Kiến trúc ba nhánh và trao đổi thông tin

2.3.1 Residual block và luồng đặc trưng trong PIDNet-S

PIDNet-S được ghép từ các residual block [1, 6]. BasicBlock dùng hai convolution 3×3. Bottleneck dùng chuỗi 1×1, 3×3, 1×1, với số kênh đầu ra gấp đôi số kênh bên trong. Trong mỗi block, shortcut đưa đầu vào đến phép cộng với kết quả của nhánh convolution. Mạng nhờ đó học phần thay đổi cần thêm vào đặc trưng đã có. Với block có ReLU sau phép cộng,

$$\mathbf{h}_{k+1} = \text{ReLU}(F_k(\mathbf{h}_k) + S_k(\mathbf{h}_k)) \,. \tag{2.8}$$

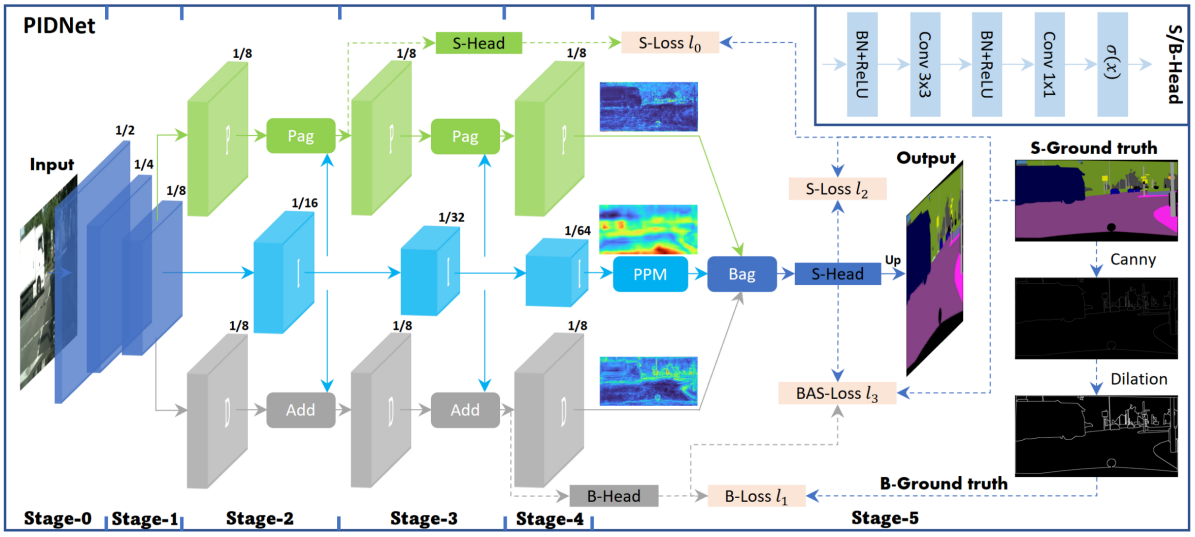
Trong đó, $\mathbf{h}_k$ là đầu vào block thứ k, F_k là nhánh convolution, còn S_k là shortcut. Khi kích thước không đổi, $S_k(\mathbf{h}_k) = \mathbf{h}_k$. Khi đổi số kênh hoặc stride, shortcut dùng convolution 1×1 và BatchNorm để hai vế có cùng kích thước trước khi cộng. Một số block bỏ ReLU sau phép cộng.

Hai convolution đầu và hai tầng residual tạo đặc trưng dùng chung, rồi mạng tách thành P, I và D như Bảng 2.1. Các block tiếp theo xử lý đặc trưng trong từng nhánh; Pag và các kết nối I–D giúp chúng trao đổi thông tin. Trước Light-Bag, P và D đều có 128 kênh trên lưới bằng 1/8 ảnh đầu vào. PAPPM đưa I về 128 kênh, rồi upsampling đến cùng

lưới để fusion. Đầu ngữ nghĩa sau đó xuất 11 logit tại mỗi vị trí và nội suy về kích thước ảnh CamVid.

Luồng	Các tầng chính	Tỷ lệ không gian	Số kênh
Dùng chung	Hai convolution 3×3; hai BasicBlock	1/4	32
Dùng chung	Hai BasicBlock, block đầu stride 2	1/8	64
P	Hai tầng, mỗi tầng hai BasicBlock; một Bottleneck	1/8	128
I	Hai tầng, mỗi tầng ba BasicBlock; hai Bottleneck	$1/16 \to 1/32 \to 1/64$	$128 \to 256 \to 512$
I	PAPPM và upsampling	1/8	128
D	Một BasicBlock; hai Bottleneck	1/8	$32 \to 64 \to 128$
Fusion	Light-Bag	1/8	128
Đầu ra	Đầu ngữ nghĩa; nội suy về ảnh gốc	$1/8 \to 1$	11

Bảng 2.1: Luồng đặc trưng của PIDNet-S với $C = 32$, $m = 2$, $n = 3$ và đầu phân đoạn 11 lớp. Tỷ lệ không gian là mức giảm danh nghĩa so với ảnh đầu vào; kích thước các tầng sâu còn phụ thuộc padding và làm tròn. Các kết nối Pag và I–D được minh họa ở Hình 2.2.



Hình 2.2: Kiến trúc PIDNet. P giữ feature map độ phân giải cao; I tổng hợp ngữ cảnh; D học thông tin biên. S-Head và B-Head là các đầu ngữ nghĩa và biên. Các đường nét đứt phục vụ loss khi train. Trích Hình 4 của Xu và cộng sự [1].

Hình 2.2 cho thấy cách ba nhánh chia việc:

- **P (proportional):** giữ feature map ở khoảng 1/8 kích thước ảnh. Nhánh này theo dõi vị trí và đường viền, chẳng hạn hình dạng người đi bộ hay cột bên đường. Số tầng vừa phải giúp giảm chi phí tính toán trên lưới lớn.
- **I (integral):** giảm dần độ phân giải qua các mức 1/16, 1/32 và 1/64. Nhánh này dùng nhiều tầng hơn để nhận ra lớp từ ngữ cảnh rộng, chẳng hạn phân biệt mặt đường với vỉa hè.

- **D (derivative):** học vị trí chuyển từ lớp này sang lớp khác. Nhãn biên tạo từ mặt nạ phân đoạn giúp D tập trung vào đường phân cách ngữ nghĩa.

I gửi ngữ cảnh sang P qua Pag và sang D qua phép cộng. Ví dụ, một cạnh mạnh có thể là mép ô tô hoặc chỉ là bóng đổ trên đường; ngữ cảnh giúp P và D phân biệt hai trường hợp này. Ở cuối mạng, Bag dùng đặc trưng D để quyết định mức đóng góp của P và I tại từng vị trí. Nhờ vậy, vùng bên trong vật thể có thể dùng nhiều ngữ cảnh, còn vùng biên giữ nhiều chi tiết hơn.

PIDNet-S/M/L thay đổi số block và số kênh để cân bằng độ chính xác với tốc độ. Ký hiệu (m, n, C) lần lượt chỉ số BasicBlock ở các tầng giữ chi tiết, số BasicBlock ở hai tầng ngữ cảnh trung gian và độ rộng cơ sở. Các cấu hình công bố là S: $(2, 3, 32)$, M: $(2, 4, 64)$ và L: $(3, 4, 64)$. Khi train, auxiliary semantic head và boundary head tạo thêm loss. Khi inference, có thể bỏ hai head này; đặc trưng D vẫn được giữ để tính Bag.

2.3.2 Pag: tiếp nhận ngữ cảnh có chọn lọc

P cần thêm ngữ cảnh từ I trong quá trình xử lý, nhưng lượng thông tin nhận vào nên thay đổi theo vị trí. Pag thực hiện việc này bằng cách đo mức tương đồng giữa hai đặc trưng:

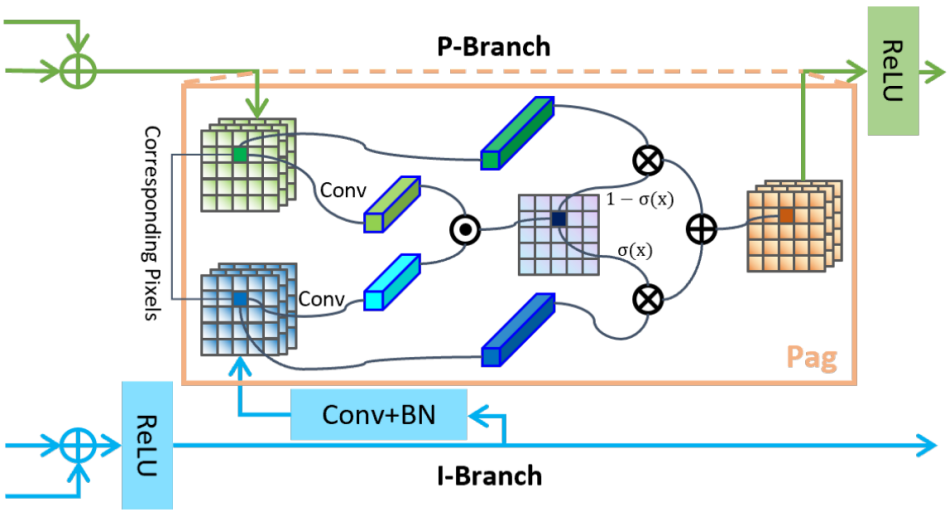
$$\alpha = \mathrm{sigmoid}\big(f_p(\mathbf{p})^\top f_i(\mathbf{i})\big)\,, \tag{2.9}$$

$$\mathbf{y}_{\mathrm{Pag}} = \alpha\mathbf{i} + (1-\alpha)\mathbf{p}. \tag{2.10}$$

Trong công thức (7)–(8) của bài báo, $\mathbf{p}$ và $\mathbf{i}$ là đặc trưng P và I tại cùng vị trí sau khi căn chỉnh kích thước; f_p và f_i là các phép chiếu học được. Tích vô hướng đo mức phù hợp giữa hai đặc trưng, còn sigmoid đưa hệ số α về khoảng $(0, 1)$. Khi α gần 1, đầu ra nhận nhiều thông tin từ I; khi gần 0, đầu ra giữ nhiều thông tin từ P. Pag vì vậy bổ sung ngữ cảnh có chọn lọc ở các tầng trung gian, trước bước fusion cuối.

2.3.3 PAPPM: tổng hợp ngữ cảnh với độ trễ thấp

Sau khi giảm độ phân giải, I cần ghép thông tin từ nhiều vùng quan sát. Pooling ở vùng nhỏ giữ ngữ cảnh lân cận; pooling trên toàn feature map cho biết bối cảnh chung của ảnh. DAPPM ghép các mức này theo chuỗi, nên mức sau phải chờ kết quả mức trước. PAPPM tổ chức lại để các mức được xử lý song song hơn và giảm số kênh mỗi mức từ 128 xuống 96. PIDNet-S/M dùng PAPPM để giảm độ trễ; PIDNet-L dùng DAPPM với số kênh được điều chỉnh.



Hình 2.3: Pag dùng tương đồng giữa đặc trưng P và I để điều chỉnh lateral fusion. Trích Hình 5 của Xu và cộng sự [1].

2.3.4 Bag và Light-Bag: dùng biên để điều tiết fusion

Ở bước fusion cuối, thông tin biên giúp chọn giữa chi tiết và ngữ cảnh. Bag thực hiện phép chọn mềm theo công thức (9)–(10) của bài báo:

$$\boldsymbol{\beta} = \mathrm{sigmoid}(\mathbf{d}), \tag{2.11}$$

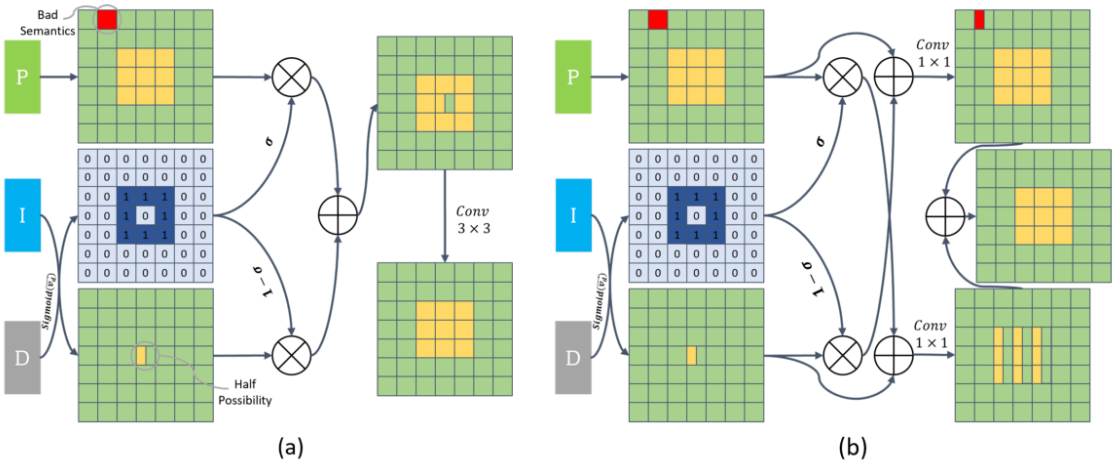
$$\mathbf{y}_{\mathrm{Bag}} = f_{\mathrm{out}}((1-\boldsymbol{\beta}) \odot \mathbf{i} + \boldsymbol{\beta} \odot \mathbf{p}). \tag{2.12}$$

Trong đó, $\mathbf{d}$ là đặc trưng của D, $\boldsymbol{\beta}$ là hệ số sau sigmoid và $\odot$ là phép nhân theo phần tử. Phép f_{out} gồm convolution, BatchNorm và ReLU. Khi $\boldsymbol{\beta}$ lớn, Bag giữ nhiều đặc trưng P; khi nhỏ, Bag dùng nhiều đặc trưng I. Ở mép người đi bộ, P giúp giữ đúng đường viền. Trong vùng mặt đường rộng, I giúp dự đoán nhãn ổn định hơn. Hệ số này được tính cho từng kênh từ đặc trưng D; boundary head riêng mới tạo một điểm biên tại mỗi pixel.

Light-Bag thay convolution 3×3 bằng hai luồng convolution 1×1, với công thức (11):

$$\begin{aligned} \mathbf{y}_{\mathrm{Light}} = {} & f_p((1-\boldsymbol{\beta}) \odot \mathbf{i} + \mathbf{p}) \\ & + f_i(\boldsymbol{\beta} \odot \mathbf{p} + \mathbf{i}). \end{aligned} \tag{2.13}$$

Ở đây, f_p và f_i là hai phép biến đổi convolution 1×1 kèm BatchNorm. Luồng thứ nhất giữ trực tiếp P và nhận thêm $(1-\boldsymbol{\beta}) \odot \mathbf{i}$; luồng thứ hai giữ trực tiếp I và nhận thêm $\boldsymbol{\beta} \odot \mathbf{p}$. Hai kết quả được cộng lại. Light-Bag nhờ đó vẫn dùng D để điều chỉnh trao đổi detail–context, với convolution nhẹ hơn Bag.



Hình 2.4: Bag (trái) và Light-Bag (phải) kết hợp P và I bằng tín hiệu D. Các ô màu minh họa vùng bên trong vật thể và vùng biên. Trích Hình 7 của Xu và cộng sự [1].

2.4 Boundary supervision và hàm mục tiêu

PIDNet phối hợp bốn loss:

$$L_{\text{PIDNet}} = 0{,}4\ell_0 + 20\ell_1 + \ell_2 + \ell_3. \tag{2.14}$$

Trong công thức (6), ℓ_0 là auxiliary semantic cross-entropy sau Pag đầu tiên, giúp P học phân loại ngay ở tầng trung gian. ℓ_1 là weighted boundary BCE, dùng trọng số để cân bằng nhóm pixel biên ít hơn nhóm không biên. ℓ_2 là semantic cross-entropy ở đầu ra chính. ℓ_3 là boundary-awareness cross-entropy, gọi tắt là BAS-Loss, tập trung vào lỗi phân loại tại những vị trí được dự đoán là biên. Nhãn cho boundary head được tạo từ mặt nạ phân đoạn bằng Canny rồi dilation.

BAS-Loss được viết trong công thức (5) của bài báo như sau:

$$\ell_3 = -\sum_{i,c} \mathbf{1}[b_i > 0{,}8]\, s_{i,c} \log \hat{s}_{i,c}. \tag{2.15}$$

Ở đây, b_i là điểm sigmoid của boundary head tại pixel i; $s_{i,c}$ bằng 1 nếu nhãn đúng là lớp c và bằng 0 ở các lớp còn lại; $\hat{s}_{i,c}$ là xác suất mạng dự đoán cho lớp đó. Hàm chỉ thị $\mathbf{1}[b_i > 0{,}8]$ giữ pixel có điểm biên lớn hơn 0,8 và bỏ các pixel khác khỏi BAS-Loss. Ba cơ chế dùng biên có vai trò riêng: BCE dạy D tìm biên, BAS nhấn mạnh lỗi ngữ nghĩa ở vùng biên dự đoán, còn Bag dùng đặc trưng D để ghép P và I. Ngưỡng 0,8 chỉ dùng cho BAS; Bag dùng hệ số sigmoid liên tục.

Biên ngữ nghĩa là nơi nhãn lớp thay đổi, chẳng hạn từ người sang mặt đường. Một vạch sơn hay bóng đổ có thể tạo cạnh ảnh mạnh nhưng vẫn thuộc cùng lớp Road. Nếu D nhầm các cạnh này thành biên, cả fusion và vùng được BAS chọn đều có thể bị ảnh hưởng. Đây là điểm cần xem xét khi phân tích những trường hợp dự đoán sai.

2.5 Thí nghiệm và mức đóng góp của paper

2.5.1 Giao thức và kết quả chính

Bài báo đánh giá trên Cityscapes, CamVid và PASCAL Context, dùng mIoU để đo độ chính xác. Mạng được pretrained trên ImageNet trước khi học phân đoạn; riêng CamVid tiếp tục từ trọng số Cityscapes. Trên Cityscapes, lịch train gồm 484 epoch, thay đổi tỷ lệ ảnh trong $[0{,}5; 2{,}0]$ và crop 1024×1024. Tác giả dùng cả train và validation để huấn luyện mô hình nộp test Cityscapes/CamVid. Tốc độ trong bảng được đo trên một RTX 3090, batch size 1, sau khi gộp BatchNorm vào convolution.

Mô hình	Dataset / tập	mIoU (%)	FPS
PIDNet-S	Cityscapes test	78,6	93,2
PIDNet-M	Cityscapes test	80,1	39,8
PIDNet-L	Cityscapes test	80,6	31,1
PIDNet-S	CamVid test	80,1	153,7
PIDNet-L	PASCAL Context validation, 59 lớp	51,9	–

Bảng 2.2: Kết quả công bố trong Bảng 5–7 của PIDNet [1]. CamVid dùng Cityscapes pretraining. PASCAL Context dùng multi-scale và flip inference.

Bảng 2.2 cho thấy PIDNet-L đạt mIoU cao hơn S trên Cityscapes, nhưng tốc độ giảm từ 93,2 xuống 31,1 FPS. PIDNet-S vì vậy phù hợp hơn khi ưu tiên tốc độ, còn L dành thêm tính toán để tăng độ chính xác. Trên PASCAL Context, PIDNet-L đạt 51,9% mIoU với 59 lớp, so với 54,0% của HRNet-W48 trong cùng bảng của bài báo. Đóng góp chính của PIDNet là cân bằng tốc độ và độ chính xác cho real-time segmentation.

2.5.2 Đóng góp từng thành phần qua ablation

Ablation thay đổi một hoặc một nhóm thành phần để xem chúng đóng góp thế nào. Bảng 1 bổ sung đồng thời nhánh D phụ và Bag vào hai baseline. BiSeNet–ResNet18 tăng từ 75,4 lên 76,7% mIoU; DDRNet-23 tăng từ 79,5 lên 80,0%. Đổi lại, FPS lần lượt giảm từ 63,2 xuống 52,1 và từ 51,4 xuống 39,2. Phép so sánh này đo tác dụng chung của nhánh biên và fusion.

Bảng 3 khảo sát riêng fusion và context aggregation trên PIDNet-S. Khi giữ PAPPM và thay phép cộng bằng Light-Bag, mIoU tăng từ 78,4 lên 78,8%, còn tốc độ giảm từ 97,8 xuống 93,2 FPS. Khi giữ Light-Bag và thay DAPPM bằng PAPPM, mIoU vẫn là 78,8% nhưng tốc độ tăng từ 83,7 lên 93,2 FPS. Như vậy, Light-Bag giúp tăng độ chính xác, còn PAPPM giảm thời gian xử lý trong các cặp đối chứng này.

Bảng 2 xem Pag và Bag có phối hợp hiệu quả hay không trên PIDNet-L pretrained. Dùng cả hai đạt 80,9% mIoU, so với 80,7% khi chỉ dùng phép cộng ở các kết nối và fusion. Hai cấu hình chỉ dùng một trong hai mô-đun đều đạt 80,5%. Trong thí nghiệm này, kết hợp

Pag với Bag tốt hơn thay riêng một thành phần.

Bảng 4 khảo sát cách giám sát trên PIDNet-L. Khi lần lượt thêm auxiliary semantic loss, boundary loss, BAS-Loss rồi OHEM, mIoU đi từ 78,6 qua 78,8; 79,9; 80,5 đến 80,9%. Boundary loss tạo mức tăng 1,1 điểm phần trăm tại bước được thêm vào. BAS tiếp tục tăng 0,6 điểm phần trăm. OHEM (Online Hard Example Mining) ưu tiên các pixel mà mạng còn khó phân loại và tăng thêm 0,4 điểm phần trăm. Chuỗi này cho thấy cách tính loss đóng góp bên cạnh kiến trúc ba nhánh; mỗi mức tăng ứng với cấu hình ở ngay bước trước.

2.6 Liên hệ với thiết kế thực nghiệm A2

Thực nghiệm A2 chọn PIDNet-S trên CamVid và so sánh PIDNet-S đủ loss với PIDNet-S bỏ BAS-Loss. Bản đủ loss dùng bốn thành phần trong công thức (2.14); bản bỏ BAS-Loss chỉ bỏ ℓ_3, tức phần cross-entropy ngữ nghĩa bổ sung tại các pixel được dự đoán là biên. Cả hai giữ ba nhánh P/I/D, Pag, PAPPM, Light-Bag và các đầu dự đoán. Auxiliary semantic loss, weighted boundary BCE và main semantic loss với OHEM vẫn được tính ở cả hai.

Lựa chọn này xuất phát từ Bảng 4: sau khi đã học phân đoạn và biên, BAS tăng thêm giám sát ngữ nghĩa tại các pixel có điểm biên cao. A2 kiểm tra tác dụng đó trên PIDNet-S và CamVid, với cùng OHEM ở hai biến thể. Câu hỏi thực nghiệm là: việc nhấn mạnh thêm lỗi ở vùng biên dự đoán có cải thiện mIoU và IoU từng lớp hay không?

Chương 3

Dữ liệu và thiết lập thực nghiệm

3.1 Nguồn dữ liệu và nhãn

CamVid gồm 701 khung hình video giao thông có nhãn cho từng pixel. Một ảnh có thể chứa mặt đường, nhà, cây, xe và người với kích thước rất khác nhau [4, 5]. Ảnh và nhãn được lấy từ bản phân phối Kaggle mà kho mã PIDNet dẫn nguồn [6, 8]. Ảnh và nhãn có kích thước gốc 960×720 pixel, được lưu dưới dạng PNG RGB. Từ 32 lớp trong bộ nhãn gốc, thí nghiệm sử dụng 11 lớp theo quy ước của PIDNet; các lớp còn lại được bỏ qua khi tính loss và chỉ số đánh giá.

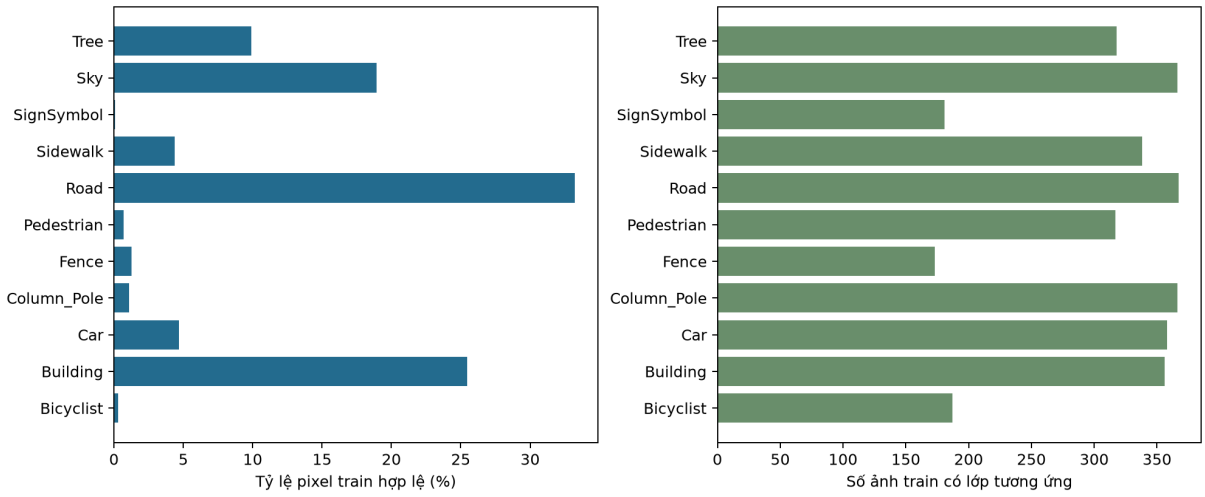
ID	Lớp	RGB	Tỷ lệ pixel train (%)
0	Bicyclist	$(0, 128, 192)$	0,31
1	Building	$(128, 0, 0)$	25,46
2	Car	$(64, 0, 128)$	4,67
3	Column_Pole	$(192, 192, 128)$	1,10
4	Fence	$(64, 64, 128)$	1,26
5	Pedestrian	$(64, 64, 0)$	0,72
6	Road	$(128, 64, 128)$	33,23
7	Sidewalk	$(0, 0, 192)$	4,36
8	SignSymbol	$(192, 128, 128)$	0,07
9	Sky	$(128, 128, 128)$	18,93
10	Tree	$(128, 128, 0)$	9,89

Bảng 3.1: Ánh xạ màu sang ID lớp theo PIDNet và phân bố đo trên toàn bộ 367 ảnh train. Tỷ lệ dùng tổng số pixel có nhãn hợp lệ làm mẫu số.

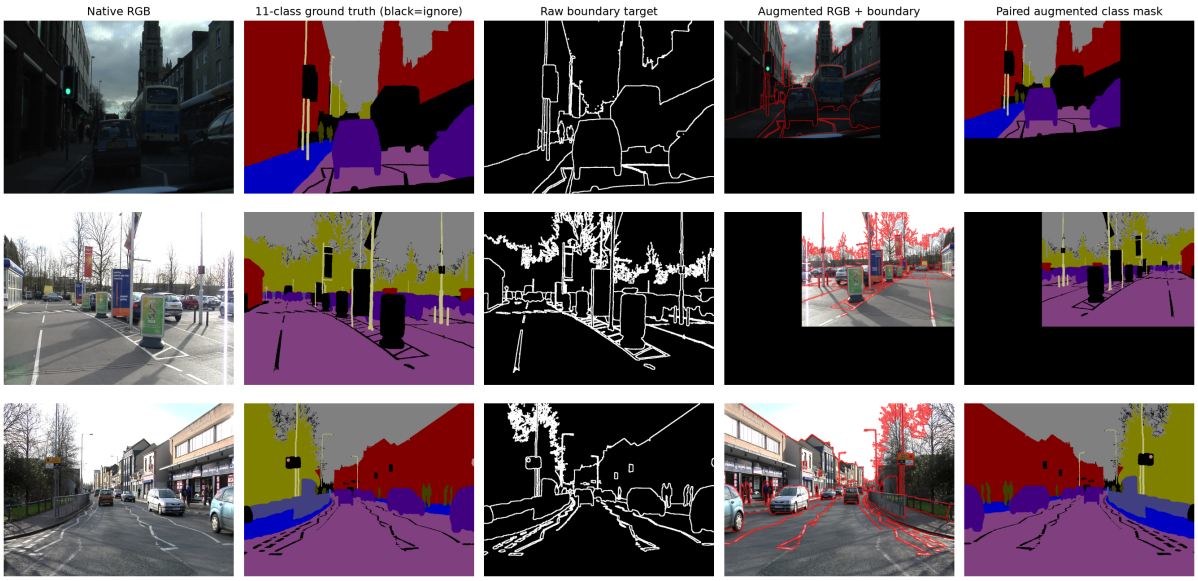
3.2 Chia tập và phân tích khám phá

Dữ liệu được chia theo danh sách của tác giả PIDNet: 367 ảnh train, 101 ảnh validation và 233 ảnh test [6]. Ba tập không trùng ảnh. Tập train dùng để cập nhật trọng số, validation dùng để chọn checkpoint và test được giữ riêng cho đánh giá cuối cùng.

Trong tập train, Road, Building và Sky chiếm 77,62% pixel hợp lệ, còn SignSymbol chỉ chiếm 0,07% (Bảng 3.1). Nếu dự đoán tốt các lớp lớn nhưng bỏ sót biển báo, mô hình vẫn có thể đạt pixel accuracy cao. Vì vậy, báo cáo dùng mIoU để mỗi lớp có trọng số ngang nhau, đồng thời xem IoU của từng lớp. Các vùng ngoài 11 lớp chiếm khoảng 10,82% tổng pixel train và được bỏ qua.



Hình 3.1: Tỷ lệ pixel hợp lệ và số ảnh có mỗi lớp trên toàn bộ 367 ảnh train. Road, Building và Sky chiếm phần lớn pixel, trong khi các lớp nhỏ xuất hiện với tỷ lệ thấp.



Hình 3.2: Ba ảnh train, mặt nạ 11 lớp, nhãn biên và ví dụ tăng cường dữ liệu được thực hiện trong notebook. Màu đen trên mặt nạ là vùng bỏ qua; crop và flip được áp dụng đồng thời cho ảnh và nhãn.

3.3 Mô hình và hai biến thể đối chứng

Thí nghiệm dùng PIDNet-S với ba nhánh P/I/D, Pag, PAPPM và Light-Bag đã trình bày ở chương trước. Mô hình bắt đầu từ checkpoint Cityscapes 19 lớp của tác giả [6]. Hai lớp convolution cuối của các đầu ngữ nghĩa được thay để dự đoán 11 lớp CamVid và khởi tạo lại. Phần còn lại nhận trọng số pretrained; toàn bộ mạng tiếp tục được cập nhật trong quá trình fine-tuning. Mô hình khi train có 7.718.871 tham số, bao gồm hai auxiliary head. Khi bỏ các head này để inference, số tham số còn 7.624.683, tương ứng mức làm tròn 7,6 triệu của PIDNet-S; cả ba nhánh P/I/D vẫn được giữ.

PIDNet-S đủ loss và PIDNet-S bỏ BAS-Loss dùng cùng kiến trúc, chỉ khác việc có tính thêm semantic cross-entropy tại vùng biên dự đoán hay không. Ở mỗi seed, chúng có cùng khởi tạo, dữ liệu và cách tăng cường ảnh. Giám sát biên cùng các loss còn lại được giữ nguyên, để phép so sánh tập trung vào tác dụng của BAS.

3.4 Tiền xử lý dữ liệu

Trong tập train, ảnh được thay đổi tỷ lệ ngẫu nhiên trong khoảng $[0{,}5; 2{,}0]$ nhưng vẫn giữ tỷ lệ khung hình. Sau đó, lấy crop 960×720 và lật ngang với xác suất 0,5. Ảnh được nội suy bilinear; nhãn dùng nearest-neighbor để giữ nguyên lớp. Ảnh nhỏ hơn kích thước crop được thêm viền đen, còn phần nhãn tương ứng được bỏ qua. Các kênh RGB được chuẩn hóa theo mean và standard deviation của ImageNet. Validation và test giữ nguyên kích thước ảnh, không dùng phép biến đổi ngẫu nhiên.

Nhãn biên được tạo từ mặt nạ ngữ nghĩa bằng Canny, sau đó dilation với kernel 4×4, theo cách xử lý CamVid của tác giả. Ảnh, mặt nạ lớp và mặt nạ biên luôn được biến đổi đồng thời để giữ đúng vị trí tương ứng.

3.5 Hàm mất mát

Gọi ℓ_0 là auxiliary semantic CE, ℓ_1 là weighted boundary BCE, ℓ_2 là main semantic OHEM CE và ℓ_3 là BAS semantic OHEM CE. Hai hàm mục tiêu là

$$L_{\text{FULL}} = 0{,}4\ell_0 + 20\ell_1 + \ell_2 + \ell_3, \tag{3.1}$$

$$L_{\text{NO_BAS}} = 0{,}4\ell_0 + 20\ell_1 + \ell_2. \tag{3.2}$$

Weighted BCE cân bằng đóng góp giữa pixel biên và pixel không biên. OHEM ưu tiên những pixel mà mạng gán xác suất thấp cho lớp đúng, với ngưỡng 0,9 và mốc chọn 131.072 pixel theo cấu hình CamVid của tác giả. BAS-Loss tính thêm semantic cross-entropy với OHEM tại những pixel có điểm sigmoid của boundary head lớn hơn 0,8. Đây là các pixel mô hình dự đoán là biên. Nếu không có pixel được chọn, BAS-Loss bằng 0.

PIDNet-S bỏ BAS-Loss vẫn giữ ba nhánh P/I/D, vẫn huấn luyện boundary head bằng weighted BCE và vẫn dùng đặc trưng D trong Light-Bag. Đối chứng vì vậy trả lời việc tính thêm lỗi phân loại tại vùng biên dự đoán có giúp cải thiện kết quả hay không.

3.6 Huấn luyện và chọn checkpoint

Mỗi biến thể được huấn luyện với ba seed 42, 43 và 44. Cả sáu lượt dùng cùng thiết lập trong Bảng 3.2 và cập nhật trọng số trên toàn bộ 367 ảnh train ở mỗi epoch.

Thành phần	Thiết lập chung
Số epoch	200
Batch size	12
Kiểu tính toán	FP32
Optimizer	SGD, momentum 0,9; weight decay 5×10^{-4}
Learning rate	Ban đầu 10^{-3}; giảm theo lịch polynomial, power 0,9

Bảng 3.2: Thiết lập train chung cho PIDNet-S đủ loss và PIDNet-S bỏ BAS-Loss.

Learning rate được cập nhật ở đầu mỗi epoch theo $\eta_e = 10^{-3}(1 - e/200)^{0,9}$, với $e = 0, \ldots, 199$. Sau mỗi epoch, mô hình được đánh giá trên 101 ảnh validation. Checkpoint có mIoU cao nhất được giữ lại; nếu nhiều epoch bằng nhau, chọn epoch sớm nhất. Toàn bộ lịch huấn luyện vẫn được chạy đủ trước khi dùng checkpoint đã chọn để đánh giá test. Sáu lượt chạy được thực hiện trên NVIDIA GeForce RTX 5090, dùng PyTorch 2.10.0 với CUDA 13.0 và kiểu tính toán FP32. Thời gian train gồm chuẩn bị batch và cập nhật trọng số; thời gian tổng còn gồm validation và ghi checkpoint.

3.7 Đánh giá phân đoạn

Tập test gồm 233 ảnh chỉ được dùng sau khi cố định thiết kế thực nghiệm và chọn checkpoint bằng validation. Dự đoán lấy từ đầu ngữ nghĩa chính, ở một tỷ lệ ảnh và không flip. Logit được nội suy về kích thước gốc 960×720 trước khi chọn lớp; các pixel không thuộc 11 lớp được bỏ qua.

Các dự đoán được gộp vào một confusion matrix cho toàn tập: hàng là lớp đúng, cột là lớp dự đoán. Từ đó tính IoU từng lớp và lấy trung bình thành mIoU:

$$\mathrm{IoU}_c = \frac{TP_c}{TP_c + FP_c + FN_c}, \qquad \mathrm{mIoU} = \frac{1}{11}\sum_{c=0}^{10} \mathrm{IoU}_c.$$

Với lớp c, TP_c là số pixel dự đoán đúng; FP_c là số pixel của lớp khác bị gán thành c; FN_c là số pixel thuộc c nhưng bị gán sang lớp khác. IoU đo phần giao giữa vùng dự đoán và vùng nhãn đúng so với phần hợp của chúng.

Chương 4

Kết quả thực nghiệm

4.1 Kết quả tổng hợp và từng lượt chạy

Trên 233 ảnh test, PIDNet-S đủ loss đạt 79,03 ± 0,44% mIoU, còn PIDNet-S bỏ BAS-Loss đạt 78,38 ± 0,47%. Macro-Dice tương ứng là 87,29 ± 0,32% và 86,75 ± 0,41%. Các giá trị sau dấu ± là độ lệch chuẩn mẫu qua ba seed.

Mô hình	mIoU (%)	Macro-Dice (%)	Train (phút)
PIDNet-S đủ loss	79,03 ± 0,44	87,29 ± 0,32	26,60 ± 0,04
PIDNet-S bỏ BAS-Loss	78,38 ± 0,47	86,75 ± 0,41	26,19 ± 0,02

Bảng 4.1: Trung bình và độ lệch chuẩn mẫu của ba seed trên 233 ảnh test. Thời gian train tính trên RTX 5090.

Seed	Epoch chọn	Val mIoU	Test mIoU	Macro-Dice	Train (phút)	Tổng (phút)
PIDNet-S đủ loss						
42	21	79,89	79,11	87,36	26,56	30,75
43	19	80,16	78,56	86,94	26,59	30,79
44	77	79,07	79,42	87,56	26,64	30,81
PIDNet-S bỏ BAS-Loss						
42	30	79,31	78,31	86,78	26,17	30,34
43	42	79,70	77,94	86,32	26,18	30,35
44	75	79,38	78,88	87,13	26,21	30,38

Bảng 4.2: Kết quả của sáu lượt train 200 epoch. Các chỉ số phân đoạn tính bằng phần trăm. Thời gian train gồm chuẩn bị batch và cập nhật trọng số; thời gian tổng còn gồm validation và ghi checkpoint.

Bản đủ loss có mIoU cao hơn ở cả ba cặp seed, lần lượt 0,80; 0,63 và 0,54 điểm phần trăm. Chênh lệch ghép theo seed là 0,66 ± 0,13 điểm phần trăm (Bảng 4.3). Thời gian train trung bình tăng từ 26,19 lên 26,60 phút mỗi lượt khi thêm BAS-Loss; thời gian tổng của một lượt vào khoảng 30–31 phút.

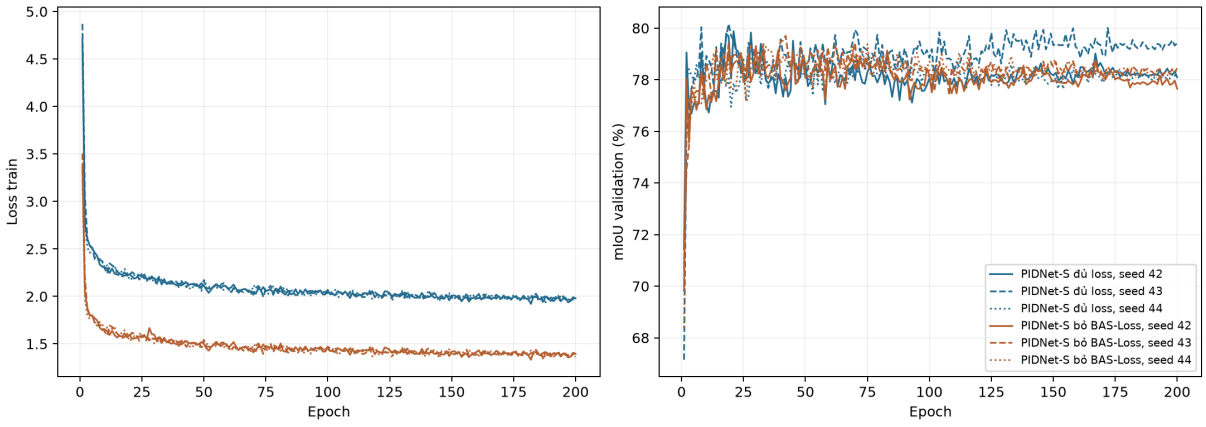
Seed	Đủ loss (%)	Bỏ BAS-Loss (%)	Chênh lệch (đpt)
42	79,11	78,31	+0,80
43	78,56	77,94	+0,63
44	79,42	78,88	+0,54
Trung bình ± SD của chênh lệch			+0,66 ± 0,13

Bảng 4.3: Chênh lệch mIoU của PIDNet-S đủ loss trừ PIDNet-S bỏ BAS-Loss ở từng cặp seed. Đpt là điểm phần trăm.

4.2 Loss train, mIoU validation và lựa chọn checkpoint

Với các seed 42, 43 và 44, bản đủ loss chọn lần lượt epoch 21, 19 và 77; bản bỏ BAS-Loss chọn epoch 30, 42 và 75. Các mốc này đều được quyết định bằng mIoU validation trong lịch 200 epoch. Test chỉ được đánh giá sau khi sáu lượt train và việc chọn checkpoint hoàn tất.

Hình 4.1 cho thấy loss giảm nhanh ở giai đoạn đầu rồi giảm chậm hơn, trong khi mIoU validation dao động quanh 78–80%. Ở các epoch cuối, loss tiếp tục giảm nhưng mIoU validation thấp hơn mốc tốt nhất đã chọn. Vì vậy, dùng checkpoint theo validation giữ được các mô hình tốt hơn trên tập này so với lấy mặc định epoch cuối. Loss tổng của bản đủ loss có thêm thành phần BAS, nên độ cao hai đường loss được đọc theo từng hàm mục tiêu.



Hình 4.1: Loss train và mIoU validation của sáu lượt chạy. Màu phân biệt biến thể, kiểu nét phân biệt seed. Mỗi đường biểu diễn một lượt; loss của bản đủ loss có thêm BAS-Loss.

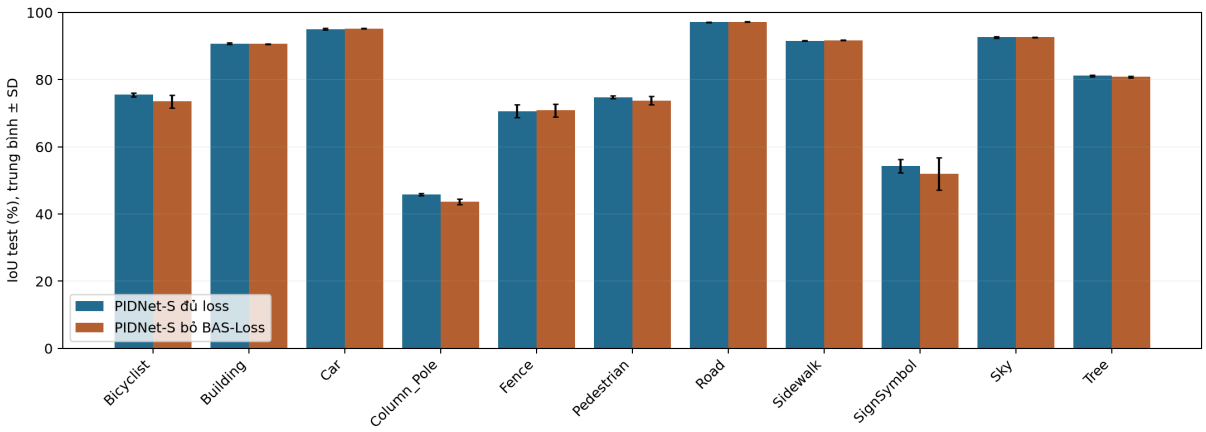
4.3 Ảnh hưởng của BAS-Loss theo từng lớp

Bảng 4.4 và Hình 4.2 cho thấy mức tăng trung bình lớn nhất ở SignSymbol (2,31 điểm phần trăm), Column_Pole (2,15 điểm phần trăm) và Bicyclist (2,00 điểm phần trăm).

Pedestrian tăng 0,98 điểm phần trăm. Ba lớp Column_Pole, Bicyclist và Pedestrian đều tăng ở cả ba cặp seed. Đây là các lớp nhỏ hoặc có hình dạng mảnh, phù hợp với mục tiêu bổ sung giám sát ở vùng biên dự đoán.

Lớp	Đủ loss (%)	Bỏ BAS-Loss (%)	Chênh lệch (đpt)
Bicyclist	$75{,}51 \pm 0{,}63$	$73{,}51 \pm 1{,}84$	$+2{,}00 \pm 2{,}10$
Building	$90{,}73 \pm 0{,}27$	$90{,}62 \pm 0{,}10$	$+0{,}11 \pm 0{,}26$
Car	$95{,}09 \pm 0{,}30$	$95{,}24 \pm 0{,}09$	$-0{,}16 \pm 0{,}21$
Column_Pole	$45{,}82 \pm 0{,}33$	$43{,}67 \pm 0{,}76$	$+2{,}15 \pm 0{,}82$
Fence	$70{,}64 \pm 1{,}91$	$70{,}86 \pm 1{,}91$	$-0{,}22 \pm 0{,}97$
Pedestrian	$74{,}78 \pm 0{,}39$	$73{,}80 \pm 1{,}27$	$+0{,}98 \pm 1{,}31$
Road	$97{,}13 \pm 0{,}07$	$97{,}24 \pm 0{,}05$	$-0{,}11 \pm 0{,}11$
Sidewalk	$91{,}59 \pm 0{,}07$	$91{,}72 \pm 0{,}09$	$-0{,}13 \pm 0{,}12$
SignSymbol	$54{,}28 \pm 2{,}02$	$51{,}98 \pm 4{,}74$	$+2{,}31 \pm 2{,}81$
Sky	$92{,}61 \pm 0{,}24$	$92{,}67 \pm 0{,}07$	$-0{,}06 \pm 0{,}20$
Tree	$81{,}17 \pm 0{,}22$	$80{,}82 \pm 0{,}29$	$+0{,}35 \pm 0{,}39$

Bảng 4.4: IoU từng lớp: trung bình và SD qua ba seed. Chênh lệch được ghép theo seed trước khi tổng hợp.



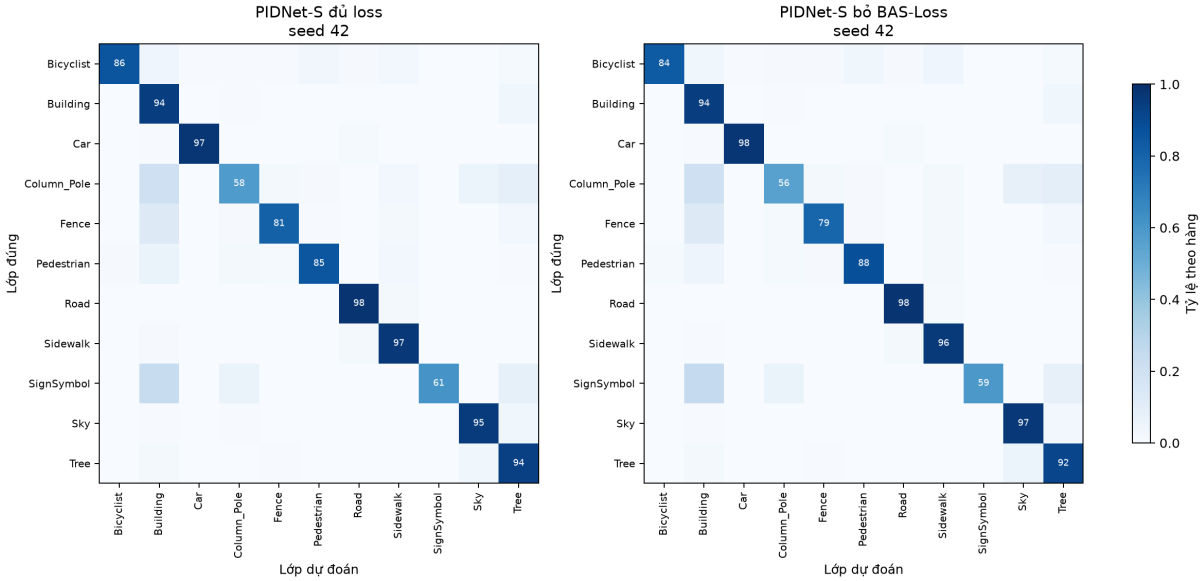
Hình 4.2: IoU test của 11 lớp, lấy trung bình qua ba seed; thanh sai số là độ lệch chuẩn mẫu.

Mức tăng ở SignSymbol có độ dao động lớn: giảm 0,29 điểm phần trăm ở seed 42, tăng 5,29 ở seed 43 và tăng 1,92 ở seed 44. Trong khi đó, các lớp Car, Fence, Road, Sidewalk và Sky giảm nhẹ về trung bình, với mức giảm dưới 0,22 điểm phần trăm mỗi lớp. Lợi ích mIoU tổng thể vì vậy chủ yếu đến từ một số lớp nhỏ, thay vì tăng đồng đều ở mọi lớp.

Cả hai biến thể vẫn học biên bằng weighted BCE và dùng D trong Light-Bag. Phần bổ sung của bản đủ loss là cross-entropy ngữ nghĩa ở các pixel được boundary head chọn. Kết quả ba cặp seed ủng hộ việc dùng thêm BAS-Loss trong thiết lập này. Phép đo hiện tại là IoU theo lớp, nên chưa tách riêng sai số trong một dải có độ rộng cố định quanh biên.

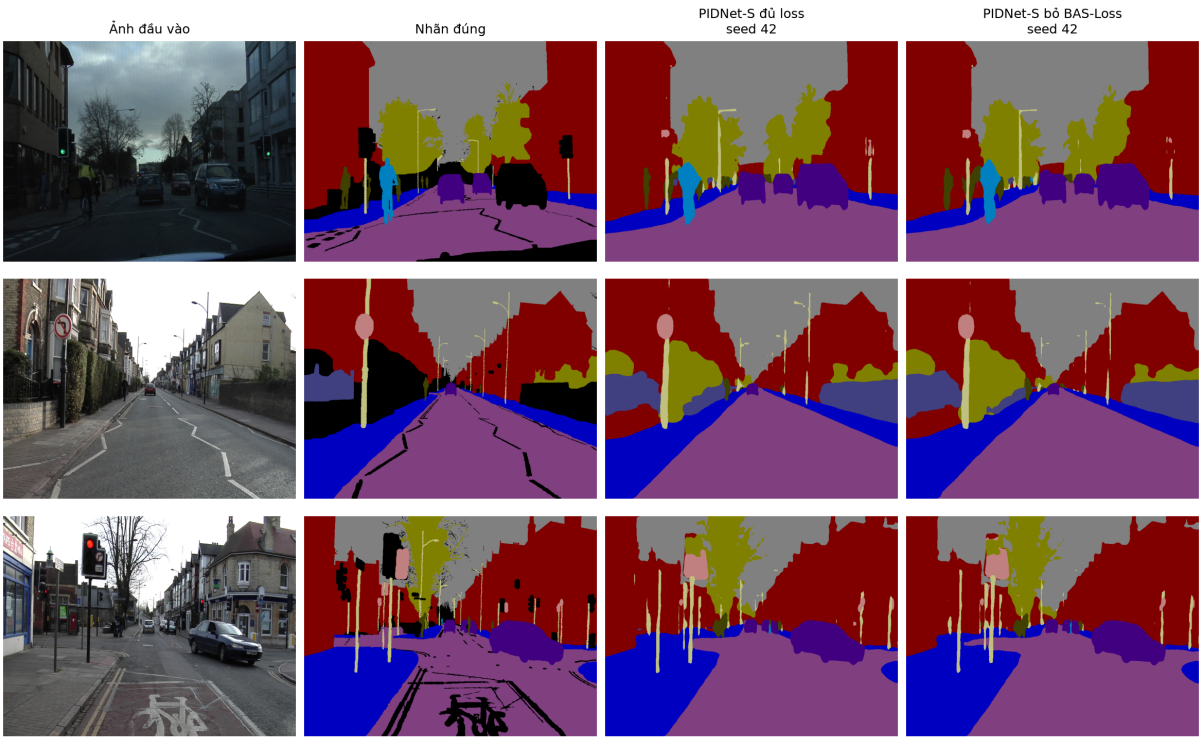
4.3.1 Nhầm lẫn giữa các lớp và ví dụ dự đoán

Column_Pole và SignSymbol vẫn là hai lớp khó nhất ở bản đủ loss, với IoU trung bình 45,82% và 54,28%. Ở seed 42, bản đủ loss nhận đúng 58,37% pixel cột, so với 55,58% của bản bỏ BAS-Loss. Khoảng 20,82% pixel cột vẫn bị gán thành Building. Với SignSymbol, 24,07% pixel bị gán thành Building ở bản đủ loss. Các cột và biển báo nhỏ nằm trước tòa nhà vì vậy còn dễ bị lẫn với nền phía sau.



Hình 4.3: Confusion matrix trên test của hai checkpoint seed 42, chuẩn hóa theo hàng. Đường chéo là tỷ lệ pixel của mỗi lớp được nhận đúng; các con số trên đường chéo tính bằng phần trăm.

Hình 4.4 dùng ba ảnh tại các vị trí cố định 0, 77 và 155 trong danh sách test, cùng checkpoint seed 42. Hai bản đều nhận ra các vùng lớn như mặt đường, tòa nhà và xe. Các cành cây mảnh còn bị gộp thành những vùng Tree đặc hơn so với nhãn đúng. Sự khác biệt giữa hai bản khó thấy khi chỉ nhìn các vùng lớn; bảng IoU theo lớp và confusion matrix bổ sung thông tin cho các ví dụ này.



Hình 4.4: Ba ảnh CamVid test, nhãn đúng và dự đoán của hai biến thể ở seed 42. Màu theo Bảng 3.1; màu đen trong nhãn đúng là vùng bỏ qua.

4.4 Đối chiếu với kết quả công bố

Split chuẩn của CamVid gồm 367 ảnh train, 101 ảnh validation và 233 ảnh test. Ở kết quả test cuối cùng, tác giả PIDNet gộp 367 ảnh train với 101 ảnh validation thành 468 ảnh để train. A2 giữ riêng 101 ảnh validation để chọn checkpoint, nên dùng 367 ảnh train. Đánh giá lại checkpoint tác giả đạt 80,1039% mIoU, gần mốc 80,1% công bố; bản đủ loss của A2 đạt trung bình 79,03%. Bảng 4.5 trình bày các kết quả cùng số ảnh train tương ứng.

Mô hình	Ảnh train	mIoU (%)	FPS	GPU
PIDNet-S công bố	468	80,10	153,70	RTX 3090
Checkpoint tác giả, đo lại	468	80,10	$230{,}23 \pm 0{,}04$	RTX 5090
PIDNet-S đủ loss	367	$79{,}03 \pm 0{,}44$	$231{,}32 \pm 0{,}06$	RTX 5090
PIDNet-S bỏ BAS-Loss	367	$78{,}38 \pm 0{,}47$	—	RTX 5090

Bảng 4.5: Đối chiếu trên CamVid test 233 ảnh ở 960×720. mIoU của hai biến thể A2 tổng hợp ba seed; FPS của bản đủ loss chỉ đo checkpoint seed 42. FPS đo lại là trung bình và SD của năm lượt, mỗi lượt 200 forward sau 20 warm-up, batch 1, FP32, tắt auxiliary heads. Không có phép đo FPS riêng cho bản bỏ BAS-Loss. Bài báo dùng train+validation và điều kiện đo riêng [1].

Trên cùng RTX 5090, tốc độ forward của hai checkpoint chỉ chênh khoảng 1 FPS, phù hợp với việc giữ nguyên kiến trúc PIDNet-S. Mốc 153,7 FPS trong bài báo dùng RTX 3090, nên việc so sánh tốc độ cần xét cả phần cứng và quy trình đo.

4.5 Suy luận trên video

Video minh họa lấy một đoạn liên tục từ chuỗi CamVid `0005VD.MXF`, ghi cảnh đường phố từ camera phía trước xe [5, 7]. Video gốc được cung cấp qua liên kết dữ liệu trong kho mã chính thức TMANet. Đoạn được chọn có 869 khung hình, dài gần 29 giây ở tốc độ nguồn 29,97 FPS.

Checkpoint seed 42 của PIDNet-S đủ loss xử lý từng khung hình ở độ phân giải 960×720, tạo mask rồi chồng màu phân đoạn lên ảnh. Phép chạy này dùng RTX 5090 và FP32. Hình 4.5 cho thấy ba khung hình đầu vào và kết quả vừa chạy.

Phép đo video	Giá trị
Số khung hình	869
Tốc độ nguồn (FPS)	29,97
Độ dài đoạn nguồn (giây)	29,00
Độ trễ từ ảnh đến mask (ms)	19,39
FPS từ ảnh đến mask	51,56
FPS toàn luồng xuất video	21,45
Thời gian xuất (giây)	40,52

Bảng 4.6: Phép chạy trên toàn bộ 869 khung hình CamVid 0005VD bằng checkpoint PIDNet-S đủ loss, seed 42, ở 960×720 trên RTX 5090, FP32. Độ trễ từ ảnh đến mask gồm tiền xử lý, suy luận và tạo mask; toàn luồng còn gồm đọc, vẽ và ghi video.

Độ trễ trung bình từ ảnh đến mask là 19,39 ms, tương đương 51,56 mask/giây, cao hơn tốc độ nguồn. Khi tính cả đọc, vẽ và ghi video, tốc độ toàn luồng còn 21,45 FPS; xuất toàn bộ đoạn mất 40,52 giây. Vì vậy, bước tạo mask đáp ứng được tốc độ nguồn trong phép chạy này, còn toàn luồng xuất video chưa đạt 29,97 FPS. Các giá trị này đo công việc rộng hơn forward và được trình bày riêng với benchmark ở Bảng 4.5.



Hình 4.5: Ba khung hình 90, 420 và 780 từ đoạn CamVid 0005VD vừa chạy qua checkpoint PIDNet-S đủ loss, seed 42. Cột trái là ảnh đầu vào; cột phải là mask dự đoán được chồng màu lên ảnh. Các vùng mặt đường, vỉa hè, tòa nhà, cây và xe được hiển thị theo 11 lớp CamVid.

Video minh họa quá trình phân đoạn trên các khung hình liên tiếp; độ chính xác được đánh giá trên 233 ảnh CamVid test. Bản video được cung cấp trên trang A2.

Chương 5

Kết luận và giới hạn

PIDNet kết hợp ba loại thông tin cần cho phân đoạn: chi tiết từ P, ngữ cảnh rộng từ I và biên ngữ nghĩa từ D. Pag bổ sung ngữ cảnh vào P ở các tầng trung gian; PAPPM tổng hợp nhiều mức ngữ cảnh với chi phí thấp; Light-Bag dùng D để ghép P và I ở cuối mạng. Phân tích các công thức và ablation cho thấy cách kết hợp đặc trưng và cách tính loss đều góp phần vào kết quả của bài báo.

Trên CamVid, PIDNet-S đủ loss đạt $79{,}03 \pm 0{,}44\%$ mIoU, so với $78{,}38 \pm 0{,}47\%$ của bản bỏ BAS-Loss. Bản đủ loss tăng ở cả ba cặp seed, với chênh lệch trung bình $0{,}66 \pm 0{,}13$ điểm phần trăm. Các lớp cột, người đi xe đạp và người đi bộ đều tăng ở cả ba seed, trong khi mức thay đổi ở biển báo dao động lớn hơn. Kết quả ủng hộ việc giữ BAS-Loss khi fine-tune PIDNet-S theo thiết lập này.

Đánh giá lại checkpoint tác giả đạt 80,1039% mIoU, gần mức 80,1% công bố. Hai biến thể fine-tuning và checkpoint tác giả có điều kiện dữ liệu khác nhau: A2 dùng 367 ảnh train và giữ 101 ảnh validation để chọn mô hình. Phép đo forward của bản đủ loss đạt $231{,}32 \pm 0{,}06$ FPS trên RTX 5090; phép chạy video CamVid mới đạt 51,56 mask/giây và 21,45 FPS cho toàn luồng xuất video. Bước tạo mask nhanh hơn tốc độ nguồn 29,97 FPS, còn toàn luồng xuất chưa đạt tốc độ này.

Thực nghiệm có ba giới hạn chính. CamVid ít ảnh có nhãn và các khung hình cùng video thường chứa cảnh tương tự. Các mô hình bắt đầu từ trọng số Cityscapes, nên kết quả là đánh giá fine-tuning trên CamVid. Cuối cùng, ba seed của PIDNet-S cho biết độ dao động trong thiết lập này; tác dụng của BAS trên mạng lớn hơn hoặc tập dữ liệu khác cần được kiểm tra riêng.

Notebook thực nghiệm được cung cấp tại notebook A2.

Phạm vi hỗ trợ của AI được trình bày trong `AI_USE_REPORT.md`.

Tài liệu tham khảo

[1] Jiacong Xu, Zixiang Xiong và Shankar P. Bhattacharyya. *PIDNet: A Real-Time Semantic Segmentation Network Inspired by PID Controllers*. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), tr. 19529–19539, 2023. DOI: 10.1109/CVPR52729.2023.01871. Bản tại CVF. Bản toàn văn trên arXiv.

[2] C. Yu, J. Wang, C. Peng, C. Gao, G. Yu và N. Sang. *BiSeNet: Bilateral Segmentation Network for Real-Time Semantic Segmentation*. European Conference on Computer Vision (ECCV), tr. 325–341, 2018. Bản toàn văn tại ECVA.

[3] Y. Hong, H. Pan, W. Sun và Y. Jia. *Deep Dual-resolution Networks for Real-time and Accurate Semantic Segmentation of Road Scenes*. arXiv:2101.06085, 2021. `https://arxiv.org/abs/2101.06085`.

[4] Gabriel J. Brostow, Julien Fauqueur và Roberto Cipolla. *Semantic Object Classes in Video: A High-Definition Ground Truth Database*. Pattern Recognition Letters, tập 30, số 2, tr. 88–97, 2009. DOI: 10.1016/j.patrec.2008.04.005.

[5] University of Cambridge. *Cambridge-driving Labeled Video Database (CamVid)*. `https://mi.eng.cam.ac.uk/research/projects/VideoRec/CamVid/`.

[6] Jiacong Xu. *PIDNet: official implementation, CamVid data lists and model checkpoints*. `https://github.com/XuJiacong/PIDNet`.

[7] Nhóm tác giả TMANet. *Video CamVid gốc: 0005VD.MXF*, liên kết dữ liệu tại mục Usage của kho mã chính thức. `https://github.com/wanghao9610/TMANet#usage`.

[8] Carlo Lepelaars. *CamVid*, bản phân phối ảnh và nhãn màu trên Kaggle được kho mã PIDNet dẫn nguồn. `https://www.kaggle.com/datasets/carlolepelaars/camvid`.