ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO BÀI TẬP LỚN A2

CO5085 · Học sâu và ứng dụng trong thị giác máy tính

Học kỳ 261 · Năm học 2026–2027

PIDNet: phân tích kiến trúc và thực nghiệm fusion theo biên

Học viên

Huỳnh Thành Đạt	2570161
Giảng viên	Lê Thành Sách
	Nguyễn Quốc Minh

Thành phố Hồ Chí Minh, tháng 11 năm 2026

Tóm tắt

Báo cáo phân tích *PIDNet: A Real-Time Semantic Segmentation Network Inspired by PID Controllers* của Jiacong Xu, Zixiang Xiong và Shankar P. Bhattacharyya, công bố tại CVPR 2023 [1]. Paper đề xuất kiến trúc ba nhánh để xử lý việc đặc trưng ngữ cảnh lấn át chi tiết ở biên vật thể: P giữ chi tiết, I tổng hợp ngữ cảnh và D học thông tin biên để điều tiết fusion. Phần phân tích làm rõ cơ sở PID, vai trò của Pag, PAPPM, Bag và các loss, đồng thời xem xét bằng chứng ablation và giới hạn của kết quả công bố.

Thực nghiệm khảo sát quy tắc boundary-guided fusion trên Oxford-IIIT Pet bằng hai biến thể ResNet18 có cùng boundary supervision, lần lượt dùng hệ số cố định và hệ số phụ thuộc vị trí. Qua ba seed, mỗi lượt 12 epoch trên toàn bộ tập train, mIoU đạt $78{,}00 \pm 0{,}11\%$ với fusion cố định và $77{,}82 \pm 0{,}03\%$ với fusion theo biên. Chênh lệch ghép theo seed là $-0{,}18 \pm 0{,}12$ điểm phần trăm. IoU dải chuyển tiếp lần lượt là $55{,}15 \pm 0{,}39\%$ và $55{,}02 \pm 0{,}13\%$. Boundary head học được tín hiệu phân biệt các vùng, nhưng dùng trực tiếp tín hiệu này làm hệ số fusion chưa cải thiện mIoU. Kết quả được diễn giải trong phạm vi phép trộn được khảo sát và những khác biệt với PIDNet đầy đủ.

Tổng quan báo cáo

Bài toán	Phân đoạn vật thể, nền và dải chuyển tiếp trên Oxford-IIIT Pet.
Bài báo	PIDNet của Xu, Xiong và Bhattacharyya, IEEE/CVF CVPR 2023 [1].
Đối chứng	ResNet18 dùng chung kiến trúc và giám sát biên. Hai biến thể lần lượt dùng tỷ lệ 50/50 và hệ số trộn theo vị trí.
Phép đo	mIoU, macro-Dice và IoU theo vùng trên 3.669 ảnh test. Mỗi biến thể chạy ba seed.
Kết quả chính	mIoU của trộn cố định và trộn theo biên lần lượt là 78,00% và 77,82%.
Đối chiếu	Mức thay đổi mIoU trong các phép ablation công bố và thí nghiệm A2.

Mục lục

Tóm tắt **i**

Tổng quan báo cáo **ii**

1 Giới thiệu **1**

1.1 Bài báo và vấn đề nghiên cứu 1

1.2 Mục tiêu và giả thuyết thực nghiệm 1

2 Phân tích PIDNet **3**

2.1 Từ mạng hai nhánh đến vấn đề overshoot 3

2.2 Cơ sở PID và ý nghĩa của nhánh D 3

2.2.1 PID truyền thống 3

2.2.2 Phép tương tự trong CNN và giới hạn của lập luận 4

2.3 Kiến trúc ba nhánh và trao đổi thông tin 5

2.3.1 Pag: tiếp nhận ngữ cảnh có chọn lọc 6

2.3.2 PAPPM: tổng hợp ngữ cảnh với độ trễ thấp 6

2.3.3 Bag và Light-Bag: dùng biên để điều tiết fusion 7

2.4 Boundary supervision và hàm mục tiêu 8

2.5 Thí nghiệm và mức đóng góp của paper 9

2.5.1 Giao thức và kết quả chính 9

2.5.2 Ablation cho thấy điều gì? 9

2.6 Liên hệ với thiết kế thực nghiệm A2 10

3 Dữ liệu và thiết lập thực nghiệm **11**

3.1 Dữ liệu và phân tích khám phá 11

3.2 Cài đặt và giao thức đánh giá 12

3.2.1 Tiền xử lý 12

3.2.2 Hai biến thể có cùng cấu trúc 12

3.2.3 Huấn luyện 13

3.2.4 Chọn checkpoint và chỉ số đánh giá 13

4 Kết quả thực nghiệm **15**

4.1 So sánh các biến thể 15

4.1.1 Độ chính xác theo vùng 17

4.1.2 Tín hiệu biên và trường hợp sai 17

4.1.3 Chi phí huấn luyện 18

4.2 Đối chiếu với kết quả công bố 18

5 Kết luận và giới hạn **19**

Danh sách hình vẽ

2.1 Phép tương tự giữa PID và mạng ba nhánh; phần dưới minh họa độ nhạy với ngữ cảnh và dự đoán của từng luồng DDRNet. Trích Hình 3 của Xu và cộng sự, CVPR 2023 [1]. 4

2.2 Kiến trúc PIDNet. P giữ feature map độ phân giải cao; I tổng hợp ngữ cảnh; D học thông tin biên. S-Head và B-Head là các đầu ngữ nghĩa và biên. Các đường nét đứt phục vụ loss khi train. Trích Hình 4 của Xu và cộng sự [1]. 5

2.3 Pag dùng tương đồng giữa đặc trưng P và I để điều chỉnh lateral fusion. Trích Hình 5 của Xu và cộng sự [1]. 7

2.4 Bag (trái) và Light-Bag (phải) kết hợp P và I bằng tín hiệu D. Các ô màu minh họa vùng bên trong vật thể và vùng biên. Trích Hình 7 của Xu và cộng sự [1]. 7

3.1 Tỷ lệ điểm ảnh theo nhãn và số ảnh theo giống ở tập train và validation. Tỷ lệ pixel được tính sau khi đưa ảnh về lưới thực nghiệm và bỏ vùng padding. 11

3.2 Bốn ảnh validation và trimap tương ứng. Xanh lục là vật thể, xanh đậm là nền, vàng là dải chuyển tiếp và xám nhạt là vùng padding. Ảnh và trimap từ Oxford-IIIT Pet [5]. 12

4.1 Loss huấn luyện và mIoU trên tập validation theo epoch của sáu lượt chạy. Màu thể hiện biến thể, kiểu nét phân biệt seed; mỗi đường là một lượt thực nghiệm. 15

4.2 Bốn ảnh test tại seed 42, lần lượt gồm ảnh RGB, trimap, dự đoán trộn cố định và dự đoán trộn theo biên. Xanh lục là vật thể, xanh đậm là nền, vàng là dải chuyển tiếp. Ảnh và trimap từ Oxford-IIIT Pet [5]. 16

4.3 Confusion matrix theo pixel, gộp ba seed của mỗi biến thể. Hàng là nhãn thực, cột là nhãn dự đoán; tỷ lệ được chuẩn hóa theo từng hàng. 16

Danh sách bảng

2.1 Kết quả công bố trong Bảng 5–7 của PIDNet [1]. CamVid dùng Cityscapes pretraining. PASCAL Context dùng multi-scale và flip inference. 9

2.2 Quan hệ giữa phương pháp gốc và pipeline được đánh giá. 10

3.1 Hai biến thể cùng số tham số, trọng số khởi tạo và giao thức huấn luyện. 13

4.1 Kết quả trên tập test theo phần trăm, trình bày trung bình và độ lệch chuẩn mẫu qua ba seed. 15

4.2 Chi phí của 12 epoch và kết quả trên tập validation. Epoch theo thứ tự seed 42, 43, 44. Thời gian gồm tải batch và cập nhật trọng số. Mức cấp phát GPU cực đại bao gồm lượt đánh giá trên tập validation. 15

4.3 Đối chiếu tác động của phép trộn trong bài báo gốc [1] và A2. Đpt là điểm phần trăm. Giá trị A2 là trung bình qua ba seed, chênh lệch tính trước khi làm tròn. 18

Chương 1

Giới thiệu

1.1 Bài báo và vấn đề nghiên cứu

Báo cáo phân tích *PIDNet: A Real-Time Semantic Segmentation Network Inspired by PID Controllers* của Jiacong Xu, Zixiang Xiong và Shankar P. Bhattacharyya, công bố tại *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) 2023*, tr. 19529–19539 [1]. Bài báo có bản PDF tại CVF, bản toàn văn trên arXiv và mã nguồn chính thức. Chủ đề được chọn là semantic segmentation, với trọng tâm là cách kết hợp thông tin chi tiết và ngữ cảnh tại biên vật thể.

Trong semantic segmentation, mỗi pixel được gán một nhãn lớp. Một mô hình cần nhận ra vật thể dựa trên ngữ cảnh đủ rộng, đồng thời giữ được vị trí của các đường viền và vật thể nhỏ. Hai yêu cầu này tạo ra sự đánh đổi: downsampling giúp giảm chi phí và mở rộng receptive field, nhưng làm mất chi tiết không gian; duy trì feature map độ phân giải cao giúp định vị tốt hơn nhưng tốn bộ nhớ và tính toán. Sự đánh đổi đặc biệt rõ khi hệ thống phải xử lý ảnh theo thời gian thực.

PIDNet xuất phát từ một hạn chế của các mạng hai nhánh như BiSeNet và DDRNet: đặc trưng chi tiết có thể bị ngữ cảnh lân cận lấn át ngay tại bước fusion. Đóng góp của paper là tổ chức lại việc xử lý thành ba nhánh P, I và D, lấy cảm hứng từ bộ điều khiển PID; nhánh D học thông tin biên để hướng dẫn fusion giữa P và I. Các module Pag, PAPPM và Bag giúp thực hiện ý tưởng này với chi phí phù hợp cho real-time segmentation. Giá trị của thiết kế nằm ở sự phối hợp giữa kiến trúc, trao đổi thông tin và giám sát biên, thay vì chỉ bổ sung một đầu dự đoán biên.

1.2 Mục tiêu và giả thuyết thực nghiệm

Phần thực nghiệm khảo sát cơ chế boundary-guided fusion của Bag trên Oxford-IIIT Pet. Hai biến thể ResNet18 có cùng encoder, segmentation head và boundary supervision; khác biệt duy nhất trong phép fusion là hệ số cố định 0,5 hoặc hệ số phụ thuộc vị trí lấy từ boundary head. Đối chứng này kiểm tra liệu đưa tín hiệu biên đã học vào phép fusion có cải thiện phân đoạn khi lợi ích của boundary supervision đã có ở cả hai mô hình.

Giả thuyết là vùng chuyển tiếp cần nhiều thông tin chi tiết hơn vùng trong vật thể và nền. Nếu boundary head định vị đúng vùng này, một hệ số thích nghi có thể phân bổ đóng góp của hai luồng phù hợp hơn phép trung bình cố định. Tuy nhiên, tín hiệu biên

sai hoặc quá rộng cũng có thể làm giảm đóng góp của ngữ cảnh tại nơi vẫn cần ngữ nghĩa để phân loại. Vì vậy, báo cáo phân tích IoU của từng vùng cùng mIoU, Dice, confusion matrix và ảnh dự đoán, thay vì chỉ xét một chỉ số toàn ảnh.

Phần phân tích paper trình bày cơ sở PID, kiến trúc, các công thức fusion và loss, sau đó đối chiếu ablation của tác giả với thực nghiệm. Thiết kế ResNet18 khảo sát riêng quy tắc fusion; những khác biệt về nhánh D, Pag, context aggregation và nhãn biên được nêu khi diễn giải kết quả.

Chương 2

Phân tích PIDNet

2.1 Từ mạng hai nhánh đến vấn đề overshoot

Các mạng encoder–decoder mở rộng receptive field qua strided convolution hoặc pooling, rồi khôi phục độ phân giải bằng upsampling. Chi tiết đã mất ở encoder không thể được khôi phục chỉ bằng việc tăng kích thước feature map. Dilated convolution và các kiến trúc nhiều độ phân giải giảm bớt vấn đề này, nhưng chi phí thực tế còn phụ thuộc cách truy cập bộ nhớ và khả năng thực thi trên GPU.

BiSeNet [2] tách một luồng giữ chi tiết không gian khỏi một luồng học ngữ cảnh. DDRNet [3] duy trì hai độ phân giải và tăng trao đổi thông tin giữa chúng. Cách tổ chức này giảm chi phí của việc giữ mọi tầng ở độ phân giải cao, nhưng chưa bảo đảm fusion cuối cùng giữ đúng biên. Tại mép một vật thể mảnh, receptive field rộng có thể chứa chủ yếu pixel nền. Nếu đặc trưng ngữ cảnh chiếm ưu thế, nhãn nền lan qua mép hoặc làm biến mất vật thể nhỏ, dù luồng chi tiết còn giữ được vị trí của nó.

Paper gọi hiện tượng trên là *overshoot*, liên hệ sự lan thông tin qua biên không gian với đáp ứng vượt mức trong điều khiển. Điểm cần giải quyết là phân bổ ảnh hưởng của ngữ cảnh theo vị trí: vùng trong vật thể cần ngữ nghĩa ổn định, còn vùng tiếp giáp cần giữ biến thiên cục bộ. Chỉ cộng thêm đặc trưng độ phân giải cao không trực tiếp giải quyết việc hai nguồn thông tin có thể mâu thuẫn tại cùng một pixel.

2.2 Cơ sở PID và ý nghĩa của nhánh D

2.2.1 PID truyền thống

Với sai số $e(t) = r(t) - y(t)$ giữa giá trị đặt và đầu ra hệ thống, dạng PID liên tục lý tưởng là

$$u(t) = K_P e(t) + K_I \int_0^t e(\tau)\, d\tau + K_D \frac{de(t)}{dt}. \tag{2.1}$$

Thành phần proportional phản ứng với sai số hiện tại; integral tích lũy sai số; derivative phản ứng với tốc độ thay đổi của sai số. Trong dạng rời rạc với chu kỳ lấy mẫu hấp thụ

vào các hệ số, công thức tương ứng là

$$u[n] = k_p e[n] + k_i \sum_{j=0}^{n} e[j] + k_d\big(e[n] - e[n-1]\big). \tag{2.2}$$

Công thức (1) của paper chỉ gồm hai hạng P và I; hạng D trong Hình 3 của paper hoàn thiện biểu thức (2.2). Khi sai số giảm, hạng $e[n] - e[n-1]$ có thể âm, bù lại phần tích lũy vẫn còn lớn. Đây là trực giác về tác dụng giảm overshoot; mức đáp ứng cụ thể còn phụ thuộc hệ được điều khiển và các hệ số.

Với điều kiện đầu bằng 0, hàm truyền rời rạc và đáp ứng trên đường tròn đơn vị là

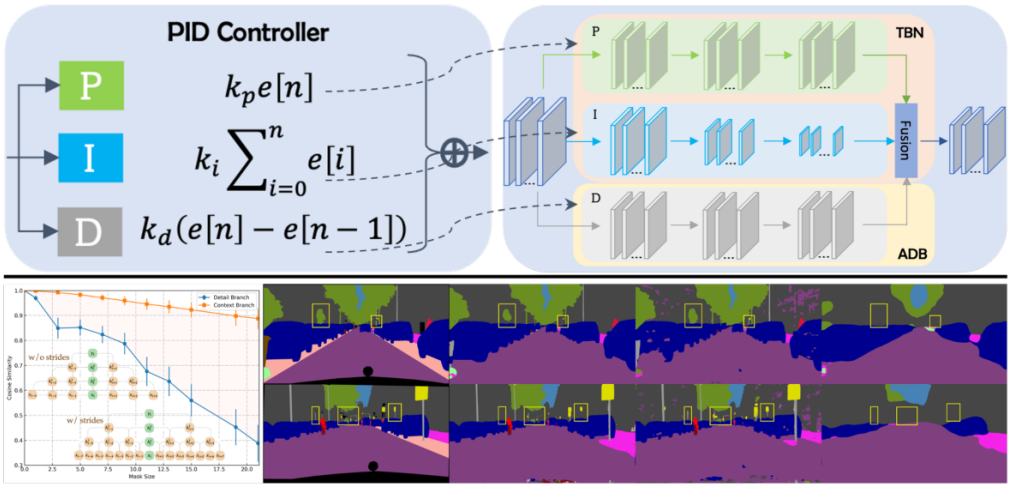
$$C(z) = k_p + \frac{k_i}{1 - z^{-1}} + k_d(1 - z^{-1}), \tag{2.3}$$

$$C(e^{j\omega}) = k_p + \frac{k_i}{1 - e^{-j\omega}} + k_d(1 - e^{-j\omega}). \tag{2.4}$$

Biểu thức (2.4) tương ứng công thức (4) của paper. Với $0 < \omega \le \pi$, bỏ qua hệ số khuếch đại,

$$|H_I(e^{j\omega})| = \frac{1}{2|\sin(\omega/2)|}, \qquad |H_D(e^{j\omega})| = 2|\sin(\omega/2)|. \tag{2.5}$$

Khi ω tăng, gain của integral giảm còn gain của derivative tăng; proportional có gain không đổi. Tác giả dùng quan sát này để liên hệ ngữ cảnh tổng hợp với thành phần tần số thấp và tín hiệu chuyển lớp với thành phần tần số cao. Trong ảnh, tần số ở đây mô tả biến thiên theo không gian, không phải diễn biến theo thời gian của chuỗi ảnh.



Hình 2.1: Phép tương tự giữa PID và mạng ba nhánh; phần dưới minh họa độ nhạy với ngữ cảnh và dự đoán của từng luồng DDRNet. Trích Hình 3 của Xu và cộng sự, CVPR 2023 [1].

2.2.2 Phép tương tự trong CNN và giới hạn của lập luận

Paper xét hai CNN một chiều gồm ba tầng, bỏ BatchNorm và ReLU, để phân tích ảnh hưởng của receptive field. Viết gọn công thức (2)–(3) của paper dưới dạng tổng, với x là

tín hiệu đầu vào,

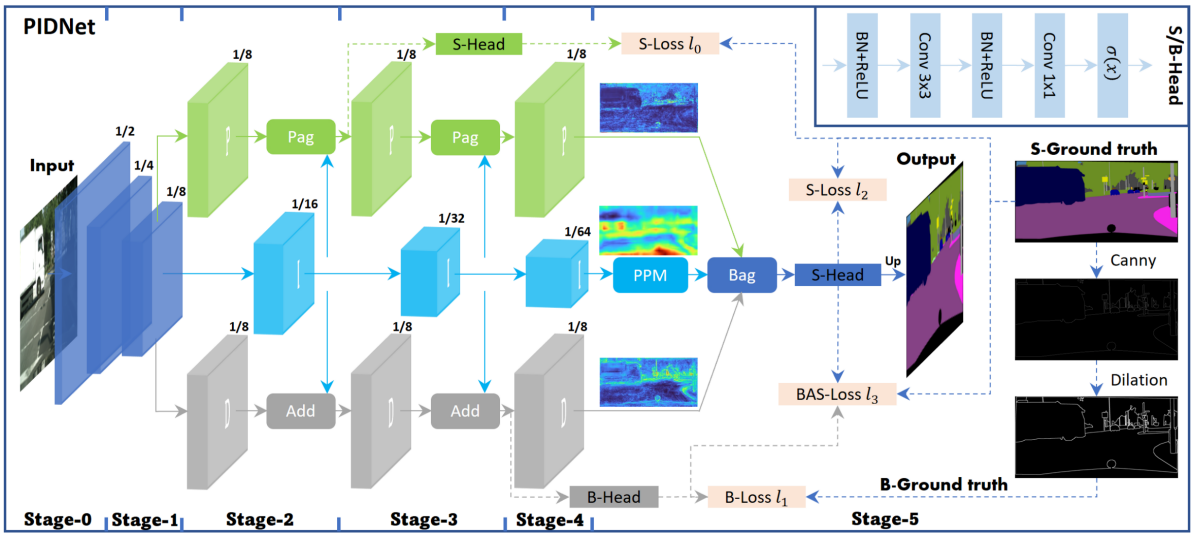
$$O_{\text{detail}}[i] = \sum_{r=-3}^{3} K^{D}_{i+r} x[i+r], \tag{2.6}$$

$$O_{\text{context}}[i] = \sum_{r=-7}^{7} K^{C}_{i+r} x[i+r]. \tag{2.7}$$

Các hệ số K là tổ hợp của trọng số convolution qua ba tầng; ký hiệu D trong K^D chỉ *detail*, khác với nhánh derivative của PIDNet. Trong ví dụ này, luồng detail phụ thuộc vào lân cận hẹp hơn, còn luồng context nhận thông tin từ vùng rộng hơn. Đây là cơ sở để tác giả liên hệ detail với P và context với I.

Lập luận trên giải thích một xu hướng thiết kế, nhưng không chứng minh mọi CNN hai nhánh đều là bộ điều khiển PI. Trọng số convolution được học có thể mang dấu khác nhau; BatchNorm, ReLU và residual connection còn làm thay đổi đáp ứng. PIDNet cũng không duy trì trạng thái tích lũy sai số theo thời gian hay tối ưu các gain k_p, k_i, k_d của một vòng điều khiển. Ý tưởng PID được chuyển thành việc học ba loại thông tin bổ sung nhau trong miền không gian. Nhánh D học *semantic boundary*, vì biến thiên màu hoặc texture lớn chưa chắc là nơi nhãn lớp thay đổi.

2.3 Kiến trúc ba nhánh và trao đổi thông tin



Hình 2.2: Kiến trúc PIDNet. P giữ feature map độ phân giải cao; I tổng hợp ngữ cảnh; D học thông tin biên. S-Head và B-Head là các đầu ngữ nghĩa và biên. Các đường nét đứt phục vụ loss khi train. Trích Hình 4 của Xu và cộng sự [1].

Hình 2.2 cho thấy ba nhánh dùng chung các tầng đầu rồi đảm nhiệm những vai trò khác nhau:

- **P (proportional):** duy trì feature map ở khoảng 1/8 kích thước đầu vào để giữ

vị trí, hình dạng và chi tiết của vật thể. Độ sâu ở mức vừa phải nhằm hạn chế chi phí trên lưới còn tương đối lớn.

- **I (integral):** tiếp tục downsampling qua các mức 1/16, 1/32 và 1/64, sử dụng nhiều tầng hơn và context aggregation để nhận ra vật thể từ vùng quan sát rộng.
- **D (derivative):** là nhánh nông học các vùng chuyển lớp. Boundary supervision giúp nhánh này tập trung vào biên ngữ nghĩa, thay vì đáp ứng với mọi cạnh ảnh.

Nhánh I truyền thông tin sang D bằng phép cộng và sang P bằng Pag. Ở cuối mạng, context feature được upsampling về lưới phù hợp rồi kết hợp với P dưới sự hướng dẫn của D qua Bag. Vì P và D ít tầng hơn, thông tin từ I giúp chúng phân biệt đường viền vật thể với texture bên trong vật thể. Ngược lại, giữ luồng chi tiết riêng hạn chế việc ngữ cảnh quyết định nhãn ở mọi vị trí.

PIDNet-S/M/L tăng năng lực bằng cách thay đổi độ sâu và số kênh. Các auxiliary head giúp tối ưu khi train và được bỏ ở inference; feature của nhánh D vẫn cần để tính Bag. Vì vậy, bỏ boundary prediction head khi inference không đồng nghĩa bỏ nhánh D khỏi mô hình.

2.3.1 Pag: tiếp nhận ngữ cảnh có chọn lọc

Với $\mathbf{p}$ và $\mathbf{i}$ là vector đặc trưng của P và I tại cùng vị trí sau khi căn chỉnh kích thước, Pag dùng hai phép chiếu để tính mức tương đồng:

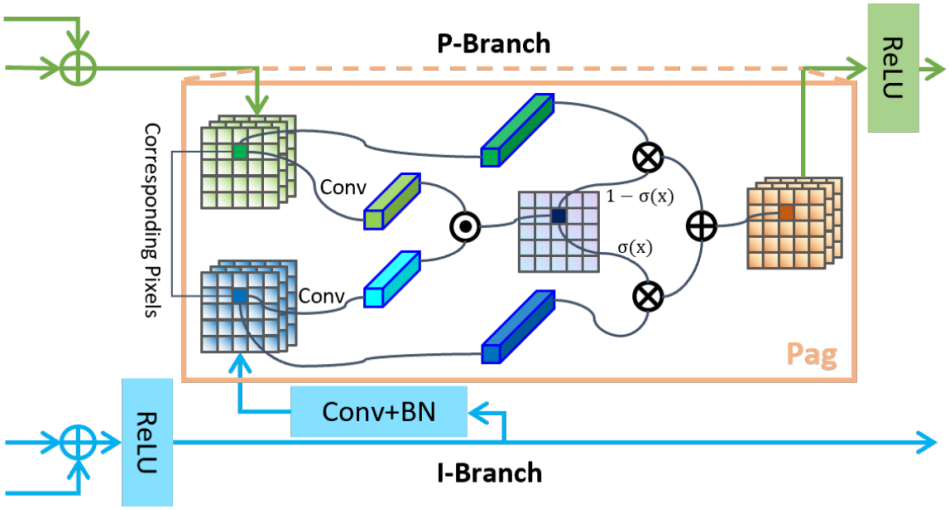
$$\alpha = \mathrm{sigmoid}\big(f_p(\mathbf{p})^\top f_i(\mathbf{i})\big)\,, \tag{2.8}$$

$$\mathbf{y}_{\mathrm{Pag}} = \alpha\mathbf{i} + (1-\alpha)\mathbf{p}. \tag{2.9}$$

Đây là công thức (7)–(8) của paper. Khi α lớn, P tiếp nhận nhiều ngữ cảnh hơn; khi hai biểu diễn không phù hợp, tỷ trọng của P được giữ cao hơn. Pag được áp dụng trước fusion cuối, nên mục tiêu là tránh làm mất chi tiết ngay trong quá trình trao đổi thông tin. Điểm sigmoid là hệ số attention được học, không mặc nhiên là xác suất đã được calibration.

2.3.2 PAPPM: tổng hợp ngữ cảnh với độ trễ thấp

Context aggregation phải thu nhận cả thông tin cục bộ và toàn ảnh. DAPPM kết hợp nhiều mức pooling theo chuỗi, nên một số nhánh phải chờ đầu ra của nhánh trước. PAPPM thay các phụ thuộc nối tiếp bằng cấu trúc có thể xử lý song song và giảm số kênh ở mỗi mức từ 128 xuống 96. PIDNet-S/M dùng PAPPM để phù hợp mục tiêu tốc độ, còn PIDNet-L giữ DAPPM với số kênh điều chỉnh. Điểm thay đổi nằm ở cả cấu trúc phụ thuộc tính toán và độ rộng đặc trưng, không chỉ số mức pooling.



Hình 2.3: Pag dùng tương đồng giữa đặc trưng P và I để điều chỉnh lateral fusion. Trích Hình 5 của Xu và cộng sự [1].

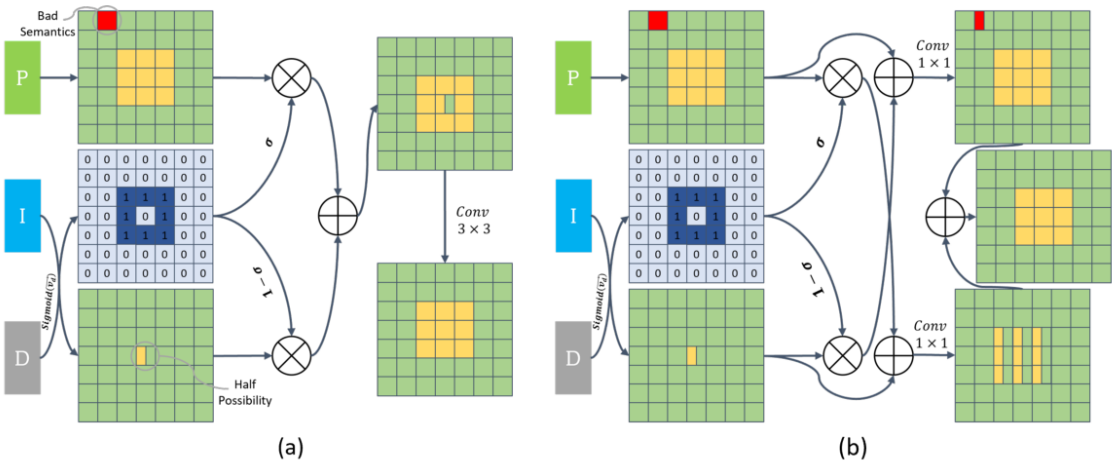
2.3.3 Bag và Light-Bag: dùng biên để điều tiết fusion

Gọi **d** là vector đặc trưng nhánh D. Công thức (9)–(10) của paper là

$$\boldsymbol{\beta} = \mathrm{sigmoid}(\mathbf{d}), \tag{2.10}$$

$$\mathbf{y}_{\mathrm{Bag}} = f_{\mathrm{out}}((1-\boldsymbol{\beta}) \odot \mathbf{i} + \boldsymbol{\beta} \odot \mathbf{p})\,. \tag{2.11}$$

Phép $\odot$ là nhân theo phần tử; f_{out} kết hợp convolution, BatchNorm và ReLU. Khác với Pag, hệ số Bag lớn làm tăng đóng góp của P. Vai trò này phù hợp vùng biên: biểu diễn I có thể đã trộn ngữ nghĩa của hai phía, còn P giữ vị trí rõ hơn. Trong vùng đồng nhất, tăng đóng góp của I giúp tránh phân mảnh do texture. $\boldsymbol{\beta}$ được tính từ *feature vector* của D, có thể khác theo kênh; nó không phải xác suất vô hướng của auxiliary boundary head.



Hình 2.4: Bag (trái) và Light-Bag (phải) kết hợp P và I bằng tín hiệu D. Các ô màu minh họa vùng bên trong vật thể và vùng biên. Trích Hình 7 của Xu và cộng sự [1].

Light-Bag thay convolution 3×3 bằng hai luồng convolution 1×1, với công thức (11):

$$\begin{aligned}\mathbf{y}_{\text{Light}} = f_p((1-\boldsymbol{\beta}) \odot \mathbf{i} + \mathbf{p}) \\ + f_i(\boldsymbol{\beta} \odot \mathbf{p} + \mathbf{i})\,.\end{aligned} \tag{2.12}$$

Mỗi luồng giữ một thành phần trực tiếp và nhận thêm thành phần được điều tiết từ luồng kia. Do còn hai phép biến đổi học được và phép cộng đầu ra, Light-Bag không đơn thuần là trung bình có trọng số của hai vector. Thiết kế này cho phép giảm chi phí convolution trong khi vẫn dùng biên để điều chỉnh sự phối hợp detail–context.

2.4 Boundary supervision và hàm mục tiêu

PIDNet phối hợp bốn loss:

$$L_{\text{PIDNet}} = 0{,}4\ell_0 + 20\ell_1 + \ell_2 + \ell_3. \tag{2.13}$$

Theo công thức (6) và Hình 4 của paper, ℓ_0 là auxiliary semantic cross-entropy sau Pag đầu tiên; ℓ_1 là weighted boundary BCE; ℓ_2 là semantic cross-entropy ở đầu ra chính; ℓ_3 là boundary-awareness cross-entropy (BAS-Loss). Auxiliary semantic loss tạo tín hiệu tối ưu cho P ở tầng trung gian, còn weighted BCE xử lý sự chênh lệch số pixel biên và không biên. Nhãn biên của paper được tạo từ nhãn segmentation bằng Canny rồi dilation, như Hình 2.2.

Với b_i là điểm sigmoid của boundary head tại pixel i, $s_{i,c}$ là nhãn one-hot và $\hat{s}_{i,c}$ là xác suất dự đoán lớp c, công thức (5) của paper là

$$\ell_3 = -\sum_{i,c} \mathbf{1}[b_i > 0{,}8]\, s_{i,c} \log \hat{s}_{i,c}. \tag{2.14}$$

Loss này nhấn mạnh semantic error tại những vị trí boundary head có đáp ứng cao. Ngưỡng 0,8 chọn vị trí đóng góp vào BAS-Loss; Bag vẫn dùng sigmoid liên tục và không áp dụng ngưỡng này cho phép fusion. Hai tác dụng vì vậy khác nhau: boundary BCE học cách phát hiện biên, BAS-Loss tăng giám sát ngữ nghĩa ở vùng được chọn, còn Bag dùng boundary feature để thay đổi đường truyền đặc trưng.

Một giới hạn của cơ chế là biên dự đoán sai có thể ảnh hưởng cả vị trí được nhấn mạnh trong loss và hệ số fusion. Texture lông hoặc nền có cạnh mạnh không đồng nghĩa semantic boundary. Ngược lại, biên mờ nhưng có đổi nhãn vẫn cần được nhận ra. Do đó, chất lượng nhãn và tương quan giữa detail–context quyết định mức hữu ích của D, chứ sự tồn tại của một boundary head không tự bảo đảm tăng mIoU.

2.5 Thí nghiệm và mức đóng góp của paper

2.5.1 Giao thức và kết quả chính

Paper đánh giá Cityscapes, CamVid và PASCAL Context với mIoU. Mô hình dùng ImageNet pretraining trước segmentation; Cityscapes có lịch 484 epoch, random scaling trong $[0{,}5; 2{,}0]$ và crop 1024×1024. Trước khi đánh giá test Cityscapes/CamVid, tác giả train trên cả train và validation. FPS được đo trên một RTX 3090, batch size 1, sau khi gộp BatchNorm vào convolution. Các điều kiện này cần được giữ khi diễn giải tuyên bố về tốc độ.

Mô hình	Dataset / tập	mIoU (%)	FPS
PIDNet-S	Cityscapes test	78,6	93,2
PIDNet-M	Cityscapes test	80,1	39,8
PIDNet-L	Cityscapes test	80,6	31,1
PIDNet-S	CamVid test	80,1	153,7
PIDNet-L	PASCAL Context validation, 59 lớp	51,9	–

Bảng 2.1: Kết quả công bố trong Bảng 5–7 của PIDNet [1]. CamVid dùng Cityscapes pretraining. PASCAL Context dùng multi-scale và flip inference.

Trong phạm vi các mô hình được tác giả so sánh tại thời điểm công bố, PIDNet cải thiện đánh đổi mIoU–FPS của real-time segmentation. PIDNet-L tăng accuracy so với PIDNet-S nhưng giảm tốc độ rõ rệt; cấu hình lớn không thay thế cấu hình nhỏ cho mọi ứng dụng. Trên PASCAL Context, PIDNet-L đạt 51,9% mIoU ở giao thức 59 lớp, thấp hơn 54,0% của HRNet-W48 trong cùng bảng. Kết quả này giới hạn tuyên bố về ưu thế vào bối cảnh real-time và điều kiện so sánh cụ thể.

2.5.2 Ablation cho thấy điều gì?

Bảng 1 của paper thêm đồng thời auxiliary derivative branch và Bag vào các mạng hai nhánh. BiSeNet–ResNet18 tăng từ 75,4 lên 76,7% mIoU, còn DDRNet-23 tăng từ 79,5 lên 80,0%; FPS tương ứng giảm từ 63,2 xuống 52,1 và từ 51,4 xuống 39,2. Đây là bằng chứng cho một gói thay đổi gồm nhánh biên và fusion, chưa tách riêng lợi ích của Bag khỏi boundary supervision.

Bảng 3 giữ PAPPM trong PIDNet-S, thay phép cộng bằng Light-Bag: mIoU tăng từ 78,4 lên 78,8%, FPS giảm từ 97,8 xuống 93,2. Khi giữ Light-Bag và thay DAPPM bằng PAPPM, mIoU giữ ở 78,8% còn tốc độ tăng từ 83,7 lên 93,2 FPS. Hai phép so sánh cho thấy tác giả xử lý đồng thời chất lượng fusion và chi phí context aggregation.

Bảng 2 trên PIDNet-L cho thấy cấu hình pretrained dùng Pag và Bag đạt 80,9% mIoU, so với 80,7% khi cả lateral connection và fusion đều dùng phép cộng. Hai cấu hình chỉ thay một trong hai thành phần đều đạt 80,5%. Kết quả ủng hộ việc duy trì cơ chế chọn

lọc nhất quán trong trao đổi và fusion; lợi ích của một module còn phụ thuộc vào phần còn lại của mạng.

OHEM (Online Hard Example Mining) ưu tiên các pixel khó khi tối ưu semantic loss. Bảng 4 lần lượt bổ sung auxiliary semantic loss, boundary loss, BAS-Loss và OHEM trên PIDNet-L. mIoU tăng theo chuỗi 78,6; 78,8; 79,9; 80,5 và 80,9%. Bước thêm boundary loss tạo mức tăng 1,1 điểm phần trăm trong chuỗi này. Như vậy, kết quả cuối không chỉ đến từ biểu thức Bag: cách giám sát, khai thác ví dụ khó và tương tác giữa các module cũng có ảnh hưởng. Các bước được thêm tuần tự nên mức tăng phụ thuộc cấu hình đã có trước đó.

2.6 Liên hệ với thiết kế thực nghiệm A2

Thực nghiệm giữ ý tưởng của công thức (2.11) nhưng dùng một boundary head vô hướng trên feature nông của ResNet18. Bảng 2.2 xác định các khác biệt chi phối cách đọc kết quả.

Thành phần	PIDNet	Thực nghiệm A2
Detail và context	Ba nhánh chuyên biệt; P/D khoảng stride 8, I xuống stride 64.	Hai feature của một ResNet18 ở stride 4 và 32.
Tín hiệu fusion	Sigmoid của feature vector nhánh D.	Sigmoid của một logit biên tại mỗi vị trí, dùng chung hệ số cho mọi kênh.
Trao đổi / context	Pag và PAPPM/DAPPM.	Chiếu kênh và upsampling; không có các module này.
Boundary target	Biên từ semantic mask qua Canny và dilation.	Vùng chưa phân loại có sẵn trong trimap.
Loss	Bốn thành phần và OHEM trong cấu hình cuối.	CE ba vùng cộng balanced boundary BCE.
Đối chứng	Các ablation theo module và loss.	Giữ boundary supervision, chỉ đổi hệ số fusion.

Bảng 2.2: Quan hệ giữa phương pháp gốc và pipeline được đánh giá.

Đối chứng này cô lập vai trò của việc *sử dụng* bản đồ biên trong fusion khi cả hai mô hình đã *học* từ biên. Nó không kiểm tra đầy đủ ưu thế của kiến trúc PIDNet. Nếu kết quả không tăng, khả năng phân biệt biên, chất lượng hai luồng đặc trưng và sự phù hợp của trimap đều là những yếu tố cần xem xét. Các giải thích này được đối chiếu với IoU từng vùng, điểm boundary head và failure case ở phần kết quả; chưa thể tách tác động của từng yếu tố khi chưa có ablation tương ứng.

Chương 3

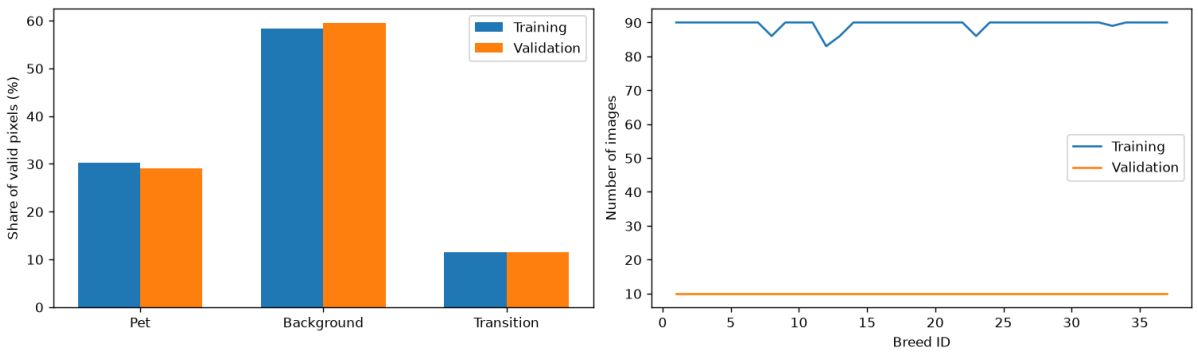
Dữ liệu và thiết lập thực nghiệm

3.1 Dữ liệu và phân tích khám phá

Oxford-IIIT Pet có 7.349 ảnh với 37 giống chó và mèo, kích thước và tư thế đa dạng [4, 5]. Mỗi ảnh có trimap, trong đó giá trị 1 là vật thể, 2 là nền và 3 là vùng chưa phân loại. Báo cáo gọi nhãn 3 là *dải chuyển tiếp* và dùng nó làm tín hiệu gần đúng cho biên. Nhãn giống chỉ phục vụ việc chia tập. Dữ liệu được tải từ trang Visual Geometry Group, University of Oxford. Bản gốc lưu ảnh JPG trong `images/`, trimap PNG trong `annotations/trimaps/` và danh sách ảnh cùng nhãn giống trong `annotations/trainval.txt` và `annotations/test.txt`.

Từ 3.680 ảnh trong tập train/validation chính thức, chọn 10 ảnh mỗi giống làm tập validation bằng seed 2026. Phần còn lại gồm 3.310 ảnh dùng để cập nhật trọng số. Tập test chính thức gồm 3.669 ảnh được giữ riêng. Đối chiếu kích thước và pixel RGB giải mã không tìm thấy ảnh trùng chính xác giữa các tập; phép đối chiếu này chỉ phát hiện ảnh trùng pixel.

Trung vị chiều rộng và chiều cao ảnh gốc lần lượt là 500 và 375 pixel. Trên lưới dùng để huấn luyện, vật thể chiếm 30,23% điểm ảnh có nhãn, nền chiếm 58,36% và dải chuyển tiếp chiếm 11,41%. Tỷ lệ dải chuyển tiếp theo từng ảnh có trung vị 10,91% và khoảng tứ phân vị 8,64–13,77%. BCE cân bằng duy trì đóng góp của dải chuyển tiếp vào loss phụ dù vùng này chiếm ít pixel hơn.



Hình 3.1: Tỷ lệ điểm ảnh theo nhãn và số ảnh theo giống ở tập train và validation. Tỷ lệ pixel được tính sau khi đưa ảnh về lưới thực nghiệm và bỏ vùng padding.



Hình 3.2: Bốn ảnh validation và trimap tương ứng. Xanh lục là vật thể, xanh đậm là nền, vàng là dải chuyển tiếp và xám nhạt là vùng padding. Ảnh và trimap từ Oxford-IIIT Pet [5].

3.2 Cài đặt và giao thức đánh giá

3.2.1 Tiền xử lý

Ảnh được resize cạnh dài về 192 pixel, giữ aspect ratio rồi thêm padding bên phải hoặc phía dưới để tạo đầu vào 192×192. Ảnh RGB dùng bilinear interpolation; trimap dùng nearest-neighbor interpolation để giữ giá trị nhãn. Pixel padding được bỏ qua trong loss và metric. Tập train dùng shuffle và random horizontal flip đồng thời ảnh với mask, xác suất 0,5. Validation và test dùng phép biến đổi cố định. RGB normalization sử dụng mean và standard deviation ImageNet.

3.2.2 Hai biến thể có cùng cấu trúc

Hai mô hình dùng ResNet18 với trọng số pretrained ImageNet từ torchvision [6, 7]. Đầu phân loại của ResNet18 được bỏ. Đặc trưng nông lấy từ `layer1` ở stride 4 và đặc trưng sâu lấy từ `layer4` ở stride 32. Hai nhánh được chiếu về 64 kênh; đặc trưng sâu được upsampling về lưới đặc trưng nông. Một đầu dự đoán biên trên đặc trưng nông xuất một logit e tại mỗi vị trí.

Bộ phân loại điểm ảnh giống nhau ở hai biến thể. Logit của ba vùng được upsampling về lưới ảnh trước khi tính loss và lấy nhãn có logit lớn nhất. Thí nghiệm giữ phép trộn theo sigmoid của Bag, dùng một hệ số chung cho mọi kênh và một encoder ResNet18. Các khối Pag, PAPPM và nhánh D độc lập của PIDNet nằm ngoài cấu hình này. Đầu phụ và giám sát biên giống nhau ở hai biến thể, giúp cô lập việc đưa bản đồ biên vào phép trộn.

Biến thể	Phép trộn tại từng vị trí	Vai trò của đầu dự đoán biên
Trộn cố định	$0{,}5P + 0{,}5I$	Học bằng hàm mất mát phụ.
Trộn theo biên	$\sigma(e)P + (1-\sigma(e))I$	Học bằng hàm mất mát phụ và tham gia trộn đặc trưng.

Bảng 3.1: Hai biến thể cùng số tham số, trọng số khởi tạo và giao thức huấn luyện.

3.2.3 Huấn luyện

Với Ω là các điểm ảnh có nhãn, hàm mục tiêu là cross-entropy ba vùng cộng BCE cân bằng theo nhóm. Gọi Ω_b là dải chuyển tiếp, Ω_n là phần còn lại của Ω, và $\ell_{\mathrm{BCE}}(e, y)$ là BCE tính trực tiếp từ logit. Khi hai nhóm đều có điểm ảnh,

$$L = L_{\mathrm{CE}} + 0{,}25L_b, \quad L_b = \frac{1}{2|\Omega_b|}\sum_{i\in\Omega_b}\ell_{\mathrm{BCE}}(e_i, 1) + \frac{1}{2|\Omega_n|}\sum_{i\in\Omega_n}\ell_{\mathrm{BCE}}(e_i, 0).$$

Nếu một nhóm rỗng trong batch, đóng góp của nhóm đó bằng 0. Việc lấy trung bình riêng giúp dải chuyển tiếp vẫn đóng góp vào gradient dù chiếm ít điểm ảnh. Khác với loss có ngưỡng của PIDNet, thành phần CE ở đây luôn tính trên toàn bộ Ω. Tín hiệu biên của bản trộn theo biên còn nhận gradient qua loss chính vì phép trộn khả vi.

Mỗi biến thể chạy 12 epoch với ba seed 42, 43 và 44. Batch size là 32. AdamW dùng weight decay 10^{-4} và learning rate ban đầu 2×10^{-4} cho encoder, 10^{-3} cho các đầu mới. Learning rate giảm theo cosine sau mỗi epoch. Vòng lặp gọi trực tiếp forward, tính loss, lan truyền ngược và cập nhật trọng số. Sáu lượt huấn luyện được thực hiện trực tiếp từ notebook trên NVIDIA GeForce RTX 5090, BF16 autocast với loss tính bằng FP32, 4 worker tải dữ liệu và 4 luồng CPU của PyTorch. Môi trường gồm Python 3.12.12, PyTorch 2.10.0, torchvision 0.25.0 và CUDA 13.0.

3.2.4 Chọn checkpoint và chỉ số đánh giá

Mỗi lượt chọn checkpoint có mIoU trên tập validation cao nhất. Khi bằng nhau, chọn epoch sớm hơn. Tập test chỉ được đánh giá sau khi cả sáu lượt huấn luyện hoàn tất và giao thức đã cố định.

Với mỗi lớp c, lấy TP_c, FP_c và FN_c từ ma trận đếm điểm ảnh trên toàn tập. Các chỉ số được tính như sau:

$$\mathrm{IoU}_c = \frac{TP_c}{TP_c + FP_c + FN_c}, \qquad \mathrm{Dice}_c = \frac{2TP_c}{2TP_c + FP_c + FN_c}.$$

mIoU và macro-Dice là trung bình đều trên ba lớp. Cách gộp này cho dải chuyển tiếp cùng trọng số với các lớp lớn, dù số điểm ảnh mỗi lớp khác nhau. IoU riêng của dải chuyển tiếp dùng đúng nhãn trimap ở lưới 192×192 và phản ánh độ khớp vùng. Sai lệch

biên tính bằng khoảng cách trên ảnh gốc nằm ngoài phép đo.

Chương 4

Kết quả thực nghiệm

4.1 So sánh các biến thể

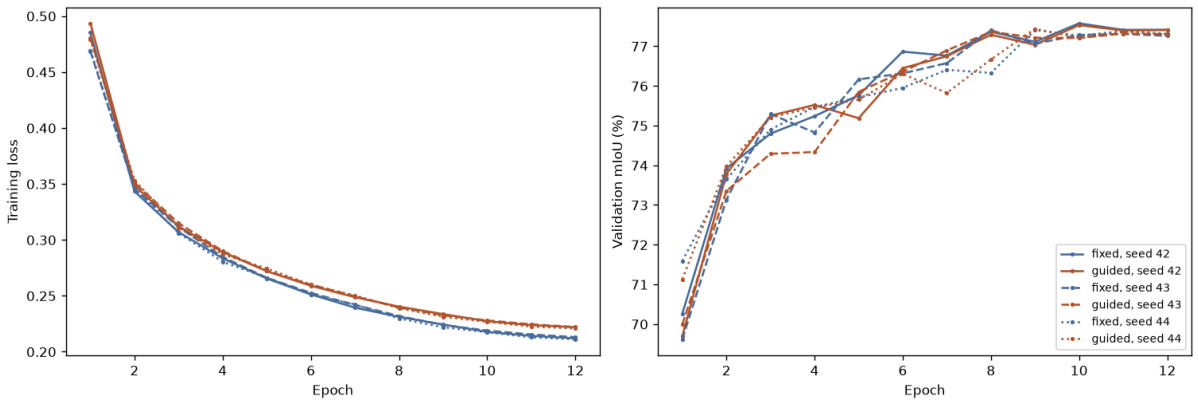
Biến thể	mIoU	Dice	IoU vật thể	IoU nền	IoU chuyển tiếp
Trộn cố định	$78{,}00 \pm 0{,}11$	$86{,}62 \pm 0{,}10$	$86{,}17 \pm 0{,}10$	$92{,}68 \pm 0{,}03$	$55{,}15 \pm 0{,}39$
Trộn theo biên	$77{,}82 \pm 0{,}03$	$86{,}51 \pm 0{,}02$	$85{,}89 \pm 0{,}15$	$92{,}55 \pm 0{,}05$	$55{,}02 \pm 0{,}13$

Bảng 4.1: Kết quả trên tập test theo phần trăm, trình bày trung bình và độ lệch chuẩn mẫu qua ba seed.

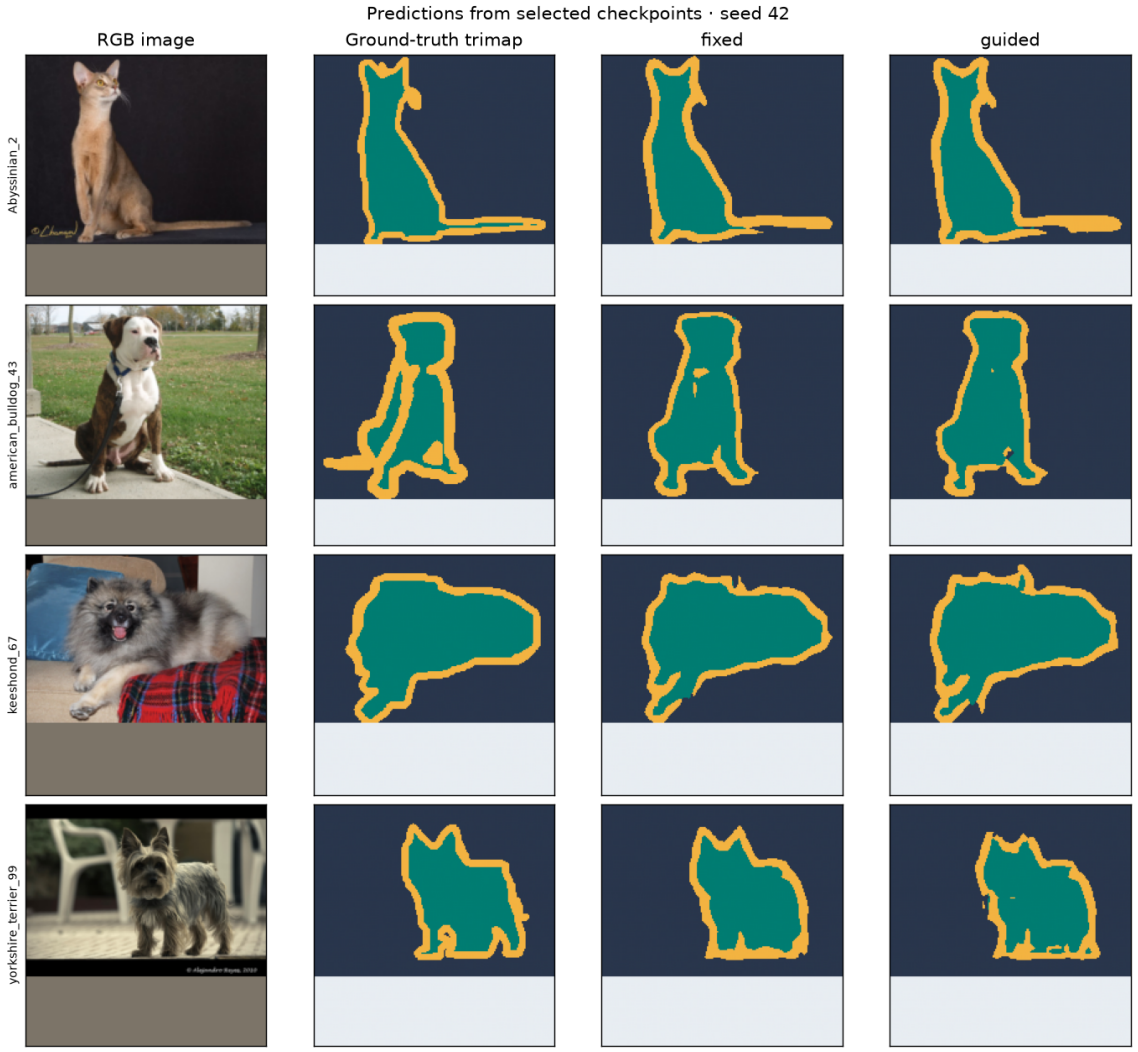
Biến thể	Validation mIoU (%)	Epoch được chọn	Thời gian (s)	Đỉnh (MiB)
Trộn cố định	$77{,}46 \pm 0{,}10$	10, 8, 9	$8{,}8 \pm 0{,}3$	$559{,}7 \pm 1{,}2$
Trộn theo biên	$77{,}44 \pm 0{,}08$	10, 8, 9	$8{,}6 \pm 0{,}0$	$572{,}2 \pm 0{,}0$

Bảng 4.2: Chi phí của 12 epoch và kết quả trên tập validation. Epoch theo thứ tự seed 42, 43, 44. Thời gian gồm tải batch và cập nhật trọng số. Mức cấp phát GPU cực đại bao gồm lượt đánh giá trên tập validation.

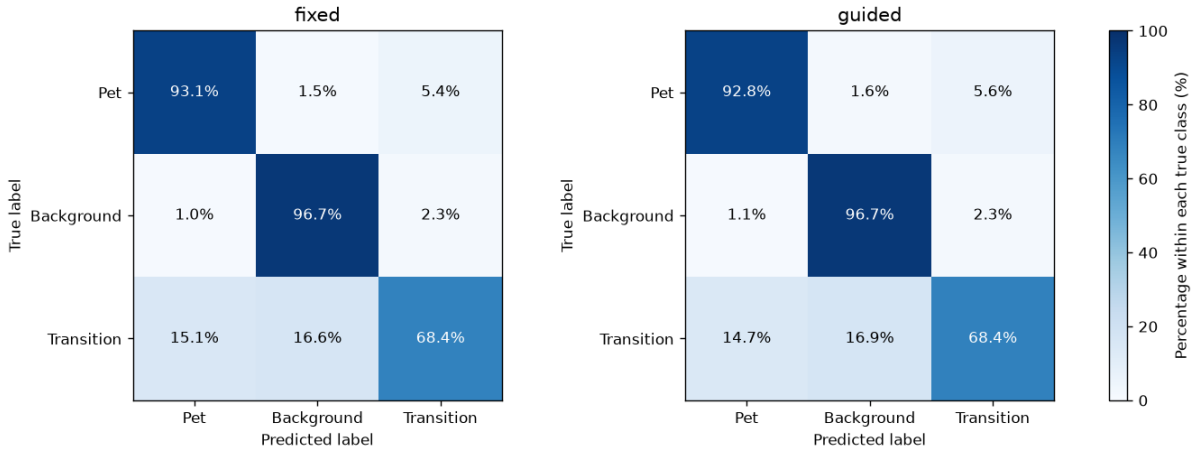
Cả hai biến thể chọn các epoch 10, 8 và 9 theo thứ tự seed 42, 43 và 44 trong lịch 12 epoch. Hình 4.1 cho thấy loss huấn luyện tiếp tục giảm đến cuối lịch, trong khi mIoU trên tập validation chững lại quanh 77% sau epoch 8. Các đường validation gần nhau nên mức khác biệt được xem thêm qua từng cặp seed và từng vùng trên tập test.



Hình 4.1: Loss huấn luyện và mIoU trên tập validation theo epoch của sáu lượt chạy. Màu thể hiện biến thể, kiểu nét phân biệt seed; mỗi đường là một lượt thực nghiệm.



Hình 4.2: Bốn ảnh test tại seed 42, lần lượt gồm ảnh RGB, trimap, dự đoán trộn cố định và dự đoán trộn theo biên. Xanh lục là vật thể, xanh đậm là nền, vàng là dải chuyển tiếp. Ảnh và trimap từ Oxford-IIIT Pet [5].



Hình 4.3: Confusion matrix theo pixel, gộp ba seed của mỗi biến thể. Hàng là nhãn thực, cột là nhãn dự đoán; tỷ lệ được chuẩn hóa theo từng hàng.

4.1.1 Độ chính xác theo vùng

Hai mô hình cùng có 11.302.116 tham số được huấn luyện. So với trộn cố định, trộn theo biên thay đổi mIoU $-0{,}18 \pm 0{,}12$ điểm phần trăm và macro-Dice $-0{,}11 \pm 0{,}09$ điểm phần trăm khi ghép theo seed. mIoU giảm ở cả ba cặp, lần lượt 0,16, 0,31 và 0,07 điểm phần trăm. Mức giảm IoU trung bình lớn nhất thuộc vùng vật thể (0,28 điểm phần trăm), tiếp đến là nền và dải chuyển tiếp (đều khoảng 0,13 điểm phần trăm). IoU dải chuyển tiếp tăng 0,11 điểm phần trăm ở seed 44, nhưng giảm ở hai seed còn lại. Ba cặp seed chỉ mô tả độ dao động trong thiết lập đã khảo sát.

Dải chuyển tiếp vẫn là vùng khó nhất, với IoU khoảng 55%, thấp hơn IoU vật thể khoảng 86% và IoU nền trên 92%. Confusion matrix ở Hình 4.3 cho thấy khoảng 68,4% pixel thực của dải chuyển tiếp được nhận đúng ở cả hai biến thể. Với bản cố định, 15,1% bị gán thành vật thể và 16,6% thành nền; các tỷ lệ tương ứng của bản theo biên là 14,7% và 16,9%. Tỷ lệ nhận đúng dải chuyển tiếp gần bằng nhau nhưng IoU vẫn có thể khác vì IoU tính thêm các pixel từ lớp khác bị dự đoán thành dải này. Chẳng hạn, tỷ lệ pixel vật thể bị gán nhãn chuyển tiếp tăng từ 5,4% lên 5,6% ở bản theo biên.

4.1.2 Tín hiệu biên và trường hợp sai

Điểm sigmoid của đầu biên sau upsampling ở bản theo biên đạt trung bình 0,772 trên dải chuyển tiếp, 0,311 trên vật thể và 0,182 trên nền. Bản cố định, chỉ dùng đầu này cho loss phụ, cũng phân biệt các vùng với các giá trị tương ứng 0,792, 0,297 và 0,180. Đầu phụ đã học tín hiệu phân biệt vùng chuyển tiếp, nhưng sự phân biệt này chưa chuyển thành lợi ích về IoU khi dùng trong phép trộn. BCE cân bằng đặt trọng số khác nhau cho hai nhóm pixel nên điểm sigmoid được diễn giải như mức đáp ứng của đầu biên.

Hình 4.2 dùng bốn vị trí cách đều trong danh sách test tại seed 42. Với `Abyssinian\_2`, cả hai mô hình nới dải chuyển tiếp ở phần đuôi; IoU dải này lần lượt là 64,5% và 66,5% cho bản cố định và bản theo biên. Với `yorkshire\_terrier\_99`, bản theo biên đưa thêm nhãn chuyển tiếp vào phần trong thân, trong khi IoU dải này giảm từ 54,8% xuống 48,9%. Các ví dụ cho thấy tác động của phép trộn thay đổi theo từng ảnh.

Đối chứng đã nhận đặc trưng chi tiết ở mọi vị trí và được huấn luyện bằng cùng loss biên. Lợi ích của cổng thích nghi vì vậy còn phụ thuộc vào khả năng phân biệt biên và thông tin bổ sung giữa hai nhánh. Với đặc trưng stride 4 và nhãn trimap có bề rộng, tín hiệu đó có thể thay đổi phép trộn cả ở nơi cần ngữ cảnh để phân biệt vật thể với nền. Thí nghiệm hiện tại chưa tách riêng ảnh hưởng của độ phân giải đặc trưng và cách tạo nhãn biên.

4.1.3 Chi phí huấn luyện

Trên RTX 5090, tổng thời gian cập nhật trọng số qua 12 epoch trung bình là $8{,}75 \pm 0{,}33$ giây với trộn cố định và $8{,}58 \pm 0{,}04$ giây với trộn theo biên. Khoảng thời gian này gồm tải batch và huấn luyện, không gồm lượt validation. Bộ nhớ GPU cấp phát cực đại, có tính cả validation, lần lượt là $559{,}7 \pm 1{,}2$ MiB và $572{,}2 \pm 0{,}0$ MiB. Chênh lệch thời gian nhỏ giữa sáu lượt chạy không xác lập lợi thế tốc độ của cơ chế trộn. Lượt thực nghiệm này chưa đo độ trễ suy luận nên không đối chiếu tốc độ trực tiếp với FPS của PIDNet.

4.2 Đối chiếu với kết quả công bố

Thí nghiệm	Điều kiện đối chứng	mIoU trước/sau (%)	Chênh lệch (đpt)
PIDNet, Bảng 1	Cityscapes (validation), BiSeNet–ResNet18, thêm nhánh biên và Bag.	75,4/76,7	+1,3
PIDNet, Bảng 3	Cityscapes, PIDNet-S giữ PAPPM, thay phép cộng bằng Light-Bag.	78,4/78,8	+0,4
A2	Oxford-IIIT Pet (test), ResNet18 giữ giám sát biên, thay trộn 50/50 bằng trộn theo biên.	78,00/77,82	−0,18

Bảng 4.3: Đối chiếu tác động của phép trộn trong bài báo gốc [1] và A2. Đpt là điểm phần trăm. Giá trị A2 là trung bình qua ba seed, chênh lệch tính trước khi làm tròn.

Bảng 4.3 đối chiếu chênh lệch mIoU trong từng giao thức. Hai thí nghiệm Cityscapes đo thay đổi khi thêm nhánh biên cùng Bag vào BiSeNet, hoặc thay phép cộng bằng Light-Bag trong PIDNet-S. Trên Oxford-IIIT Pet, cả hai biến thể ResNet18 đã học với cùng loss biên. Mức chênh lệch đo được ở A2 vì vậy mô tả tác dụng của việc đưa bản đồ biên vào phép trộn trong cấu hình đó. Dải chưa phân loại của trimap khác nhãn biên ngữ nghĩa của Cityscapes về độ dày và cách tạo nhãn. Khác biệt này, cùng với kiến trúc và độ phân giải, giới hạn phạm vi đối chiếu giữa hai nghiên cứu.

Chương 5

Kết luận và giới hạn

Trên đầy đủ Oxford-IIIT Pet với cùng encoder ResNet18 và cùng giám sát biên, trộn theo bản đồ biên đạt 77,82% mIoU, thấp hơn 78,00% của trộn cố định. Macro-Dice lần lượt là 86,51% và 86,62%. Cả ba cặp seed cùng cho mức giảm mIoU, trong khi thay đổi ở dải chuyển tiếp có hướng khác nhau theo seed và theo ảnh. Khả năng phân biệt vùng của đầu biên chưa đủ để bảo đảm lợi ích khi dùng trực tiếp làm cổng trộn. IoU theo vùng và confusion matrix cho thấy dải chuyển tiếp vẫn tập trung nhiều sai số.

Tập ảnh chủ yếu gồm một thú cưng nổi bật, nên kết quả chưa bao quát cảnh có nhiều lớp tiếp giáp hoặc vật thể nhỏ như Cityscapes. Dải chưa phân loại trong trimap có độ dày khác nhau giữa các ảnh. Đổi độ phân giải ảnh và mặt nạ cũng làm thay đổi độ dày biểu kiến của dải này. Ngoài ra, chỉ ba lượt khởi tạo cho mỗi biến thể được dùng để mô tả độ ổn định.

Các đường cong, confusion matrix và ảnh dự đoán được trích từ kết quả thực thi của notebook A2.

Phạm vi hỗ trợ của AI được trình bày trong `AI_USE_REPORT.md`.

Tài liệu tham khảo

[1] Jiacong Xu, Zixiang Xiong và Shankar P. Bhattacharyya. *PIDNet: A Real-Time Semantic Segmentation Network Inspired by PID Controllers*. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), tr. 19529–19539, 2023. DOI: 10.1109/CVPR52729.2023.01871. Bản tại CVF. Bản toàn văn trên arXiv.

[2] C. Yu, J. Wang, C. Peng, C. Gao, G. Yu và N. Sang. *BiSeNet: Bilateral Segmentation Network for Real-Time Semantic Segmentation*. European Conference on Computer Vision (ECCV), tr. 325–341, 2018. Bản toàn văn tại ECVA.

[3] Y. Hong, H. Pan, W. Sun và Y. Jia. *Deep Dual-resolution Networks for Real-time and Accurate Semantic Segmentation of Road Scenes*. arXiv:2101.06085, 2021. `https://arxiv.org/abs/2101.06085`.

[4] O. M. Parkhi, A. Vedaldi, A. Zisserman và C. V. Jawahar. *Cats and Dogs*. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), tr. 3498–3505, 2012. DOI: 10.1109/CVPR.2012.6248092.

[5] Visual Geometry Group, University of Oxford. *The Oxford-IIIT Pet Dataset*. `https://www.robots.ox.ac.uk/~vgg/data/pets/`.

[6] K. He, X. Zhang, S. Ren và J. Sun. *Deep Residual Learning for Image Recognition*. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), tr. 770–778, 2016. DOI: 10.1109/CVPR.2016.90.

[7] Torchvision. *ResNet18 and ImageNet weights*. `https://docs.pytorch.org/vision/stable/models/generated/torchvision.models.resnet18.html`.