ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



HỌC SÂU VÀ ỨNG DỤNG TRONG THỊ GIÁC MÁY TÍNH

Mã môn học CO5085

BÁO CÁO BÀI TẬP LỚN A2

Phân đoạn ảnh với phép trộn đặc trưng theo biên

Phân tích PIDNet và thực nghiệm trên Oxford-IIIT Pet

Học kỳ 261 · Năm học 2026–2027

Giảng viên	Lê Thành Sách, Nguyễn Quốc Minh
Sinh viên	Huỳnh Thành Đạt
Mã số sinh viên	2570161
Hình thức	Cá nhân

Thành phố Hồ Chí Minh, tháng 11 năm 2026

Tóm tắt

PIDNet dùng thông tin biên để điều chỉnh tỷ lệ trộn đặc trưng chi tiết và ngữ cảnh trong phân đoạn ảnh. Bài tập khảo sát cơ chế này trên Oxford-IIIT Pet bằng hai biến thể ResNet18 có cùng đầu dự đoán biên, lần lượt dùng hệ số trộn cố định và hệ số trộn theo vị trí. Qua ba hạt giống, biến thể cố định đạt $77{,}88 \pm 0{,}13\%$ mIoU, còn biến thể theo biên đạt $77{,}78 \pm 0{,}06\%$. Chênh lệch IoU của dải chuyển tiếp là $-0{,}16 \pm 0{,}27$ điểm phần trăm khi ghép theo hạt giống. Bản đồ biên làm nổi bật được một số cấu trúc mảnh, nhưng đáp ứng cũng xuất hiện trên hoa văn nền. Trong thiết lập này, dùng bản đồ đó làm cổng trộn chưa cải thiện chất lượng phân đoạn trung bình.

1 Câu hỏi nghiên cứu

Phân đoạn ảnh yêu cầu xác định vùng của từng điểm ảnh. Đặc trưng ở độ phân giải thấp giúp nhận ra vật thể trong ngữ cảnh chung, nhưng khi đưa trở lại lưới ảnh, chúng có thể làm mờ đường viền. Đặc trưng ở độ phân giải cao giữ nhiều chi tiết hơn và cũng dễ phản ứng với hoa văn của lông hoặc nền. Hai nguồn thông tin vì vậy có giá trị khác nhau ở phần trong của vật thể và vùng chuyển tiếp giữa vật thể với nền.

Bài tập kiểm tra ý tưởng trộn đặc trưng theo bản đồ biên trong PIDNet của Xu, Xiong và Bhattacharyya [1]. Câu hỏi thực nghiệm là liệu phép trộn thay đổi theo vị trí có tăng IoU của dải chuyển tiếp trên Oxford-IIIT Pet khi cả hai mô hình đã được giám sát bằng nhãn vùng này. IoU theo từng vùng được đọc cùng mIoU và Dice để xác định mức cải thiện ở vùng hẹp có đi kèm thay đổi ở phần trong và nền hay không.

2 Phân tích PIDNet

2.1 Giới hạn của các mạng hai nhánh

Trong phân đoạn thời gian thực, giảm kích thước bản đồ đặc trưng giúp giảm chi phí, nhưng việc giảm mẫu sớm làm mất thông tin định vị. Một pixel trong bản đồ sâu có thể tổng hợp cả hai phía của đường viền. Khi nội suy trở lại lưới ảnh, tín hiệu đó có thể lan sang vùng bên cạnh, làm mờ biên hoặc xóa một vật thể nhỏ giữa vùng nền lớn. Các bộ mã hóa dùng tích chập giãn có thể giữ lưới dày hơn ở những tầng sâu, với chi phí bộ nhớ và độ trễ phụ thuộc phần cứng.

BiSeNet [2] xử lý sự đánh đổi này bằng một luồng giữ chi tiết không gian và một luồng tổng hợp ngữ cảnh. DDRNet [3] duy trì hai độ phân giải và trao đổi thông tin giữa chúng qua nhiều tầng. Theo phân tích của PIDNet, ngay cả khi nhánh chi tiết còn giữ được một đoạn biên, việc cộng hai bản đồ có thể làm đáp ứng ngữ cảnh mạnh lấn át tín hiệu cục bộ. Chẳng hạn ở mép một vật thể mảnh, phần lớn trường tiếp nhận của nhánh sâu có thể nằm trong nền. Nhãn nền có thể lan qua mép khi đặc trưng hai nhánh được trộn cùng một cách ở mọi vị trí.

2.2 Phép tương tự với điều khiển PID

Trong bộ điều khiển, thành phần tỉ lệ P phản ứng với sai số hiện tại, I tích lũy sai số và D phản ứng với sự thay đổi của sai số. Ở miền tần số rời rạc, bỏ qua hệ số khuếch đại và xét $0 < \omega \leq \pi$, độ lớn đáp ứng của tích phân và vi phân lần lượt là

$$|H_I(e^{j\omega})| = \frac{1}{2|\sin(\omega/2)|}, \qquad |H_D(e^{j\omega})| = 2|\sin(\omega/2)|.$$

Tích phân nhấn mạnh biến thiên chậm, còn vi phân đáp ứng mạnh khi tín hiệu đổi nhanh. Trên mô hình một chiều của paper, nhánh chi tiết có trường tiếp nhận tập trung gần vị trí đang xét, trong khi nhánh ngữ

cảnh tổng hợp trên vùng rộng hơn. Tác giả liên hệ hai nhánh với P và I, rồi dùng hiện tượng đáp ứng vượt mức của PI để giải thích trực giác về sự lan nhãn qua biên. Thành phần D gợi ý một tín hiệu bổ sung có thể làm thay đổi phép trộn tại nơi nhãn chuyển nhanh.

Nhánh	Thông tin chính	Vai trò khi tổng hợp
P	Chi tiết không gian trên lưới tương đối dày.	Giữ hình dạng và vị trí của đường viền.
I	Ngữ cảnh từ tầng sâu và khối gộp hình tháp.	Ổn định nhãn trong vùng đồng nhất.
D	Tín hiệu chuyển lớp được giám sát bằng nhãn biên.	Điều chỉnh trọng số dành cho P và I theo vị trí.

Bảng 1: Vai trò của ba nhánh trong PIDNet.

Phép tương tự PID dẫn đến lựa chọn kiến trúc trong Bảng 1. PIDNet sử dụng một nhánh học từ dữ liệu để định vị biên ngữ nghĩa. Các đáp ứng tần số trên mô tả bộ điều khiển tuyến tính, còn các nhánh tích chập thực tế có chuẩn hóa, hàm kích hoạt và các kết nối chéo. Trong Bag, D cung cấp hệ số trộn cho hai luồng đặc trưng.

2.3 Trao đổi thông tin và hàm mục tiêu

Nhánh I gửi thông tin ngữ nghĩa sang P qua Pag và bổ sung đặc trưng cho D bằng phép cộng. Pag chiếu hai vector tại cùng vị trí, lấy tích vô hướng và áp dụng sigmoid để điều chỉnh mức tiếp nhận ngữ cảnh của P. PAPPM tổng hợp ngữ cảnh qua các nhánh gộp song song trong PIDNet-S/M. Ở cuối mạng, Bag sử dụng tín hiệu của D để điều tiết hai luồng. Với đặc trưng chi tiết P, ngữ cảnh I và biểu diễn biên D, biểu thức của Bag có dạng

$$a = \sigma(D), \qquad Y = f_{\text{out}}\big(a \odot P + (1 - a) \odot I\big).$$

Hệ số a lớn tăng đóng góp của P ở vùng chuyển lớp. Ở vùng tương đối đồng nhất, I cung cấp ngữ cảnh để ổn định nhãn. Light-Bag dùng một phép kết hợp với các tích chập 1×1 để giảm độ trễ trong biến thể nhẹ.

Hàm mục tiêu của paper gồm cross-entropy ở đầu ra phụ và đầu ra chính, BCE có trọng số để giám sát nhánh D, cùng một cross-entropy có nhận biết biên. Thành phần cuối chỉ tính tại các vị trí có đáp ứng biên vượt ngưỡng $0{,}8$ theo thiết lập của tác giả. Nhánh D vừa nhận tín hiệu trực tiếp từ nhãn biên, vừa tham gia quyết định đặc trưng được đưa vào bộ phân loại điểm ảnh.

2.4 Thí nghiệm gốc và phạm vi kết luận

Bài báo đánh giá mIoU trên Cityscapes, CamVid và PASCAL Context. Với Cityscapes, tác giả dùng ảnh 2048×1024 và báo cáo PIDNet-S đạt 78,6% mIoU trên tập kiểm tra, ở 93,2 FPS trong phép đo với RTX 3090, batch 1 và gộp BatchNorm vào tích chập. Trên CamVid, mô hình này đạt 80,1% mIoU sau khi khởi tạo từ trọng số Cityscapes. Điều kiện khởi tạo cần được tính đến khi so sánh với mô hình học từ nguồn khác. PIDNet-L đạt 80,6% trên Cityscapes test ở 31,1 FPS, phản ánh chi phí của biến thể lớn. Trên PASCAL Context, PIDNet-L đạt 51,9% mIoU ở giao thức 59 lớp với suy luận đa tỷ lệ và lật ảnh, so với 54,0% của HRNet-W48 trong Bảng 7. Kết quả này cho thấy lợi thế phụ thuộc bộ dữ liệu và chế độ suy luận.

Đối chứng trong Bảng 1 của paper cho thấy thêm nhánh biên và Bag vào BiSeNet dùng ResNet18 tăng mIoU xác thực Cityscapes từ 75,4% lên 76,7%, đồng thời giảm tốc độ từ 63,2 xuống 52,1 FPS. Hai thành phần được thêm cùng lúc nên mức tăng này chưa tách riêng tác dụng của phép trộn. Bảng 3 giữ PAPPM và so sánh phép cộng với Light-Bag trên PIDNet-S. mIoU tăng từ 78,4% lên 78,8%, còn FPS giảm từ 97,8 xuống 93,2. Kết quả thể hiện sự đánh đổi giữa độ chính xác và tốc độ ngay trong cùng một họ kiến trúc.

Trong chuỗi ablation ở Bảng 4, việc bổ sung loss biên có trọng số tăng mIoU từ 78,8% lên 79,9% khi loss ngữ nghĩa phụ đã có. Mức tăng là hiệu ứng đo được ở cấu hình đó. Tác giả cũng lưu ý mô hình cần nhãn

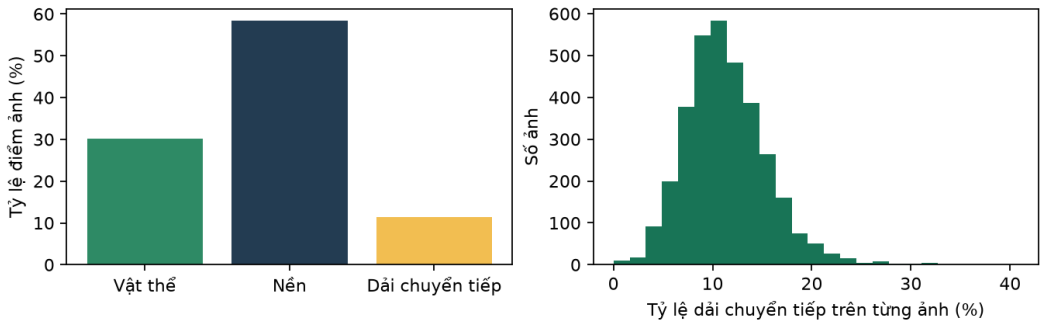
biên đủ chính xác. Các bảng mIoU gộp toàn ảnh nên khó xác định phần cải thiện nằm sát biên, trên vật thể nhỏ hay ở vùng trong. Phép đo FPS còn phụ thuộc độ phân giải, phần cứng và cấu hình suy luận. Ở ảnh thú cưng, lông, bóng đổ và nền có hoa văn tạo nhiều biến thiên cục bộ; đáp ứng cao ở các vùng này có thể dẫn đến ưu tiên chi tiết ngay cả khi nhãn thực thuộc vùng nền. Thí nghiệm dưới đây đo riêng sai số vùng chuyển tiếp để kiểm tra giới hạn đó.

3 Dữ liệu và phân tích khám phá

Oxford-IIIT Pet có 7.349 ảnh với 37 giống chó và mèo, kích thước và tư thế đa dạng [4, 5]. Mỗi ảnh có trimap, trong đó giá trị 1 là vật thể, 2 là nền và 3 là vùng chưa phân loại. Báo cáo gọi nhãn 3 là *dải chuyển tiếp* và dùng nó làm tín hiệu gần đúng cho biên. Nhãn giống chỉ phục vụ việc chia tập. Tập dữ liệu được công bố theo CC BY-SA 4.0 trên trang của Oxford. Quyền tác giả ảnh thuộc về chủ sở hữu gốc.

Từ 3.680 ảnh trong tập huấn luyện/xác thực chính thức, chọn 10 ảnh mỗi giống làm tập xác thực bằng hạt giống 2026. Phần còn lại gồm 3.310 ảnh dùng để cập nhật trọng số. Tập kiểm tra chính thức gồm 3.669 ảnh được giữ riêng. So sánh SHA-256 của kích thước và pixel RGB giải mã cho thấy không có ảnh trùng chính xác giữa các tập. Kiểm tra này chỉ phát hiện ảnh trùng pixel.

Trung vị chiều rộng và chiều cao ảnh gốc lần lượt là 500 và 375 pixel. Trên lưới dùng để huấn luyện, vật thể chiếm 30,23% điểm ảnh có nhãn, nền chiếm 58,36% và dải chuyển tiếp chiếm 11,41%. Tỷ lệ dải chuyển tiếp theo từng ảnh có trung vị 10,91% và khoảng tứ phân vị 8,64–13,77%. Sự mất cân bằng này là lý do dùng BCE cân bằng cho đầu dự đoán biên.



Hình 1: Tỷ lệ điểm ảnh theo nhãn và phân bố kích thước dải chuyển tiếp trên tập huấn luyện. Các thống kê tính sau khi đưa ảnh về lưới thực nghiệm và bỏ vùng đệm.

4 Cài đặt và giao thức đánh giá

4.1 Tiền xử lý

Cạnh dài của ảnh được nội suy về 192 pixel, giữ tỷ lệ khung hình và đệm bên phải hoặc phía dưới để có đầu vào 192×192. Ảnh RGB dùng nội suy song tuyến tính, còn trimap dùng láng giềng gần nhất để giữ giá trị nhãn. Nhãn đệm được bỏ qua trong hàm mục tiêu và phép đo. Tập huấn luyện xáo thứ tự và lật ngang đồng thời ảnh và mặt nạ với xác suất 0,5. Các tập xác thực và kiểm tra dùng phép biến đổi cố định. Chuẩn hóa RGB sử dụng trung bình và độ lệch chuẩn ImageNet.

4.2 Hai biến thể có cùng cấu trúc

Hai mô hình dùng ResNet18 với trọng số ImageNet từ torchvision [6, 7]. Đầu phân loại của ResNet18 được bỏ. Đặc trưng nông lấy từ `layer1` ở stride 4 và đặc trưng sâu lấy từ `layer4` ở stride 32. Hai nhánh được

chiếu về 64 kênh; đặc trưng sâu được nội suy về lưới đặc trưng nông. Một đầu dự đoán biên trên đặc trưng nông xuất một logit e tại mỗi vị trí.

Biến thể	Phép trộn tại từng vị trí	Vai trò của đầu dự đoán biên
Trộn cố định	$0{,}5P + 0{,}5I$	Học bằng hàm mất mát phụ.
Trộn theo biên	$\sigma(e)P + (1 - \sigma(e))I$	Học bằng hàm mất mát phụ và tham gia trộn đặc trưng.

Bảng 2: Hai biến thể cùng số tham số, trọng số khởi tạo và giao thức huấn luyện.

Bộ phân loại điểm ảnh giống nhau ở hai biến thể. Logit của ba vùng được nội suy về lưới ảnh trước khi tính loss và lấy nhãn có logit lớn nhất. Thử nghiệm giữ phép trộn theo sigmoid của Bag, dùng một hệ số chung cho mọi kênh và một bộ mã hóa ResNet18. Các khối Pag, PAPPM và nhánh D độc lập của PIDNet nằm ngoài cấu hình này. Đầu phụ và giám sát biên giống nhau ở hai biến thể, giúp cô lập việc đưa bản đồ biên vào phép trộn.

4.3 Huấn luyện

Với Ω là các điểm ảnh có nhãn, hàm mục tiêu là cross-entropy ba vùng cộng BCE cân bằng theo nhóm. Gọi Ω_b là dải chuyển tiếp, Ω_n là phần còn lại của Ω, và $\ell_{\text{BCE}}(e, y)$ là BCE tính trực tiếp từ logit. Khi hai nhóm đều có điểm ảnh,

$$L = L_{\text{CE}} + 0{,}25L_b, \quad L_b = \frac{1}{2|\Omega_b|} \sum_{i \in \Omega_b} \ell_{\text{BCE}}(e_i, 1) + \frac{1}{2|\Omega_n|} \sum_{i \in \Omega_n} \ell_{\text{BCE}}(e_i, 0).$$

Nếu một nhóm rỗng trong batch, đóng góp của nhóm đó bằng 0. Việc lấy trung bình riêng giúp dải chuyển tiếp vẫn đóng góp vào gradient dù chiếm ít điểm ảnh. Khác với loss có ngưỡng của PIDNet, thành phần CE ở đây luôn tính trên toàn bộ Ω. Tín hiệu biên của bản trộn theo biên còn nhận gradient qua loss chính vì phép trộn khả vi.

Mỗi biến thể chạy 12 epoch với ba hạt giống 42, 43 và 44. Batch size là 32. AdamW dùng hệ số suy giảm trọng số 10^{-4} và tốc độ học ban đầu 2×10^{-4} cho bộ mã hóa, 10^{-3} cho các đầu mới. Tốc độ học giảm theo cosine sau mỗi epoch. Vòng lặp gọi trực tiếp forward, tính loss, lan truyền ngược và cập nhật trọng số. Phép đo dùng NVIDIA GeForce RTX 3090, BF16 autocast với loss tính bằng FP32, 6 worker tải dữ liệu và 2 luồng CPU của PyTorch. Môi trường gồm PyTorch 2.14.1, torchvision 0.29.1 và CUDA 13.2.

4.4 Chỉ số và kiểm soát so sánh

Mỗi lượt chọn checkpoint có mIoU xác thực cao nhất. Khi bằng nhau, chọn epoch sớm hơn. Sau khi cả sáu lượt hoàn tất, cấu hình, dữ liệu và checkpoint được đối chiếu bằng SHA-256 rồi khóa trước bước đánh giá trên tập kiểm tra.

Với mỗi lớp c, lấy TP_c, FP_c và FN_c từ ma trận đếm điểm ảnh trên toàn tập. Các chỉ số được tính như sau:

$$\text{IoU}_c = \frac{TP_c}{TP_c + FP_c + FN_c}, \qquad \text{Dice}_c = \frac{2TP_c}{2TP_c + FP_c + FN_c}.$$

mIoU và macro-Dice là trung bình đều trên ba lớp. Cách gộp này cho dải chuyển tiếp cùng trọng số với các lớp lớn, dù số điểm ảnh mỗi lớp khác nhau. IoU riêng của dải chuyển tiếp dùng đúng nhãn trimap ở lưới 192×192 và phản ánh độ khớp vùng. Sai lệch biên tính bằng khoảng cách trên ảnh gốc nằm ngoài phép đo.

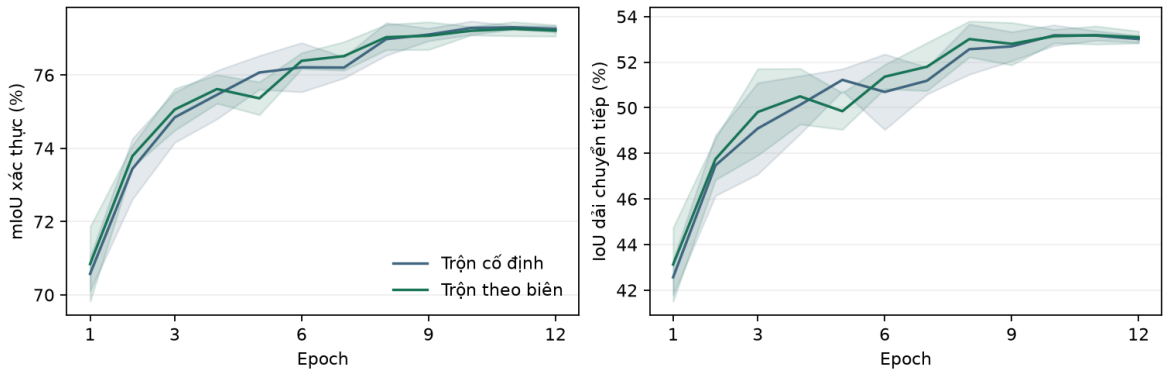
5 Kết quả và phân tích lỗi

Biến thể	mIoU	Dice	IoU vật thể	IoU nền	IoU chuyển tiếp
Trộn cố định	$77{,}88 \pm 0{,}13$	$86{,}53 \pm 0{,}11$	$86{,}17 \pm 0{,}13$	$92{,}65 \pm 0{,}05$	$54{,}83 \pm 0{,}42$
Trộn theo biên	$77{,}78 \pm 0{,}06$	$86{,}45 \pm 0{,}05$	$86{,}08 \pm 0{,}03$	$92{,}58 \pm 0{,}02$	$54{,}67 \pm 0{,}19$

Bảng 3: Kết quả kiểm tra theo phần trăm, trình bày trung bình và độ lệch chuẩn mẫu qua ba hạt giống.

Biến thể	mIoU xác thực (%)	Epoch được chọn	Thời gian (s)	Đỉnh (MiB)
Trộn cố định	$77{,}36 \pm 0{,}12$	10, 8, 11	$53{,}8 \pm 1{,}3$	$559{,}8 \pm 0{,}7$
Trộn theo biên	$77{,}30 \pm 0{,}14$	10, 11, 9	$54{,}8 \pm 0{,}4$	$572{,}6 \pm 0{,}0$

Bảng 4: Chi phí của 12 epoch và kết quả xác thực. Epoch theo thứ tự hạt giống 42, 43, 44. Thời gian gồm tải batch và cập nhật trọng số. Mức cấp phát GPU cực đại bao gồm lượt xác thực.



Hình 2: mIoU xác thực và IoU dải chuyển tiếp theo epoch. Đường đậm là trung bình của ba hạt giống, vùng mờ biểu diễn một độ lệch chuẩn mẫu.

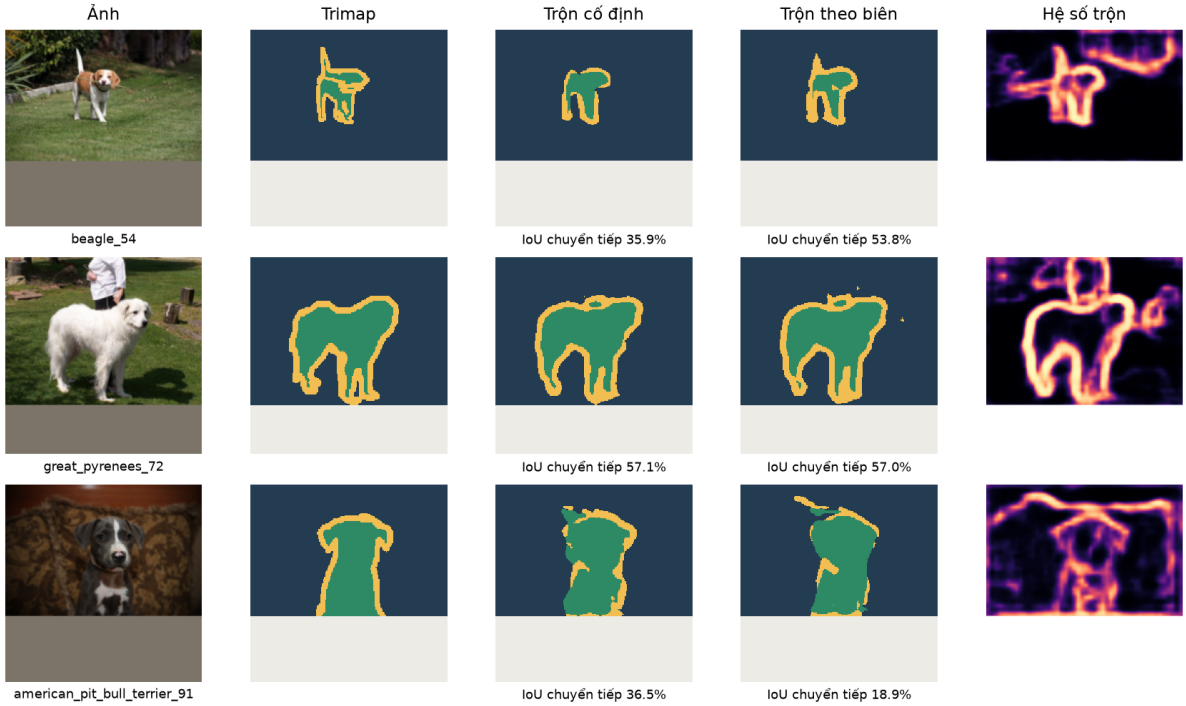
5.1 Độ chính xác theo vùng

Hai mô hình cùng có 11.302.116 tham số được huấn luyện. So với phép trộn cố định, phép trộn theo biên thay đổi mIoU $-0{,}11 \pm 0{,}07$ điểm phần trăm và macro-Dice $-0{,}07 \pm 0{,}06$ điểm phần trăm, tính theo cặp cùng hạt giống. mIoU giảm nhẹ ở cả ba cặp. IoU dải chuyển tiếp giảm trung bình $0{,}16$ điểm phần trăm, nhưng tăng $0{,}09$ điểm ở hạt giống 44. Dải chuyển tiếp là vùng khó nhất ở cả hai biến thể, với IoU xấp xỉ 55%, so với hơn 86% ở phần vật thể và hơn 92% ở nền.

Khi chia hậu nghiệm tập kiểm tra thành ba nhóm bằng nhau theo tỷ lệ vật thể trong ảnh, chênh lệch IoU chuyển tiếp lần lượt là $+0{,}10$, $-0{,}11$ và $-0{,}40$ điểm phần trăm, từ nhóm tỷ lệ thấp đến cao. Mức giảm tập trung hơn ở nhóm vật thể chiếm diện tích lớn. Tỷ lệ vật thể có thể đi cùng độ dày viền, kiểu nền hoặc góc chụp, nên phép phân nhóm chỉ mô tả dữ liệu hiện có.

5.2 Bản đồ hệ số và trường hợp sai

Ở biến thể theo biên, điểm sigmoid của đầu biên sau nội suy đạt trung bình 0,760 trên dải chuyển tiếp, 0,294 trên vật thể và 0,170 trên nền. Đầu biên của biến thể cố định, vốn chỉ học bằng loss phụ, cũng có sự phân tách tương tự, với các giá trị tương ứng 0,787, 0,290 và 0,178. BCE cân bằng đặt trọng số khác nhau cho các nhóm điểm ảnh. Vì vậy, giá trị sigmoid được dùng để mô tả mức đáp ứng của đầu biên. Đáp ứng cao trên dải chuyển tiếp cho thấy đầu biên đã học tín hiệu phân biệt vùng, trong khi kết quả IoU cho thấy tín hiệu đó chưa đem lại lợi ích khi trực tiếp điều tiết phép trộn.



Hình 3: Ví dụ từ tập kiểm tra với hạt giống 42. Xanh lá là vật thể, xanh đậm là nền, vàng là dải chuyển tiếp. Bản đồ bên phải là hệ số trộn của biến thể theo biên. Ảnh và trimap gốc từ Oxford-IIIT Pet, CC BY-SA 4.0 [5].

Hình 3 lấy ba ảnh ở hạt giống 42 theo chênh lệch IoU dải chuyển tiếp lớn nhất, trung vị và thấp nhất, giới hạn ở ảnh có dải chuyển tiếp chiếm ít nhất 2% điểm ảnh có nhãn. Với `beagle_54`, bản theo biên giữ được phần đuôi mảnh rõ hơn, nâng IoU vùng này từ 35,9% lên 53,8%. Với `great_pyrenees_72`, hai dự đoán có IoU gần bằng nhau và cùng xuất hiện nhãn chuyển tiếp thừa phía trên lưng. Ở `american_pit_bull_terrier_91`, bản đồ hệ số sáng ở cả đường viền nền phía trên. Bản theo biên bỏ sót nhiều đoạn dải chuyển tiếp quanh đầu và thân, với IoU giảm từ 36,5% xuống 18,9%.

Một cách giải thích phù hợp với các quan sát là đối chứng đã nhận chi tiết ở mọi vị trí và đã dùng cùng tín hiệu giám sát biên khi học đặc trưng. Cổng thích nghi chỉ có thể cải thiện trên nền đó nếu dự đoán biên đủ tin cậy và nếu P, I mang thông tin bổ sung phù hợp. Cổng sai có thể giảm đóng góp của ngữ cảnh đúng tại điểm cần ngữ cảnh để phân biệt đường viền vật thể với hoa văn nền. Với lưới stride 4 và trimap nội suy, hiệu quả của riêng độ phân giải và nguồn nhãn chưa được tách ra.

5.3 Chi phí tính toán

Trên RTX 3090, phép trộn theo biên tăng thời gian huấn luyện trung bình từ 53,8 lên 54,8 giây mỗi lượt và tăng mức bộ nhớ cấp phát cực đại từ 559,8 lên 572,6 MiB. Phép đo bổ sung dùng 50 lượt làm nóng và 200 lần đo bằng CUDA events cho mỗi checkpoint, batch 1, đầu vào đã nằm trên GPU. Trung bình của các trung vị theo hạt giống là 5,22 ms với trộn cố định và 5,28 ms với trộn theo biên. Trung bình của phân vị 95 lần lượt là 5,25 và 5,42 ms. Phép đo gồm forward của đầu phụ ở cả hai biến thể và loại thời gian tiền xử lý, truyền dữ liệu và dựng mặt nạ. Các số liệu này mô tả độ trễ của pipeline ở 192×192, dưới giao thức khác với FPS của PIDNet.

6 Đối chiếu với kết quả công bố

Thí nghiệm	Điều kiện đối chứng	mIoU trước/sau (%)	Chênh lệch (đpt)
PIDNet, Bảng 1	Cityscapes xác thực, BiSeNet–ResNet18, thêm nhánh biên và Bag.	75,4/76,7	+1,3
PIDNet, Bảng 3	Cityscapes, PIDNet-S giữ PAPPM, thay phép cộng bằng Light-Bag.	78,4/78,8	+0,4
A2	Oxford-IIIT Pet kiểm tra, ResNet18 giữ giám sát biên, thay trộn 50/50 bằng trộn theo biên.	77,88/77,78	−0,11

Bảng 5: Đối chiếu tác động của phép trộn trong bài báo gốc [1] và A2. Đpt là điểm phần trăm. Giá trị A2 là trung bình qua ba hạt giống, chênh lệch tính trước khi làm tròn.

Bảng 5 so sánh hướng thay đổi trong từng giao thức. Mức mIoU tuyệt đối không dùng để xếp hạng giữa các dòng vì tập dữ liệu, tập đánh giá và định nghĩa lớp khác nhau. A2 tái hiện phép trộn theo cổng của Bag trong một bộ mã hóa nhỏ. Bản trộn cố định của A2 đã học với loss biên, trong khi đối chứng BiSeNet của paper thêm đồng thời nhánh D và Bag. Đối chứng Light-Bag giữ PAPPM và gần hơn về câu hỏi nghiên cứu, nhưng vẫn dùng hệ thống nhiều nhánh, đặc trưng biên và nhãn Cityscapes. Trong A2, chỉ thay phép trộn trên một cặp mô hình đã có giám sát biên. Kết quả trái chiều vì vậy giới hạn kết luận của bài tập ở phép chuyển cơ chế này sang trimap Oxford-IIIT Pet.

7 Kết luận và giới hạn

Cơ chế Bag trong PIDNet cho thấy cách dùng tín hiệu chuyển lớp để phân bổ đóng góp của nhánh chi tiết và ngữ cảnh. Trên Oxford-IIIT Pet, phép trộn theo bản đồ biên có hiệu quả khác nhau giữa từng ảnh, nhưng không cải thiện mIoU hoặc Dice trung bình so với trộn cố định dưới cùng mức giám sát. Cả hai biến thể đạt trên 92% IoU nền trong khi IoU dải chuyển tiếp chỉ khoảng 55%. Chênh lệch này cho thấy phép đo riêng ở vùng chuyển tiếp cần thiết để đánh giá giả thuyết về biên.

Tập ảnh chủ yếu gồm một thú cưng nổi bật, nên kết quả chưa bao quát cảnh có nhiều lớp tiếp giáp hoặc vật thể nhỏ như Cityscapes. Dải chưa phân loại trong trimap có độ dày khác nhau giữa các ảnh. Đổi độ phân giải ảnh và mặt nạ cũng làm thay đổi độ dày biểu kiến của dải này. Ngoài ra, chỉ ba lượt khởi tạo cho mỗi biến thể được dùng để mô tả độ ổn định.

Mã nguồn và hướng dẫn chạy nằm trong `src/A2`. Cấu hình được lưu ở `configs/a2_experiments.json`. Lịch sử từng lượt, ma trận nhầm lẫn, định danh dữ liệu và checksum checkpoint được lưu cùng báo cáo. Phạm vi hỗ trợ của AI được trình bày trong `AI_USE_REPORT.md`.

Tài liệu

[1] J. Xu, Z. Xiong và S. P. Bhattacharyya. *PIDNet: A Real-Time Semantic Segmentation Network Inspired by PID Controllers*. Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), tr. 19529–19539, 2023. DOI: 10.1109/CVPR52729.2023.01871. Bản toàn văn tại CVF.

[2] C. Yu, J. Wang, C. Peng, C. Gao, G. Yu và N. Sang. *BiSeNet: Bilateral Segmentation Network for Real-Time Semantic Segmentation*. European Conference on Computer Vision (ECCV), tr. 325–341, 2018. Bản toàn văn tại ECVA.

[3] Y. Hong, H. Pan, W. Sun và Y. Jia. *Deep Dual-resolution Networks for Real-time and Accurate Semantic Segmentation of Road Scenes*. arXiv:2101.06085, 2021. `https://arxiv.org/abs/2101.06085`.

[4] O. M. Parkhi, A. Vedaldi, A. Zisserman và C. V. Jawahar. *Cats and Dogs*. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), tr. 3498–3505, 2012. DOI: 10.1109/CVPR.2012.6248092.

[5] Visual Geometry Group, University of Oxford. *The Oxford-IIIT Pet Dataset*. `https://www.robots.ox.ac.uk/~vgg/data/pets/`.

[6] K. He, X. Zhang, S. Ren và J. Sun. *Deep Residual Learning for Image Recognition*. IEEE Conference on Computer Vision and Pattern Recognition (CVPR), tr. 770–778, 2016. DOI: 10.1109/CVPR.2016.90.

[7] Torchvision. *ResNet18 and ImageNet weights*. `https://docs.pytorch.org/vision/stable/models/generated/torchvision.models.resnet18.html`.