ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH



BÁO CÁO BÀI TẬP E1–E3

CO5085 · Học sâu và ứng dụng trong thị giác máy tính

Học kỳ 261 · Năm học 2026–2027

Phân loại ảnh với CNN, attention và mạng hồi tiếp

Sinh viên

Huỳnh Thành Đạt	2570161
Giảng viên	Lê Thành Sách
	Nguyễn Quốc Minh

Thành phố Hồ Chí Minh, tháng 11 năm 2026

Tóm tắt

Ba bài tập khảo sát cách biểu diễn ảnh trong bài toán phân loại Fashion-MNIST. E1 so sánh bộ phân loại softmax, MLP và CNN. E2 đối chiếu multi-head self-attention tự viết với mô-đun PyTorch trên ba cách tạo token. E3 so sánh LSTM và GRU khi ảnh được đọc theo hàng hoặc theo ô, đồng thời khảo sát độ nhạy với thứ tự quét.

Mỗi cấu hình được huấn luyện từ đầu với ba seed. CNN đạt độ chính xác trên tập test trung bình cao nhất, 92,62%. Trong nhóm attention, bản PyTorch dùng CNN-stem đạt 88,59%. GRU đọc ảnh theo hàng đạt 90,07%. Phân tích gradient và phép thay đổi thứ tự quét mô tả độ nhạy của mô hình đối với biểu diễn chuỗi.

Tổng quan báo cáo

Dữ liệu	Fashion-MNIST, 10 lớp. Ba bài dùng cùng các tập huấn luyện, validation và test.
E1	So sánh softmax, MLP và CNN về độ chính xác, số tham số và lỗi phân loại.
E2	Đối chiếu hai hiện thực attention trên token theo hàng, theo ô và theo đặc trưng CNN-stem.
E3	So sánh LSTM, GRU với MLP và CNN. Khảo sát độ nhạy với thứ tự quét và gradient theo bước.
Phép đo	13 cấu hình, ba seed mỗi cấu hình. Checkpoint được chọn trên tập validation.
Kết quả chính	CNN đạt 92,62% độ chính xác trên tập test trung bình. GRU đọc theo hàng đạt 90,07% trong E3.

Mục lục

Tóm tắt **i**

Tổng quan báo cáo **ii**

1 Dữ liệu và quy trình chung **1**

1.1 Phạm vi bài làm 1

1.2 Tập dữ liệu và cách chia 1

1.3 Huấn luyện và chỉ số đánh giá 2

2 E1: Softmax, MLP và CNN **3**

2.1 Ba bộ phân loại 3

2.2 Kết quả và phân tích lỗi 3

3 E2: MSA và cách lấy token **7**

3.1 Hiện thực attention 7

3.2 Ba cách tokenization 7

3.3 So sánh attention và tokenization 8

4 E3: LSTM/GRU trên chuỗi ảnh **10**

4.1 Biểu diễn ảnh và kiến trúc 10

4.2 Các phương trình được sử dụng 10

4.3 Kết quả và quan hệ không gian 11

4.4 Độ nhạy với thứ tự quét 13

5 Tái lập và giới hạn **14**

5.1 Mã nguồn và tệp kết quả 14

5.2 Cấu hình và các lượt chạy 14

5.3 Kết luận 15

Tài liệu tham khảo **16**

Danh sách hình vẽ

2.1 Validation CE của ba mô hình E1 ở seed 42. 4
2.2 Validation accuracy của E1; seed dùng cho hình ghi trên biểu đồ. 5
2.3 Confusion matrix test của CNN ở seed đại diện. 5
2.4 Một số dự đoán sai có confidence cao của CNN. 6

3.1 Validation CE của sáu cấu hình E2 ở seed 42. 9
3.2 Validation accuracy khi thay attention backend và tokenizer. 9

4.1 Cross-entropy trên tập validation của các mạng hồi tiếp và mô hình đối chứng E1 ở cùng seed. 12
4.2 Độ chính xác trên tập validation của E3 và hai mô hình đối chứng MLP, CNN. 12
4.3 Chuẩn gradient theo bước của LSTM đọc ảnh theo hàng trên tập validation ở seed 42. 13

Danh sách bảng

1.1 Thiết lập huấn luyện dùng chung cho E1–E3. 2

2.1 Kiến trúc E1. Conv không dùng bias vì sau đó có batch normalization. . 3
2.2 Kết quả E1, tổng hợp theo các seed được công bố. 3

3.1 Tokenization của E2 trên ảnh $1 \times 28 \times 28$. 7
3.2 Sáu cấu hình E2. Manual và PyTorch của cùng tokenizer có cùng số tham số. 8

4.1 Kết quả E3 và hai mô hình đối chứng E1 trên cùng phân hoạch dữ liệu. . 11

5.1 Phạm vi kết quả. Mỗi cấu hình được huấn luyện và đánh giá với các seed 42, 43 và 44. 14

Chương 1

Dữ liệu và quy trình chung

1.1 Phạm vi bài làm

Báo cáo so sánh các mô hình phân loại ảnh trên cùng tập Fashion-MNIST. E1 gồm softmax, MLP và CNN. E2 trình bày hiện thực multi-head self-attention (MSA), đối chiếu với thư viện và khảo sát ba cách tạo token. E3 biểu diễn ảnh thành chuỗi để phân loại bằng LSTM/GRU, với MLP và CNN của E1 làm đối chứng. Chỉ số bước của mạng hồi tiếp tương ứng với thứ tự quét các vùng trên ảnh.

Báo cáo tổng hợp 13 cấu hình, gồm ba cấu hình E1, sáu cấu hình E2 và bốn cấu hình hồi tiếp E3. Mỗi cấu hình được huấn luyện từ đầu với ba seed 42, 43 và 44, tương ứng 39 lượt. Các mô hình dùng chung cách chia dữ liệu và quy tắc chọn checkpoint.

1.2 Tập dữ liệu và cách chia

Fashion-MNIST gồm ảnh thời trang mức xám 28×28, 10 lớp, với 60.000 ảnh train và 10.000 ảnh test chính thức [2]. Kích thước ảnh nhỏ phù hợp để khảo sát cả CNN, attention và mạng hồi tiếp trên cùng đầu vào.

Từ 60.000 ảnh train, tách phân tầng 10% làm validation với split seed 2026. Như vậy có 54.000 ảnh train, 6.000 validation và 10.000 test. Mỗi lớp lần lượt có 5.400, 600 và 1.000 ảnh theo phân bố chuẩn của bộ dữ liệu. Split seed không đổi giữa E1–E3 và không trùng vai trò với seed khởi tạo mô hình.

Ảnh được chuyển từ uint8 sang $[0, 1]$, sau đó chuẩn hóa $x' = (x - \mu)/\sigma$. Hai thống kê μ, σ được tính trên 54.000 ảnh train và dùng lại cho validation/test. Các thí nghiệm không dùng augmentation để giữ đầu vào thống nhất khi so sánh cách biểu diễn ảnh.

`src/common/data.py` lưu chỉ số từng split, checksum dữ liệu và fingerprint của cả split lẫn normalization. Loader ưu tiên HTTPS từ repo chính thức của dataset và giữ kiểm tra checksum của torchvision. Dữ liệu test có thể được tải cùng kho ảnh, nhưng không được đọc vào vòng chọn checkpoint hay tính normalization.

1.3 Huấn luyện và chỉ số đánh giá

Mỗi mô hình xuất logits $z \in \mathbb{R}^{10}$. Với nhãn đúng y, cross-entropy là

$$\ell(z, y) = -z_y + \log \sum_{k=1}^{10} \exp(z_k), \qquad \frac{\partial \ell}{\partial z_k} = p_k - \mathbf{1}[k = y]. \tag{1.1}$$

Vì `cross_entropy` đã thực hiện log-softmax ổn định số, code không chèn softmax trước loss. Softmax chỉ được dùng khi cần xác suất để trình bày dự đoán.

Thiết lập	Giá trị định trước
Optimizer	AdamW, weight decay 10^{-4} trên các tham số trainable
Ngân sách	30 epoch, batch 256, không early stopping
Learning rate	E1/E3: 10^{-3}; E2: 3×10^{-4}
Scheduler	Cosine decay về 1% learning rate ban đầu
Gradient clipping	Global norm tối đa 1, sau backward và trước step
Độ chính xác số	FP32; tắt AMP, TF32 và compile
Seed mô hình	42, 43, 44; cùng split seed 2026
Chọn checkpoint	Validation accuracy lớn nhất; hòa thì CE nhỏ nhất

Bảng 1.1: Thiết lập huấn luyện dùng chung cho E1–E3.

Vòng lặp huấn luyện gồm zero gradient, forward, tính loss, backward, clipping và optimizer step. Checkpoint được chọn trên validation; test được đánh giá sau khi hoàn tất các cấu hình đã định. Chương trình kiểm tra tính hữu hạn của loss và gradient tại mỗi bước cập nhật.

Accuracy là chỉ số chính; macro-F1 bổ sung đánh giá theo lớp. Confusion matrix và các dự đoán sai có confidence cao được dùng để phân tích lỗi. Chi phí mô hình được mô tả qua số tham số và thời gian train/epoch. Thời gian được đồng bộ CUDA, gồm lấy batch và cập nhật trọng số; median bỏ epoch đầu để giảm ảnh hưởng khởi tạo. Tốc độ inference được đo riêng, bỏ hai batch đầu và không tính thời gian truyền dữ liệu sang GPU.

Bảng kết quả trình bày độ chính xác trên tập validation trung bình và độ chính xác trên tập test dưới dạng trung bình ± độ lệch chuẩn mẫu qua ba seed. Các đường cong, confusion matrix và ảnh minh họa dùng seed 42. Ngân sách 30 epoch được giữ cố định cho mọi cấu hình; do đó kết quả phản ánh hiệu quả trong ngân sách này.

Chương 2

E1: Softmax, MLP và CNN

2.1 Ba bộ phân loại

Softmax nhận vector $x \in \mathbb{R}^{784}$ và tính logits $z = Wx + b$; ranh giới giữa hai lớp là siêu phẳng trong không gian pixel. MLP bổ sung hai tầng phi tuyến trên cùng vector flatten. CNN dùng kernel chia sẻ theo vị trí để học đặc trưng cục bộ. Ba kiến trúc được giữ nhỏ và mô tả đầy đủ trong bảng dưới đây.

Mô hình	Các lớp theo thứ tự
Softmax	Flatten $784 \to 10$
MLP	Flatten; $784 \to 256$; ReLU; dropout 0,2; $256 \to 128$; ReLU; dropout 0,2; $128 \to 10$
CNN	Conv $1 \to 32$, kernel 3, padding 1; BN; ReLU; pool 2; Conv $32 \to 64$ tương tự; pool 2; flatten; $3136 \to 128$; ReLU; dropout 0,2; $128 \to 10$

Bảng 2.1: Kiến trúc E1. Conv không dùng bias vì sau đó có batch normalization.

Hai phép pooling đưa ảnh $28 \to 14 \to 7$, vì vậy head CNN nhận $64 \times 7 \times 7 = 3136$ giá trị. Với một lớp Linear $d_{in} \to d_{out}$ có bias, số tham số là $d_{in}d_{out} + d_{out}$. Ví dụ softmax có $784 \times 10 + 10 = 7.850$ tham số. Các số còn lại được đếm trực tiếp bằng `numel()`, gồm tham số affine của BN nhưng không gồm running statistics.

2.2 Kết quả và phân tích lỗi

Mô hình	Tham số	Val (%)	Test (%)	Giây/epoch
Softmax	7,850	85.98	84.51 ± 0.15	0.29
MLP	235,146	91.02	89.88 ± 0.14	0.38
CNN	421,738	93.02	92.62 ± 0.06	0.48

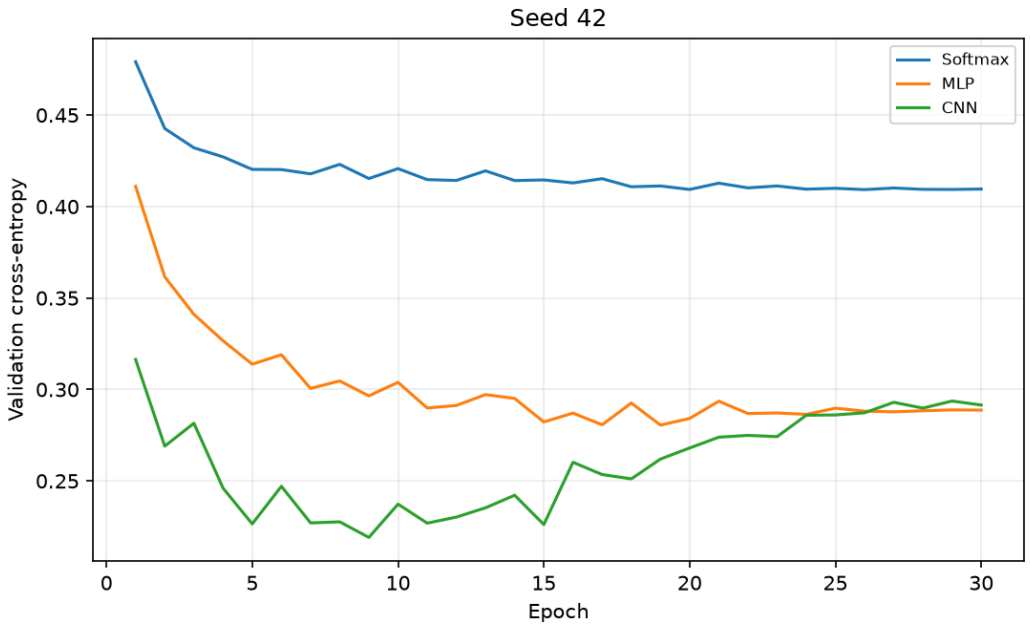
Bảng 2.2: Kết quả E1, tổng hợp theo các seed được công bố.

Val/Test: accuracy (%). Tham số đếm từ kiến trúc; ±: SD qua ba seed. Các lượt chạy được liệt kê ở Chương 5; cách đo thời gian ở Chương 1.

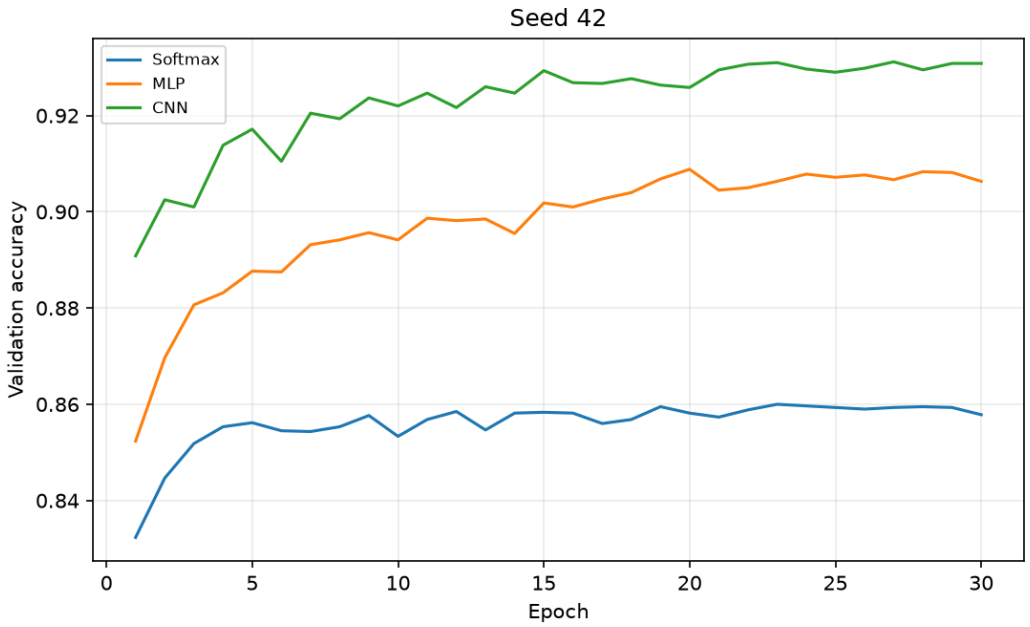
Train/validation CE được đối chiếu với accuracy để phân tích quá trình học. Confusion matrix và ảnh dự đoán sai bên dưới lấy từ CNN ở seed 42. MLP tăng độ chính xác trên

tập test từ 84,51% của softmax lên 89,88%. CNN đạt 92,62%, cao hơn MLP 2,74 điểm phần trăm. MLP bổ sung các lớp phi tuyến. CNN còn giữ cấu trúc hai chiều và khai thác lân cận bằng kernel dùng chung. Hai mô hình khác nhau cả về cấu trúc lẫn số tham số.

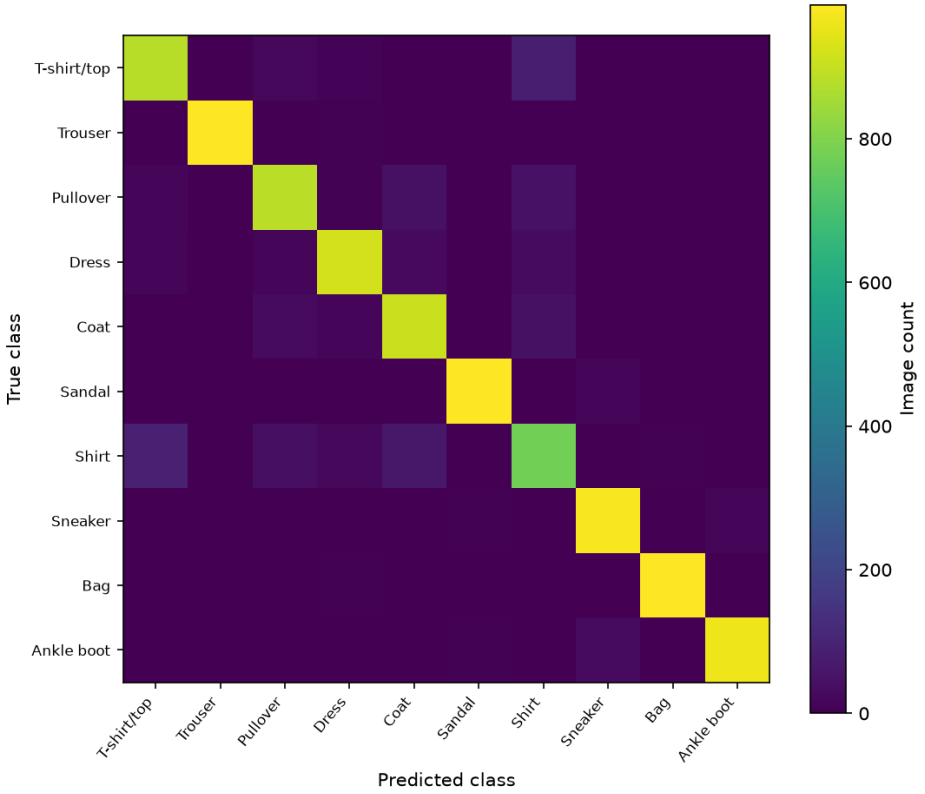
Ở epoch cuối, cross-entropy của CNN là 0,0167 trên tập huấn luyện và 0,3017 trên tập validation. Khoảng cách này cho thấy mô hình khớp tập huấn luyện nhiều hơn. Trong ma trận nhầm lẫn của seed 42, lỗi có tần suất cao nhất theo một chiều là Shirt bị gán thành T-shirt/top, gồm 92 ảnh.



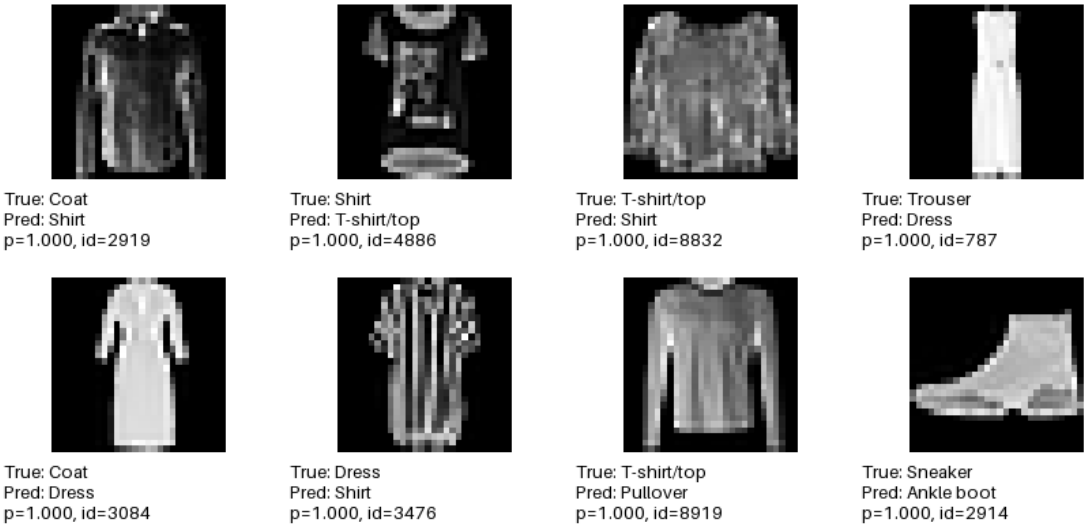
Hình 2.1: Validation CE của ba mô hình E1 ở seed 42.



Hình 2.2: Validation accuracy của E1; seed dùng cho hình ghi trên biểu đồ.



Hình 2.3: Confusion matrix test của CNN ở seed đại diện.



Hình 2.4: Một số dự đoán sai có confidence cao của CNN.

Chương 3

E2: MSA và cách lấy token

3.1 Hiện thực attention

Với tensor token $X \in \mathbb{R}^{B\times N\times d}$, mỗi head học các phép chiếu query, key và value. Bỏ chỉ số batch để gọn, attention của một head là [3]

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V, \qquad A = \mathrm{softmax}_{\text{hàng}}\left(\frac{QK^\top}{\sqrt{d_h}}\right), \quad O = AV. \tag{3.1}$$

Các bias được lược bỏ trong công thức cho gọn, nhưng có trong hiện thực. Ở đây $d = 64$, có bốn head nên $d_h = 16$. Ba phép Linear được gộp thành QKV, reshape thành các head, nhân ma trận, softmax theo chiều key, áp dụng dropout, ghép head và chiếu output. Bản manual không gọi `nn.MultiheadAttention`, `TransformerEncoder` hoặc fused attention để thay phần tính này.

Bản đối chiếu dùng `nn.MultiheadAttention(batch_first=True)`. Chương trình tạo toàn bộ model manual rồi copy đúng QKV và output projection sang module PyTorch. Các phần tokenizer, positional embedding, FFN, LayerNorm và head cũng giữ nguyên tensor khởi tạo của cùng seed. Chỉ reset seed trước hai constructor khác nhau là chưa đủ bảo đảm điều này.

Tính tương đương số học được kiểm tra bằng tensor nhỏ và dropout bằng 0, qua output, gradient đầu vào và gradient của toàn bộ tham số. Khi huấn luyện, dropout và kernel có thể làm hai phiên bản đi theo quỹ đạo khác nhau dù cùng khởi tạo.

3.2 Ba cách tokenization

Cách chia	N	Đầu vào/token	Phép tạo embedding
Hàng	28	28	Linear $28 \to 64$
Patch 4×4	49	16	Unfold không chồng lấp, Linear $16 \to 64$
CNN-stem	49	64	Hai Conv stride 2: $1 \to 32 \to 64$, BN/ReLU; flatten spatial

Bảng 3.1: Tokenization của E2 trên ảnh $1 \times 28 \times 28$.

Token hàng gom các pixel cùng một hàng. Token patch quét lưới từ trái sang phải, trên

xuống dưới. CNN-stem rút feature map $64 \times 7 \times 7$; mỗi vị trí là một token đã qua xử lý cục bộ. Stem được huấn luyện từ đầu và bổ sung cả phép tính lẫn tham số so với hai cách tạo token trực tiếp.

Mỗi cấu hình thêm learned positional embedding, qua hai encoder block dạng pre-LN và kết thúc bằng LayerNorm, mean pooling và Linear $64 \to 10$. Không có CLS token. Mỗi block tính

$$U = X + \text{Dropout}(\text{MSA}(\text{LN}(X))), \tag{3.2}$$

$$Y = U + \text{FFN}(\text{LN}(U)), \tag{3.3}$$

trong đó FFN là $64 \to 128 \to 64$ với GELU và dropout 0,1. Attention không dùng causal mask vì toàn bộ ảnh đã có tại thời điểm phân loại.

3.3 So sánh attention và tokenization

Mô hình	Tham số	Val (%)	Test (%)	Giây/epoch
patches / manual	71,946	87.03	85.93 ± 0.60	1.05
patches / torch	71,946	87.09	86.02 ± 0.37	0.98
rows / manual	71,370	88.61	87.92 ± 0.03	0.95
rows / torch	71,370	88.61	87.86 ± 0.02	0.91
cnn / manual	89,770	89.32	88.55 ± 0.34	1.03
cnn / torch	89,770	89.37	88.59 ± 0.44	0.97

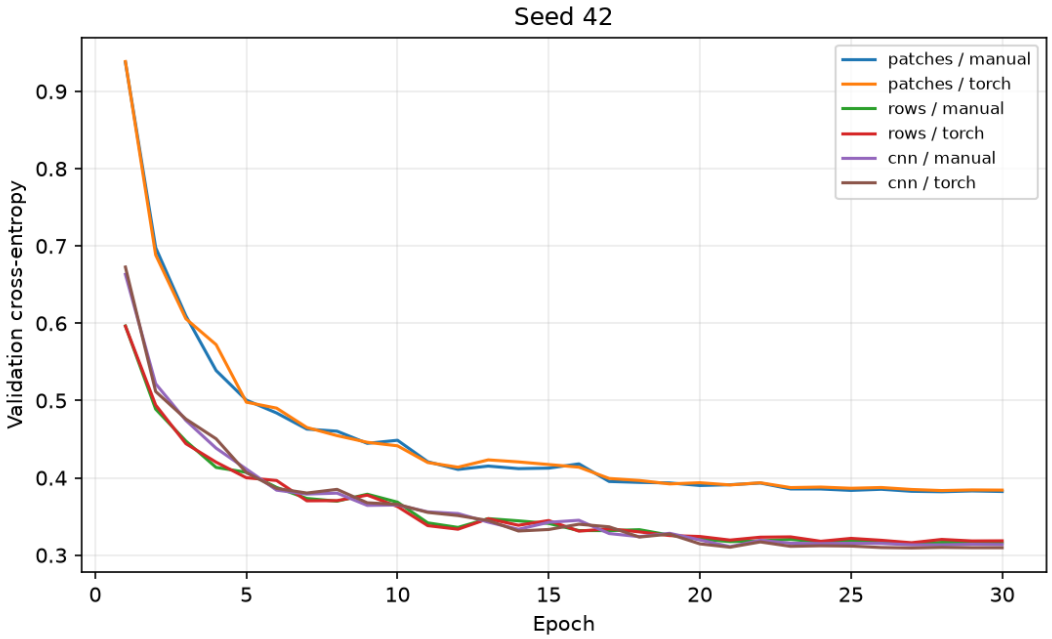
Bảng 3.2: Sáu cấu hình E2. Manual và PyTorch của cùng tokenizer có cùng số tham số.

Val/Test: accuracy (%). Tham số đếm từ kiến trúc; ±: SD qua ba seed. Các lượt chạy được liệt kê ở Chương 5; cách đo thời gian ở Chương 1.

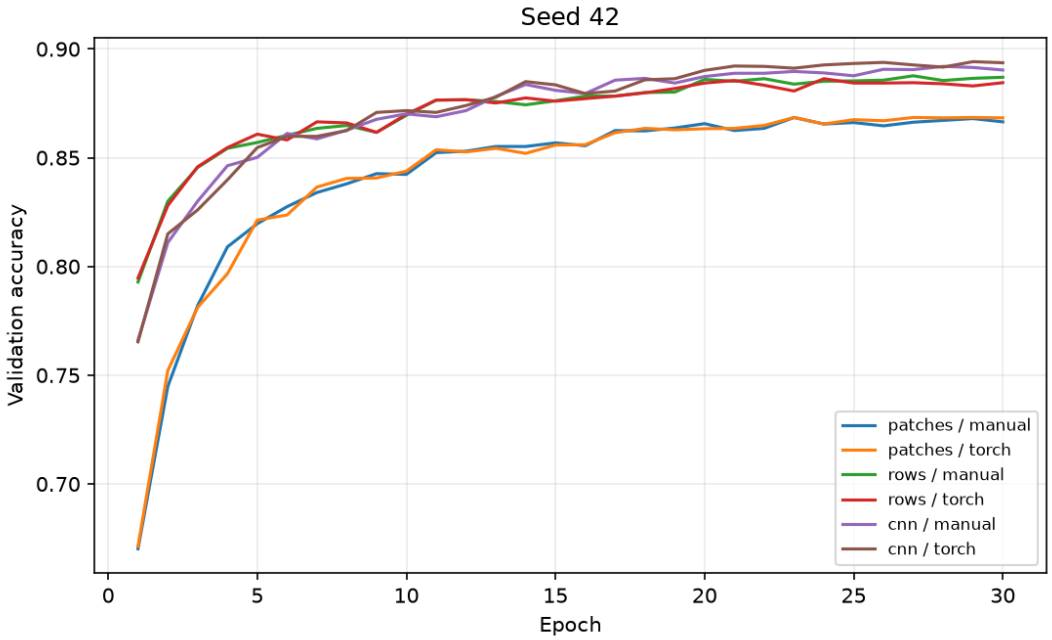
Manual và thư viện được so sánh ở từng tokenizer; ba tokenizer được so sánh khi giữ attention backend cố định. Chi phí phần score của attention tỉ lệ $N^2 d$; số cặp token của patch gấp $49^2/28^2 \approx 3,06$ lần token hàng. Thời gian toàn mô hình còn gồm projection, FFN, stem và chi phí thực thi kernel.

Các kết quả dưới đây được đo trên cùng split, với cùng thiết lập giữa hai backend của mỗi tokenizer. Trên cùng cách lấy token, chênh lệch độ chính xác trên tập test giữa bản PyTorch và bản tự viết lần lượt là $-0,06$, $+0,10$ và $+0,05$ điểm phần trăm cho token theo hàng, theo patch và theo đặc trưng CNN-stem. Các chênh lệch đều dưới 0,11 điểm phần trăm. Bản PyTorch có thời gian huấn luyện mỗi epoch ngắn hơn trong cả ba cặp.

CNN-stem đạt 88,55% với MSA tự viết và 88,59% với MSA PyTorch, cao hơn token theo hàng và theo patch ở cùng hiện thực. Tầng tích chập đưa đặc trưng cục bộ vào chuỗi trước attention. Cách lấy token đồng thời thay đổi độ dài chuỗi, kích thước đặc trưng và số tham số, nên kết quả phản ánh cả cấu hình biểu diễn.



Hình 3.1: Validation CE của sáu cấu hình E2 ở seed 42.



Hình 3.2: Validation accuracy khi thay attention backend và tokenizer.

Chương 4

E3: LSTM/GRU trên chuỗi ảnh

4.1 Biểu diễn ảnh và kiến trúc

Ảnh được biến thành chuỗi theo hai cách đã dùng trong E2, nhưng không qua embedding học được: hàng cho $T = 28, D = 28$; patch 4×4 cho $T = 49, D = 16$. Cả LSTM và GRU đều có một tầng, một chiều, hidden size $H = 128$, trạng thái đầu bằng zero. Bộ phân loại lấy trạng thái ẩn cuối, áp dụng dropout 0,1 rồi chiếu tuyến tính $128 \to 10$.

Quét hàng giữ các quan hệ ngang trong một token và để mạng hồi tiếp xử lý quan hệ giữa các hàng. Quét patch tạo nhiều bước hơn, mỗi bước mô tả một vùng nhỏ hơn. Vì vậy, so sánh này thay đổi đồng thời độ dài chuỗi và kích thước đầu vào tại mỗi bước.

4.2 Các phương trình được sử dụng

Với LSTM, đặt $a_t = W_x x_t + W_h h_{t-1} + b$ rồi tách thành bốn phần [4]:

$$i_t = \sigma(a_t^i), \qquad f_t = \sigma(a_t^f), \qquad g_t = \tanh(a_t^g), \qquad o_t = \sigma(a_t^o), \tag{4.1}$$

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t, \qquad h_t = o_t \odot \tanh(c_t). \tag{4.2}$$

c_t có đường cập nhật cộng, còn h_t là trạng thái dùng cho output và hồi tiếp. Cổng quên lớn có thể giữ thông tin, nhưng kiến trúc này không tự bảo đảm mọi gradient đều được bảo toàn.

GRU dùng reset gate r_t, update gate z_t và trạng thái ứng viên n_t. Diagnostic khớp đúng cách PyTorch đặt reset gate sau phép chiếu hidden [5]:

$$r_t = \sigma(W_{ir} x_t + b_{ir} + W_{hr} h_{t-1} + b_{hr}), \tag{4.3}$$

$$z_t = \sigma(W_{iz} x_t + b_{iz} + W_{hz} h_{t-1} + b_{hz}), \tag{4.4}$$

$$n_t = \tanh(W_{in} x_t + b_{in} + r_t \odot (W_{hn} h_{t-1} + b_{hn})), \tag{4.5}$$

$$h_t = (1 - z_t) \odot n_t + z_t \odot h_{t-1}. \tag{4.6}$$

Trong công thức của PyTorch, reset gate tác động sau phép chiếu hidden. Đây là điểm khác với cách viết $W_{hn}(r_t \odot h_{t-1})$. GRU sử dụng một trạng thái hidden, còn LSTM tách hidden state và cell state.

PyTorch lưu hai vector bias cho mỗi tầng. Vì vậy, số tham số phần recurrent là $4H(D +$

$H + 2)$ với LSTM và $3H(D + H + 2)$ với GRU; cộng thêm $10H + 10$ cho head. Giữ cùng H giúp so sánh rõ nhưng không làm hai mô hình có cùng capacity.

4.3 Kết quả và quan hệ không gian

Mô hình	Tham số	Val (%)	Test (%)	Giây/epoch
MLP	235,146	91.02	89.88 ± 0.14	0.38
CNN	421,738	93.02	92.62 ± 0.06	0.48
LSTM / rows	82,186	90.32	89.58 ± 0.05	0.38
GRU / rows	61,962	91.05	90.07 ± 0.17	0.37
LSTM / patches	76,042	88.83	87.65 ± 0.38	0.58
GRU / patches	57,354	88.97	88.00 ± 0.23	0.56

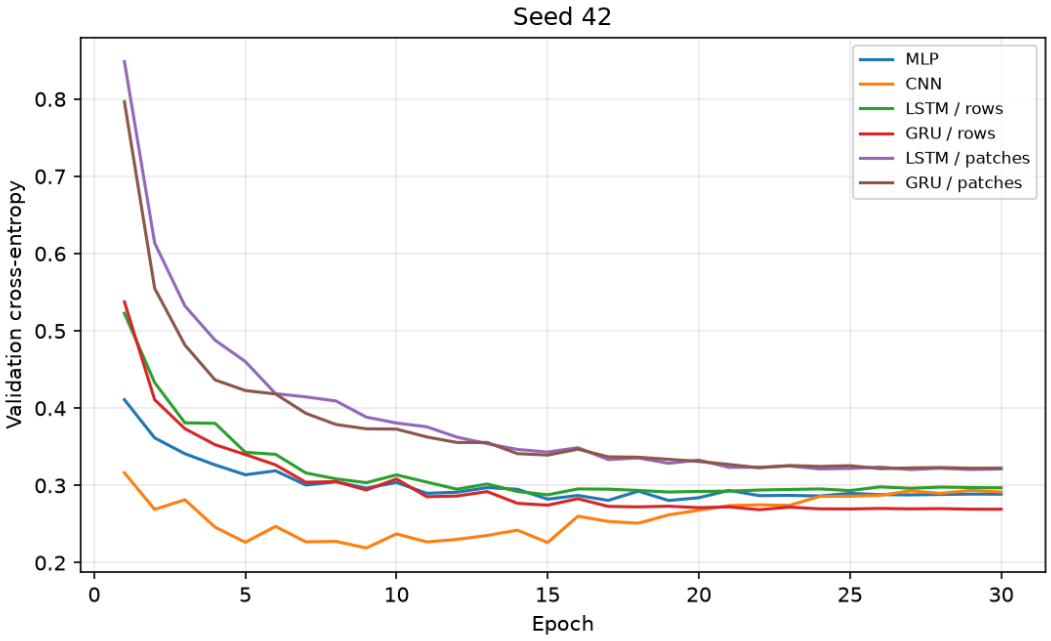
Bảng 4.1: Kết quả E3 và hai mô hình đối chứng E1 trên cùng phân hoạch dữ liệu.

Val/Test: accuracy (%). Tham số đếm từ kiến trúc; ±: SD qua ba seed. Các lượt chạy được liệt kê ở Chương 5; cách đo thời gian ở Chương 1.

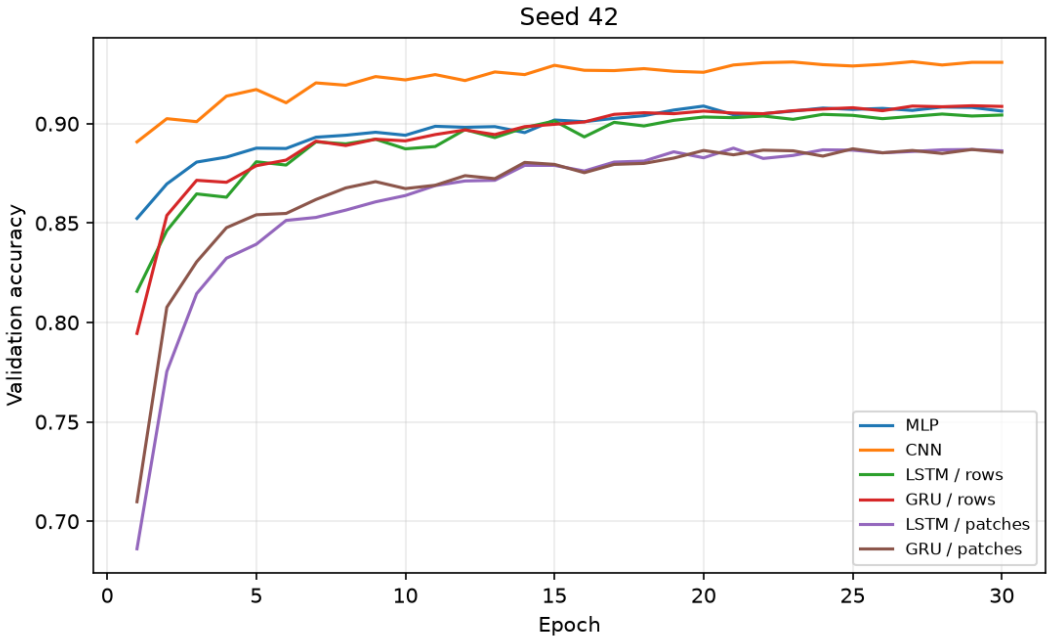
CNN khai thác lân cận hai chiều và chia sẻ kernel; LSTM/GRU tích lũy thông tin theo đường quét. Khi chuyển từ cuối một hàng patch sang đầu hàng kế tiếp, hai phần tử kề nhau trong chuỗi chưa chắc là hàng xóm gần nhất trên ảnh. Đường quét vì vậy giữ thứ tự một chiều và chỉ bảo toàn một phần quan hệ lân cận hai chiều.

Quét theo hàng tăng độ chính xác trên tập test trung bình so với quét theo ô ở cả LSTM và GRU. Chênh lệch ghép theo seed là $1{,}93 \pm 0{,}42$ điểm phần trăm với LSTM và $2{,}07 \pm 0{,}22$ điểm phần trăm với GRU. Trên cùng biểu diễn theo hàng, GRU cao hơn LSTM $0{,}49 \pm 0{,}21$ điểm phần trăm.

GRU theo hàng đạt 90,07%, gần với MLP (89,88%) và thấp hơn CNN (92,62%). GRU theo hàng có 61.962 tham số, so với 235.146 của MLP và 421.738 của CNN. Hai cách quét thay đổi đồng thời số bước và kích thước của mỗi token, nên chênh lệch quan sát được phản ánh tác động kết hợp của chúng.



Hình 4.1: Cross-entropy trên tập validation của các mạng hồi tiếp và mô hình đối chứng E1 ở cùng seed.

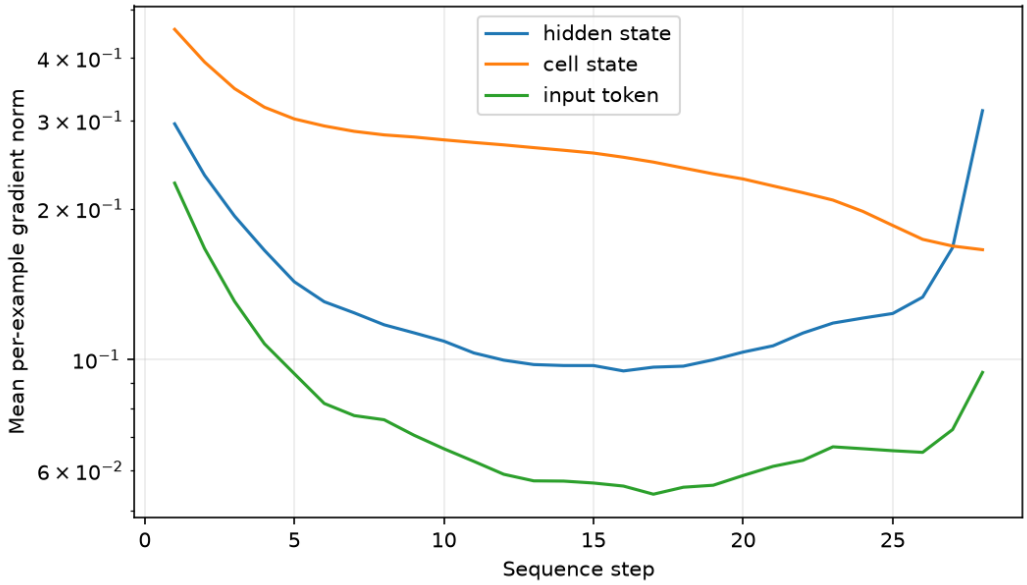


Hình 4.2: Độ chính xác trên tập validation của E3 và hai mô hình đối chứng MLP, CNN.

4.4 Độ nhạy với thứ tự quét

Phép đo dùng checkpoint LSTM đọc theo hàng của mỗi seed và cùng 256 ảnh validation có chỉ số gốc nhỏ nhất. Ba lần đánh giá lần lượt dùng thứ tự gốc, đảo ngược chuỗi và một hoán vị cố định. Trọng số của mô hình giữ nguyên trong cả ba phép đo. Độ chính xác trung bình lần lượt là 89,71%, 20,96% và 44,53%.

Để khảo sát đường truyền gradient, phép khai triển dùng cùng trọng số với mô-đun hồi tiếp và giữ lại đạo hàm của các trạng thái trung gian. Cross-entropy được cộng theo mẫu để tránh hệ số chia theo kích thước batch. Chuẩn gradient được tính cho từng mẫu trước khi lấy trung bình. Hình dưới trình bày gradient theo trạng thái ẩn, trạng thái ô nhớ và token đầu vào của LSTM theo hàng ở seed 42.



Hình 4.3: Chuẩn gradient theo bước của LSTM đọc ảnh theo hàng trên tập validation ở seed 42.

Mức giảm độ chính xác khi thay đổi thứ tự cho thấy checkpoint nhạy với cách quét đã học. Đảo và hoán vị tạo đầu vào khác phân bố huấn luyện. Do đó, mức giảm chỉ mô tả độ nhạy trong phép thử này. CNN và MLP xử lý trực tiếp lưới pixel hoặc vector cố định, nên đối chiếu với hai mô hình này dựa trên độ chính xác và số tham số. Chuỗi 28 hoặc 49 bước giới hạn phạm vi kết luận về phụ thuộc dài hạn.

Chương 5

Tái lập và giới hạn

5.1 Mã nguồn và tệp kết quả

Quy trình thực nghiệm được trình bày trong `notebooks/E1.ipynb`, `notebooks/E2.ipynb` và `notebooks/E3.ipynb`. Các notebook sử dụng mã mô hình theo từng bài và vòng lặp PyTorch trong `src/common/`. Mỗi run có `run.json`, `history.csv`, `best.pt`, `last.pt` và `metrics.json`. Đánh giá test sinh thêm prediction CSV, confusion matrix, ảnh sai và chỉ số theo lớp. Siêu tham số được khai báo trong `configs/experiments.json`.

Checkpoint cuối epoch lưu model, AdamW, cosine scheduler, lịch sử và trạng thái RNG của Python, NumPy, PyTorch, CUDA, shuffle generator. Resume từ epoch hoàn tất gần nhất, không từ batch đang dở. Fingerprint kiểm tra code, config, seed, dữ liệu và normalization; môi trường torch/CUDA cũng được đối chiếu. Khóa thư mục ngăn hai tiến trình ghi cùng run. Cơ chế này không hứa khả năng tái lập bitwise giữa các phần cứng khác nhau.

`scripts/export_report.py` tổng hợp kết quả thành bảng LaTeX, CSV/JSON và hình vẽ. Chương trình đối chiếu cấu hình, seed, split và checkpoint trước khi gộp các lượt chạy.

5.2 Cấu hình và các lượt chạy

Ba notebook đã thực thi 39 lượt huấn luyện và 39 lượt đánh giá trên tập test với RTX 5090, PyTorch 2.10.0 và CUDA 13.0. Bảng và đường cong trong báo cáo lấy từ các lượt này. Bảng dưới mô tả phạm vi kết quả theo từng bài. Hai mô hình đối chứng E1 được dùng lại trong E3.

Bài	Cấu hình	Số cấu hình	Số lượt
E1	Softmax, MLP, CNN	3	9
E2	Hai hiện thực MSA với ba cách tạo token	6	18
E3	LSTM, GRU với hai cách biểu diễn ảnh	4	12

Bảng 5.1: Phạm vi kết quả. Mỗi cấu hình được huấn luyện và đánh giá với các seed 42, 43 và 44.

Các kiểm thử bao gồm đầu ra và gradient của MSA, thứ tự token, phép khai triển LSTM/GRU, phân hoạch dữ liệu và khôi phục trạng thái huấn luyện. Môi trường chạy, log và checksum được ghi trong `docs/TRAINING_EXECUTION.md` cùng thư mục kết quả.

Ba seed cho phép quan sát biến thiên giữa các lượt khởi tạo. Phạm vi so sánh giới hạn ở một tập dữ liệu, ngân sách 30 epoch và các siêu tham số đã chọn. Các chuỗi 28/49 bước cũng ngắn hơn nhiều so với những bài toán phụ thuộc dài hạn.

5.3 Kết luận

CNN đạt độ chính xác trên tập test trung bình cao nhất trong 13 cấu hình, 92,62%. Trong E2, cả hai hiện thực MSA đạt độ chính xác cao nhất với token từ CNN-stem. Trong E3, cả LSTM và GRU đạt kết quả tốt hơn khi đọc ảnh theo hàng. GRU theo hàng đạt 90,07% với số tham số thấp hơn MLP và CNN. Phép thay đổi thứ tự quét trên tập validation cho thấy LSTM theo hàng phụ thuộc vào cách sắp xếp token đã dùng khi huấn luyện.

Phạm vi hỗ trợ của AI được trình bày trong `AI_USE_REPORT.md`.

Tài liệu tham khảo

[1] Lê Thành Sách, Nguyễn Quốc Minh. *Bài tập E1–E3: Học sâu và ứng dụng trong thị giác máy tính, CO5085*. Đề học kỳ 261 (2026–2027).

[2] H. Xiao, K. Rasul, R. Vollgraf. *Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms*. arXiv:1708.07747, 2017. https://arxiv.org/abs/1708.07747. Dữ liệu: https://github.com/zalandoresearch/fashion-mnist.

[3] A. Vaswani và cộng sự. *Attention Is All You Need*. NeurIPS, 2017. https://arxiv.org/abs/1706.03762.

[4] PyTorch. *LSTM: API and equations*. https://docs.pytorch.org/docs/2.9/generated/torch.nn.LSTM.html.

[5] PyTorch. *GRU: API and implementation notes*. https://docs.pytorch.org/docs/2.9/generated/torch.nn.GRU.html.

[6] PyTorch. *Previous versions: torch 2.10.0 / torchvision 0.25.0*. https://pytorch.org/get-started/previous-versions/.